

Day 01

음성 AI 첫걸음 기술 지형도와 개발환경

Listen → Think → Speak

4 시간 · Colab T4 GPU · 실습 노트북 Part 1 ~ 6

```
# 실습 노트북 1-2 셀 출력
Python      : 3.13
CUDA 사용   : True
GPU          : Tesla T4
FFmpeg       : /usr/bin/ffmpeg
```

 안녕하세요 . 오늘 회의를
시작하겠습니다 .

 RTF 0.05 → 실시간보다 빠름

사용법만으로는 답하기 어려운 질문

1 Whisper 는 소리를 그대로 듣지 않는다 . 무엇을 " 보고 " 받아쓸까 ?

D3 · D7

2 받아쓰기가 " 잘 됐다 " 는 것을 어떻게 숫자로 말할까 ?

D10

3 우리 회사 전문용어를 Whisper 가 알아듣게 하려면 ?

D12 · D13

4 몇 초짜리 목소리만으로 음성을 복제할 수 있을까 ? 해도 될까 ?

D19

5 음성 비서는 왜 사람보다 늦게 대답할까 ? 얼마나 줄일 수 있을까 ?

D21 · D28

넘어가기 전에 각 질문의 답을 한 줄씩 적어 두세요 . 과정이 끝난 뒤 다시 비교합니다 .

" 어떻게 쓰는가 " 에서 " 왜 이렇게 동작하는가 " 로

	사용법 중심 학습	이번 과정
질문	어떻게 사용하는가	왜 이렇게 동작하는가
확인 방법	실행 결과만 확인	파형 · 스펙트로그램 · RTF · CER · Latency 로 직접 측정
Whisper	model.transcribe() 호출	소리를 어떤 그림으로 바꿔 읽는가 , 얼마나 빠르고 정확한가
TTS	음성 파일 만들기	왜 16kHz mono WAV 로 바꿔야 하는가
음성 비서	STT, LLM, TTS 연결	어느 단계가 얼마나 오래 걸리는가 , 어떻게 줄이는가

가장 큰 차이는 확인 방법 : 설명을 듣고 끝내지 않고 , 설명한 내용이 사실인지 직접 확인한다 .

음성 비서 단면도로 보는 8주

입력 · 오디오

1 주 디지털 오디오 · 샘플링 · 스펙트로그램 · VAD

ASR 듣기

2 주 Whisper · faster-whisper · 화자 분리 3 주 한국어 Fine-tuning

LLM 생각하기

5 주 Claude API · Tool Calling · RAG · MCP

TTS 말하기

4 주 Kokoro · Chatterbox · Voice Cloning 과 윤리

실시간 · 배포

6 주 Pipecat · LiveKit · Streaming 7 주 FastAPI · Docker · Edge

▶ 애니메이션 [D1-1 오늘의 흐름 \(Part 1 ~ 6\)](#)

평가 · 모든 총

CER · WER (정확도)

RTF (속도)

MOS (음질) · Latency (응답)

8주 · 최종 프로젝트

AI 콜센터, 키오스크 음성 주문, 회화 튜터 등 한 층도 빠짐없이 조립

공개 모델을 잘 쓰고, 고치고, 조립하는 과정

다루지 않는다

대규모 음성 모델 처음부터 사전학습 (Pretraining)
음악 · 효과음 생성
음성 기반 본인 인증 · 보안 시스템
음성학 · 언어학 이론

다룬다

Whisper · Kokoro 등 공개 모델 활용
한국어 데이터로 Fine-tuning (3 주차)
LLM · Tool · MCP 연결 (5 주차)
실시간 파이프라인과 배포 (6 ~ 7 주차)

오늘 쓰는 공개 모델과 도구

faster-whisper (large-v3-turbo) edge-tts jiwer librosa Claude API (선택)

Day 한 편의 흐름과 자료 구성



<u>D1_ 실습 .ipynb</u> 실습 노트북 Colab 에서 따라 하기 · 빈칸 6 개 · 정답 보기	<u>animation.html</u> 애니메이션 9 개 탭 · 마이크 실시간 · 직접 조작	<u>worksheet.html</u> 개념 워크시트 4 교시 × 10 문항 · 교시마다 채점 · 오답 캡처 → 노션 제출	<u>slides.pptx</u> 강의 슬라이드 지금 보는 자료 · 발표자 노트 포함
---	---	--	---

권장 순서 : 슬라이드 설명 → 노트북 따라 하기 (출력 비교 , 다르면 오류 해결표) → animation.html 직접 조작 → 빈칸 실습 → 교시 끝 worksheet.html → 오답 캡처를 노선에 제출

무엇을 넣고 , 무엇을 얻는가

ASR	음성	>	ASR 모델 · Whisper	>	글자	2 ~ 3 주
TTS	글자	>	TTS 모델 · edge-tts, Kokoro	>	음성	4 주
Speech-to-Speech	음성	>	S2S 모델 · Realtime, Live	>	음성	6 주
Voice Agent	음성	>	STT > LLM > TTS	>	음성	5 ~ 6 주

▶ 애니메이션 D1-2 4대 기술 입출력 흐름

이미 매일 쓰고 있는 네 가지 기술

ASR · 받아쓰기

회의록 자동 작성 · 동영상 자막
콜센터 녹취 분석 · 음성 검색

TTS · 읽어주기

지하철 안내 방송 · 오디오북
내비게이션 · 화면 읽어주기

Speech-to-Speech

실시간 통역
감정이 살아 있는 자연스러운 대화

Voice Agent

AI 콜센터 상담원 · 예약 비서
키오스크 음성 주문

규칙에서 딥러닝 , 그리고 실시간 에이전트로



2022 년 **Whisper** 공개 이후 누구나 고품질 음성 인식을 쓸 수 있게 되었고 , 이제는 듣고 말하는 에이전트로 발전하고 있다 .

Google Colab · T4 GPU · Python 3.13

구성	기준	확인 방법
Runtime	Google Colab · T4 GPU	<code>!nvidia-smi</code>
Python	3.13 (Colab 기본)	<code>sys.version</code>
PyTorch	CUDA 사용 가능	<code>torch.cuda.is_available()</code>
FFmpeg	Colab 기본 설치	<code>!ffmpeg -version</code>
ASR	faster-whisper · large-v3-turbo	Part 5 모델 로드 셀
TTS	edge-tts · ko-KR 목소리	Part 2 목소리 목록
LLM (선택)	Claude API · Colab Secrets	<code>ANTHROPIC_API_KEY</code>

GPU 런타임을 선택한다

런타임 > 런타임 유형 변경 > T4 GPU > 저장

CPU 로 실행해도 동작하지만 ASR 이 small 모델로 바뀌고 훨씬 느리다 .

```
$ !nvidia-smi
| Tesla T4 ... 15360MiB |

CUDA 사용 : True
```

API 키가 없어도 실습은 끝까지 진행된다 . Part 6 의 LLM 이 규칙 기반 응답으로 자동 대체되기 때문이다 .

아래층이 맞아야 위층이 동작한다

Google Colab

로컬 PC (uv)

Jupyter / Colab 노트북

Jupyter / Colab 노트북

음성 라이브러리

음성 라이브러리

FFmpeg

FFmpeg

PyTorch

PyTorch

Python

Python

CUDA / cuDNN

CUDA / cuDNN

NVIDIA Driver

NVIDIA Driver

GPU 하드웨어

GPU 하드웨어

▶ 애니메이션 [D1-3 개발환경 층 쌓기](#)

읽는 법

색이 채워진 층 : 이미 준비됨

점선 층 : 직접 설치

Colab에서는 맨 위 음성 라이브러리만 pip로 설치한다.

libcublas.so.12 오류는 CUDA 층 문제다.

관찰하고 측정하려면 도구가 먼저

```
!pip install -q faster-whisper edge-tts \
anthropic jiwer librosa soundfile
```

✓ 설치 완료

Part 5: CUDA 12용 라이브러리 (GPU 사용 시)

```
!pip install -q nvidia-cublas-cu12 \
"nvidia-cudnn-cu12==9.*"
```

도구	하는 일	Part
edge-tts	글자 → 목소리 합성	2
librosa	파형 · 스펙트로그램	3
ffmpeg	16kHz mono 변환	2 · 4
faster-whisper	받아쓰기 (ASR)	5
jiwer	CER 계산	5
anthropic	Claude API (LLM)	6

🧩 빈칸 실습 1 `gpu_ok = torch.cuda.____()` 정답 : `is_available`

실습 파일은 위에서부터 차례로 실행한다 . 중간 셀을 건너뛰면 뒤에서 **NameError** 가 난다 .

집에서는 uv 로 같은 환경을 만든다

```
# 설치 (Windows PowerShell)
> irm https://astral.sh/uv/install.ps1 | iex
# 프로젝트 만들기
$ uv init voice-ai && cd voice-ai
$ uv python pin 3.11
$ uv add torch faster-whisper edge-tts jiwer jupyterlab
# 실행
$ uv run jupyter lab
```


uv 란 ?

Rust 로 만든 매우 빠른 Python 패키지 관리 도구 . pip · venv · Python 버전 관리를 한 번에 한다 .

과제 3

로컬 PC 에 uv 로 환경을 만들고
torch.cuda.is_available() 결과 화면을 캡처해
제출한다 .

글자가 소리 파일이 되기까지



16kHz
1 초에 16,000 번 소리를 측정했다는 뜻


mono
채널이 하나 . 음성 모델의 공통 입력 형식

한국어 목소리
ko-KR-SunHiNeural (여성)
ko-KR-InJoonNeural (남성)

✖ 빈칸 실습 2 my_voice = "____" # 남성 목소리 정답 : ko-KR-InJoonNeural

▶ 애니메이션 [D1-4 소리 파일의 여행](#)

소리를 보는 두 가지 방법



파형

시간에 따른 소리의 크기. 평평하면 묵음

스펙트로그램

언제, 어떤 높낮이의 소리가 났는가. Whisper 가 읽는 그림

▶ 애니메이션 [D1-5 내 목소리 보기 \(마이크 실시간\)](#)

샘플 수로 오디오 길이를 알 수 있다

$$80,000 \div 16,000 = 5 \text{ 초}$$

샘플 수

1 초당 측정 횟수

오디오 길이

샘플 수 : 80,000 | 샘플링 레이트 : 16000 Hz
길이 : 5.00 초 | 범위 : [-0.612, 0.587]

🧩 빈칸 실습 3 `len(y) / _____` 정답 : sr

▶ 애니메이션 [D1-6 샘플링 체험 · 길이 계산기](#)

Whisper 는 그림을 보고 글자를 쓴다



환경	모델	특징
GPU (T4)	large-v3-turbo	정확하고 빠름 · 오늘 기본값
CPU	small	가벼움 · 정확도 낮음

sample.wav
[0.00s → 4.20s] 안녕하세요 . 음성 AI
 처리 0.4s | 오디오 7.8s | RTF 0.05

출력 수치는 예시

빈칸 실습 4 text, segs, info, elapsed = ____ (my_wav) 정답 : transcribe

▶ 애니메이션 D1-7 받아쓰기와 RTF

말하는 속도보다 빨리 받아쓰까 ?

10 초 음성을 1 초 만에 받아쓰면

0.1

$$\text{RTF} = \text{처리 시간} \div \text{음성 길이} = 1 \div 10$$

RTF < 1 · 실시간보다 빠름

말하는 속도보다 빨리 받아쓴다 . 음성 비서에 쓸 수 있다 .

RTF > 1 · 실시간보다 느림

녹음 파일을 모아서 나중에 처리하는 용도에 맞는다 .

몇 글자나 틀렸을까 ?

정답	오	늘	날	씨	중	다	.
인식	오	.	날	시	중	다	요
	일치	삭제	일치	대체	일치	일치	삽입

50%

3 번 틀림 ÷ 정답 6 글자

🌱 빈칸 실습 5 `cer = jiwer.____(ref, hyp)` 정답 : cer

▶ 애니메이션 [D1-8 CER 계산기 \(직접 입력\)](#)

같은 음성, 단계마다 보이는 모습이 다르다

librosa.load

숫자 배열

```
y.shape = (80000,)
float32, -1 ~ 1
1 초에 16,000 개
```

show_audio

소리 그림

```
80 mel × 약 500 frame
밝을수록 강한 소리
묵음은 어둡게
```

transcribe

시간 + 글자

```
[0.00s → 4.20s]
안녕하세요 . 음성 AI
RTF 0.05
```

jiwer.cer

정확도

```
REF 와 HYP 비교
대체 · 삭제 · 삽입
CER 0.00%
```

sample.wav 하나를 네 단계에서 관찰 : 숫자 → 그림 → 글자 → 점수

출력 수치는 예시이며 실행 환경에 따라 다르다 .

만날 수 있는 오류와 해결

오류 메시지	원인	해결 (노트북에 반영됨)
<code>open() got an unexpected keyword argument 'metadata_errors'</code>	최신 PyAV 와 faster-whisper 충돌	파일 경로 대신 load_16k() 로 읽은 numpy 배열 전달
<code>libcublas.so.12 is not found</code>	CUDA 12 라이브러리 없음 (CUDA 총)	nvidia-cublas-cu12, cudnn 설치 후 미리 로드
<code>CUDA 사용 : False</code>	런타임 유형이 CPU	런타임 유형 변경 › T4 GPU
<code>NameError: name '____' is not defined</code>	빈칸을 채우지 않고 실행	빈칸을 채운 뒤 다시 실행
녹음 실패 · 마이크 권한	브라우저 마이크 권한 거부	주소창 권한 허용 , 안 되면 sample.wav 사용

오류가 나면 개발환경 총 그림을 떠올린다 . 메시지가 어느 총 이야기인지부터 찾는다 .

지금까지 만든 부품을 이어 붙인다



```
# 🧩 빈칸 실습 6: 함수 이름 3 개로 조립
user_text = transcribe(input_wav)[0]
reply, _ = llm_reply(user_text)
out = await tts(reply, "my_agent.wav")
```

API 키가 없다면

llm_reply() 가 규칙 기반 응답으로 자동 대체된다 .
" 지금 몇 시야 ?" → 현재 시각

▶ 애니메이션 [D1-9 음성 비서 시뮬레이터](#)

음성 비서의 답변은 짧은 말투로

텍스트 챗봇	음성 비서
표 · 목록 · 이모지 사용	기호가 그대로 읽히므로 쓰지 않음
길고 자세한 답변	1 ~ 2 문장 , 길면 기다림이 늘어남
문어체	구어체
괄호로 보충 설명	괄호 없이 문장으로 풀기


```
SYSTEM_PROMPT = (  
    " 당신은 친절한 한국어 음성  
    비서입니다 . 답변은 TTS 로  
    읽히므로 마크다운 , 목록 ,  
    이모지 , 괄호를 쓰지 말고  
    1~2 문장의 짧은 구어체로  
    답하세요 ."  
)
```

과제 2: **SYSTEM_PROMPT** 를 바꿔 나만의 음성 비서 캐릭터 (예 : 영어 회화 선생님) 만들기

사용자가 기다리는 시간 = 세 단계의 합



예시 값 . 실제 값은 노트북 Part 6 의 막대 그래프로 확인한다 .



▶ 애니메이션 [D1-9 음성 비서 · Streaming 비교 커기](#)

디지털 오디오와 음성 신호 처리 기초

- ☐ `torch.cuda.is_available()` 가 True 다
- ☐ `edge-tts` 로 내 문장을 남자 목소리로 만들었다
- ☐ 파형과 스펙트로그램을 보고 묵음 구간을 찾았다
- ☐ 내 목소리를 받아쓰고 RTF 를 확인했다
- ☐ CER 을 계산하고 대체 · 삭제 · 삽입을 구분했다
- ☐ 함수 3 개로 음성 비서를 조립했다

[worksheet.html](#)

40 문항

개념 워크시트 · 노션 제출

[animation.html](#)

9 개 탭

인터랙티브 애니메이션

[D1_실습.ipynb](#)

빈칸 6

실습 노트북

온라인 자료 imguru-mooc.github.io/AI_Voice/day01

다음 : Day 2

오늘 본 한 줄

샘플 수 : 80,000 | 16000 Hz

이 숫자 80,000 개는 어떻게 만들어지고 , 무엇을 잃고 무엇을 남길까 ?