

Day 02

디지털 오디오 기초 소리는 어떻게 숫자가 될까

Sampling → Quantization → Format → Preprocess
4 시간 · Colab CPU · 실습 노트북 Part 1 ~ 6

```
>>> make_model_ready(src)
```

```
[ 전 ] speech_hq.wav  
      44100 Hz | 2ch | PCM_16  
      6.00 초 | 1033.7 KB
```

```
[ 후 ] ready.wav  
      16000 Hz | 1ch | PCM_16  
      5.92 초 | 185.0 KB
```

출력 예시

어제 쓴 16kHz WAV, 정확히 무엇이었을까

- 1 컴퓨터 안의 소리는 결국 무엇일까 ? Part 1
- 2 음성 AI 는 왜 16,000 Hz 면 충분할까 ? Part 2
- 3 샘플링 레이트를 함부로 줄이면 무슨 일이 생길까 ? Part 2
- 4 16bit 는 무슨 뜻이고 , 왜 가장 흔할까 ? Part 3
- 5 FLAC 은 작아졌는데 왜 원본과 숫자가 똑같은까 ? Part 5

수업이 끝나면 다섯 질문 모두에 한 문장으로 답할 수 있어야 한다 .

어제 배운 것 , 5 분 만에 확인하기

10 문항 · 5 분

객관식 5

O / X 2

선잇기 1

순서 맞추기 1

모두 고르기 1



[day02/worksheet2.html](#) 복습 애니메이션

D1 에서 꼭 기억할 것

16kHz mono WAV 모델 공통 입력

스펙트로그램 Whisper 가 읽는 그림


RTF < 1 실시간보다 빠름

CER 틀린 글자 ÷ 정답 글자

`transcribe` → `llm_reply` → `tts`

오류는 아래층부터 GPU → CUDA → torch


소리에서 숫자 , 숫자에서 파일 , 파일에서 모델 입력까지



교시	내용	실습
1 교시	D1 복습 , 소리의 정체 , 샘플링	Part 1 ~ 2 · 빈칸 1, 2
2 교시	양자화 , 채널	Part 3 ~ 4 · 빈칸 3, 4
3 교시	파일 포맷 비교	Part 5 · 빈칸 5
4 교시	pydub 편집 , 전처리 , 워크시트	Part 6 ~ 7 · 빈칸 6, 7

▶ 애니메이션 [D2-1 오늘의 흐름 \(Part 1 ~ 6\)](#)

공기의 떨림이 숫자 배열이 되기까지



주파수 (Hz) = 높낮이

1 초에 몇 번 떨리는가 . 많이 떨릴수록 높은 소리

진폭 = 크기

얼마나 크게 떨리는가 . 크게 떨릴수록 큰 소리

▶ 애니메이션 D2-2 소리의 정체 (슬라이더로 듣기)

숫자 몇 줄로 "라" 소리를 만든다



```
def tone(freq, sec=1.0, sr=SR, amp=0.5):  
    t = np.arange(int(sr*sec)) / sr  
    return amp * np.sin(2*np.pi*freq*t)
```

```
Audio(tone(440), rate=SR)
```

숫자 배열의 정체

`tone(220, sec=0.02) → 모양 (320,) float32`

처음 숫자: `[0. 0.043 0.086 0.128 ...]`

한 옥타브

440 Hz의 두 배인 880 Hz는 한 옥타브 높은 "라"

🧩 빈칸 실습 1 `my_tone = tone(____)` # 880 Hz 정답: 880

1 초에 몇 번 측정할까



샘플링 레이트	8,000 Hz	16,000 Hz	44,100 Hz	48,000 Hz
주로 쓰는 곳	옛날 전화	음성 인식 (Whisper)	음악 CD	영상 · 방송

샘플링 레이트의 절반까지만 담을 수 있다

$$16,000 \text{ Hz} \div 2 = 8,000 \text{ Hz}$$

샘플링 레이트

담을 수 있는 최고 높이

음성 AI · 16,000 Hz

8,000 Hz 까지 담음 . 말소리에 충분

전화 · 8,000 Hz


4,000 Hz 까지 . 목소리가 먹먹하게 들리는 이유

음악 · 44,100 Hz

약 22,000 Hz 까지 . 사람이 듣는 거의 모든 높이

▶ **애니메이션** [D2-3 샘플링 체험 \(전화 vs 음성 AI vs CD\)](#)

함부로 줄이면 가짜 소리가 생긴다



건너뛰기 `chirp[::4]`

절반을 넘는 높은 소리가 가짜 낮은 소리로 접힌다 (Aliasing)

`librosa.resample()`

높은 소리를 먼저 걸러낸 뒤 줄인다. 가짜 소리 없음

샘플링 레이트는 이렇게 바꾼다

방법	코드	결과
불러오면서 바꾸기	<code>librosa.load("x.wav", sr=16000)</code>	✅ 가장 많이 씀
배열 바꾸기	<code>librosa.resample(y, orig_sr=44100, target_sr=16000)</code>	✅ 바른 방법
파일 바꾸기	<code>ffmpeg -i in.wav -ar 16000 out.wav</code>	✅ 바른 방법
건너뛰기	<code>y[::3]</code>	❌ Aliasing
숫자만 바꿔 저장	<code>sf.write("out.wav", y44, 16000)</code>	❌ 느리고 낮은 소리

🧩 빈칸 실습 2 `y16 = librosa.resample(y44, orig_sr=sr44, target_sr=___)` 정답 : 16000

크기를 몇 단계로 적을까



비트 깊이	8bit	16bit	24bit	32bit float
단계 · 쓰는 곳	256 · 옛날 게임 , 전화	65,536 · CD, 음성 데이터	약 1,677 만 · 스튜디오	소수 · librosa 배열

soundfile 의 subtype

```
for subtype in ["PCM_16", "PCM_24", "FLOAT"]:  
    sf.write(f"q_{subtype}.wav", y, SR, subtype=subtype)
```

PCM_16	→ Signed 16 bit PCM	187.5 KB
PCM_24	→ Signed 24 bit PCM	281.3 KB
FLOAT	→ 32 bit float	375.1 KB

크기 비율

16bit : 24bit : 32bit
= 2 : 3 : 4 바이트

비트 깊이에 정확히 비례한다

출력 수치는 6 초 예시 음성 기준

✖ 빈칸 실습 3 `sf.write("my_16bit.wav", y, SR, subtype="_____")` 정답 : PCM_16

▶ 애니메이션 [D2-4 양자화 체험 \(비트 줄여 듣기\)](#)

mono 와 stereo, 그리고 라이브러리마다 다른 모양

mono

채널 1 개
음성 모델 입력

stereo

채널 2 개 (L, R)
음악 · 영상

라이브러리	모양	예
librosa	(채널 , 샘플) = (2, N)	<code>librosa.load(f, mono=False)</code>
soundfile	(샘플 , 채널) = (N, 2)	<code>sf.read(f)</code>
저장할 때	librosa 배열 → .T	<code>sf.write(f, stereo.T, sr)</code>
mono 로 합치기	채널 축 평균	<code>stereo.mean(axis=0)</code>

🧩 **빈칸 실습 4** `mono = stereo.mean(axis=_____)` 정답 : 0

▶ **애니메이션** [D2-5 채널 체험 \(좌우 이동\)](#)

무손실은 원래 숫자 그대로, 손실은 덜 중요한 소리를 버린다

WAV

무손실 · 압축 없음

가장 단순하고 큼
학습 · 추론 입력의 표준

FLAC

무손실 · 압축

원래 숫자 그대로 작아짐
데이터셋 보관

MP3

손실 · 압축

작고 어디서나 재생
배포 · 다운로드

Opus


손실 · 압축

낮은 비트레이트에서도 깨끗
실시간 통화 · WebRTC

무손실 : 모델 학습 · 입력

손실 : 사람에게 들려주기 · 전송

크기는 줄이고 , 숫자는 지킬까 버릴까



포맷	WAV 대비	원래 숫자와 차이
WAV	100%	0 (같음)
FLAC	29%	0 (같음)
MP3	26%	0.0257
Opus	11%	0.1682

6 초 예시 음성 · 16kHz · 16bit 기준 실행 결과 . 음성에 따라 달라진다 .

무손실 **FLAC**: 작아져도 숫자는 그대로 . 손실 **MP3 · Opus**: 훨씬 작지만 숫자가 바뀐다 .

WAV 크기는 계산으로 알 수 있다

$$16,000 \times 2 \times 1 \times 10 = 320,000$$

1 초당 샘플

바이트 (16bit)

채널

초

바이트

예측 192,000 바이트 | 실제 192,044 바이트
(차이 44: 파일 머리말)

🧩 빈칸 실습 5 bytes_per_sample = _____ 정답 : 2

▶ 애니메이션 [D2-6 포맷 계산기 \(1시간 데이터 크기\)](#)

네 가지 도구, 각자 잘하는 일이 다르다

soundfile

읽기 · 쓰기

```
sf.info(f)
sf.read(f)
sf.write(f, y, sr)
```

librosa

분석 · 변환

```
librosa.load(f,
sr=16000)
librosa.resample(...)
특징 추출 (D3)
```

pydub

편집

```
audio[1000:4000]
audio + 6
.fade_in(500)
```

ffmpeg

형식 변환

```
webm · m4a · mp3
→ wav
-ar 16000 -ac 1
```

▶ 애니메이션 [D2-7 도구 고르기 \(상황 8개\)](#)

시간은 밀리초 (ms) 로 다룬다

```
from pydub import AudioSegment
audio = AudioSegment.from_file("speech.wav")

clip = audio[1000:4000]          # 1 초 ~ 4 초
loud = clip + 6                  # 6dB 키우기
faded = clip.fade_in(500).fade_out(1000)
both = clip + AudioSegment.silent(800) + clip
clip.export("out.mp3", format="mp3")
```


밀리초 감각

1 초 = 1,000 ms
audio[:2000] = 처음 2 초
audio[-3000:] = 마지막 3 초
len(audio) = 길이 (ms)

✂ 빈칸 실습 6 first2 = audio[:____] # 2 초 정답: 2000

▶ 애니메이션 [D2-8 pydub 편집기](#)

어떤 파일이든 음성 모델용으로 바꾸는 전처리기



```
def make_model_ready(src, dst="ready.wav"):
    y, sr = librosa.load(src, sr=____, mono=____)
    y, _ = librosa.effects.trim(y, top_db=30)
    y = y / (np.abs(y).max() + 1e-9) * 0.9
    sf.write(dst, y, sr, subtype="PCM_16")
```

빈칸 실습 7

- ① sr=16000
- ② mono=True

webm, m4a 는 ffmpeg 로 먼저 wav
변환

▶ 애니메이션 [D2-9 전처리 파이프라인 \(단계별 정보 카드\)](#)

입력은 제각각 , 출력은 하나

입력 파일	입력 정보	→	출력 정보
speech_hq.wav	44100 Hz · 2ch · PCM_16 · 1033.7 KB	→	16000 Hz · 1ch · PCM_16 · 185.0 KB
speech.mp3	24000 Hz · 1ch · MP3 · 23.9 KB	→	16000 Hz · 1ch · PCM_16 · 185.0 KB
stereo.wav	16000 Hz · 2ch · PCM_16 · 125.0 KB	→	16000 Hz · 1ch · PCM_16 · 62.5 KB
f.flac	16000 Hz · 1ch · PCM_16 · 53.9 KB	→	16000 Hz · 1ch · PCM_16 · 185.0 KB

출력 열이 모두 같은 형식이다 . 과제 1: 휴대폰 녹음 (m4a) 으로 직접 해 보기

노트북 실행 예시 , 크기와 길이는 음성에 따라 다르다 .

오늘 만날 수 있는 오류와 해결

증상	원인	해결
No module named 'audioop' (pyaudioop)	Python 3.13 에서 audioop 제거	pip install audioop-lts (설치 셀에 포함)
webm 녹음 파일을 librosa 가 못 읽음	librosa 가 webm 형식을 직접 못 읽음	ffmpeg 로 먼저 wav 변환
진폭을 바꿔도 소리 크기가 같음	Audio() 가 크기를 자동으로 맞춤	Audio(..., normalize=False)
stereo 저장에 이상하거나 오류	librosa (2, N) 모양 그대로 저장	sf.write(f, stereo.T, sr)
저장한 소리가 느리고 낮음	sr 숫자만 바꿔 저장	librosa.resample() 로 먼저 변환

소리가 이상하면 먼저 확인할 세 가지 : 샘플링 레이트 , 채널 수 , 배열 모양

오늘의 원리를 여섯 줄로

원리	수식	예	노트북 검증
사인파 · 데시벨	$x[n] = A \cdot \sin(2\pi f n / f_s)$ $L = 20 \cdot \log_{10}(A1 / A0)$	진폭 2 배 → +6.02 dB	RMS = A/√2 일치
샘플링 정리	$N = f_s \cdot T$ $f_{\max} < f_s / 2$	16 kHz → 8 kHz 까지	N_new = 96,000 일치
Aliasing	$f_{\text{alias}} = f - k \cdot f_s $	7,000 Hz @11,025 → 4,025 Hz	건너뛰기 측정 4,025 Hz
양자화 잡음	$L = 2^b, \Delta \approx 2^{(1-b)}$ $\text{SNR} \approx 6.02 \cdot b + 1.76 \text{ dB}$	16bit ≈ 98 dB	측정 98.1 dB
비트레이트	$R = f_s \cdot b \cdot C$ $\text{bytes} = f_s \cdot b/8 \cdot C \cdot T + 44$	256 kbps → MP3 64k = 4 배	크기 예측 ±2 KB
dB 이득 · 정규화	$g = 10^{(G/20)}$ $y' = 0.9 \cdot y / \max y $	+6 dB → ×1.995	pydub 측정 1.995

측정값은 노트북 실행 예시 기준

주파수 분석 : 스펙트로그램은 어떻게 만들어질까

- ☐ tone() 으로 880 Hz 소리를 만들어 들었다
- ☐ 건너뛰기와 resample 의 차이를 소리로 구분했다
- ☐ PCM_16 으로 저장하고 sf.info 로 확인했다
- ☐ stereo 를 mono 로 합치고 모양을 확인했다
- ☐ WAV, FLAC, MP3, Opus 의 크기와 차이를 비교했다
- ☐ make_model_ready() 로 여러 파일을 변환했다

다음 : Day 3

오늘 본 그림 한 장
Aliasing 스펙트로그램

이 그림은 숫자 배열에서 어떻게 만들어질까 ? 25ms
창 , 10ms hop 의 의미는 ?

[worksheet1.html](#)

40 문항

개념 워크시트 · 노션 제출

[animation.html](#)

9 개 탭

인터랙티브 애니메이션

[D2_실습.ipynb](#)

빈칸 7

실습 노트북

온라인 자료 imguru-mooc.github.io/AI_Voice/day02