

Day 03

주파수 분석

FFT · STFT · Mel · MFCC

Sum of Sines → DFT → STFT → Mel → MFCC
4 시간 · Colab CPU · 실습 노트북 Part 1 ~ 6

```
>>> extract_features("speech.wav")
```

Log-Mel (80, 593) ← Whisper 입력

MFCC (13, 593) ← 붕우리 모양

1 초에 약 100 frame

```
>>> logmel_30s.shape  
(80, 3000)
```

출력 예시

Whisper 가 읽는 " 소리 그림 " 은 어떻게 만들어질까

1 목소리 같은 복잡한 소리는 무엇으로 이루어져 있을까 ?

Part 1

2 FFT 는 신호 속 주파수를 어떻게 찾아낼까 ?

Part 2

3 25 ms 로 잘라 보면 몇 Hz 차이까지 구분할 수 있을까 ?

Part 3

4 Whisper 의 80×3000 입력은 정확히 어떻게 만들까 ?


Part 4 · 5

5 목소리 높이가 달라도 " 아 " 를 " 아 " 로 알아보는 특징은 ?

Part 6

수업이 끝나면 다섯 질문 모두에 수식 하나와 한 문장으로 답할 수 있어야 한다 .

사인파에서 MFCC 까지



교시	내용	실습
1 교시	사인파의 합 , 배음 · 포먼트 , DFT 원리 , 오일러	Part 1 ~ 2 · 빈칸 1, 2 · 워크시트 1 교시
2 교시	FFT 실습 : 해상도 , 창 함수 , dB	Part 3 · 빈칸 3 · 워크시트 2 교시
3 교시	STFT, 스펙트로그램 , 트레이드오프	Part 4 · 빈칸 4 · 워크시트 3 교시
4 교시	Mel, Log-Mel, MFCC, 특징 추출기	Part 5 ~ 7 · 빈칸 5 ~ 7 · 워크시트 4 교시 · 노선 제출

▶ 애니메이션 [D3-1 오늘의 흐름 \(Part 1 ~ 6\)](#)

복잡한 소리 = 배음 (f_0 의 정수배)의 합



음 높이 = f_0


반복 주기 $T = 1/f_0$. 배음을 바꿔도 그대로

음색 = A_k

각 배음의 크기 비율. 피아노 vs 바이올린, "아" vs "이"

▶ 애니메이션 [D3-2 사인파의 합 \(배음 슬라이더\)](#)

같은 높이, 다른 모음 : 봉우리 위치가 다르다



$$x(t) = \sum A_k \sin(2\pi \cdot k \cdot f_0 \cdot t + \phi_k)$$

$A_k \approx G(k \cdot f_0)$ G = 성도의 봉우리 모양

모음	F1	F2
아	약 700 Hz	약 1200 Hz
이	약 300 Hz	약 2300 Hz
우	약 300 Hz	약 800 Hz

시간 영역과 주파수 영역




FFT: 시간 영역 → 주파수 영역 . STFT: 둘을 합쳐 " 언제 , 어떤 높이가 " (스펙트로그램)

시험 사인파와 곱해서 더하기



▶ 애니메이션 [D3-3 DFT 원리 \(스캔 · 감아 보기\)](#)

cos와 sin을 한 번에 : $e^{j\theta} = \cos \theta + j \sin \theta$




단계	식
급수	$e^x = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \dots$
$x = j\theta, j^2 = -1$	$e^{j\theta} = (1 - \frac{\theta^2}{2!} + \dots) + j(\theta - \frac{\theta^3}{3!} + \dots) = \cos \theta + j \sin \theta$
DFT 시험 사인파	$e^{-j2\pi fn/fs} = \cos(2\pi fn/fs) - j \sin(2\pi fn/fs)$

$$X[k] = \sum x[n] \cdot e^{-j2\pi kn/N}$$

$$X[k] = \sum_{n=0}^{N-1} x[n] \cdot e^{-j2\pi kn/N} = c_k - j \cdot s_k$$

$$f_k = k \cdot f_s / N \quad |X[k]| = \sqrt{c^2 + s^2} \quad A = 2|X[k]| / N$$



$N = 16$ 예시: $f_k = k \cdot f_s/N$, 유용한 범위는 $k = 0 \sim N/2$ (rfft: $N/2+1$ 개)

🧩 빈칸 실습 2 `freqs = np.arange(N) * _____ / N; mag = np._____(X)` 정답 : SR, abs

결과는 같고 , 계산은 약 100 배 빠르다

$$1,048,576 \rightarrow 10,240 = \approx 100 \text{ 배}$$

DFT: N^2 ($N = 1024$)

FFT: $N \cdot \log_2 N$

곱셈 횟수 차이

결과가 같은가 : True

직접 DFT 45.7 ms | FFT 0.092 ms | 약 499 배


실전에서는 항상 **np.fft**

$N = 16,000$ (1 초) 이면 직접 DFT 행렬만 약 4 GB

실행 예시 . 시간은 환경에 따라 다르다 .

🧩 빈칸 실습 1 chord = tone(262) + tone(330) + tone(____) # 슬 답 : 392


$\Delta f = f_s / N$: 길게 볼수록 촘촘하다



N	길이	Δf
400	25 ms	40 Hz
4096	256 ms	3.9 Hz
16000	1 s	1 Hz

▶ 애니메이션 [D3-4 주파수 해상도](#)

그냥 자르면 새어 나간다 : Hann 창




$$w[n] = 0.5 - 0.5 \cdot \cos(2\pi n / (N-1))$$

🧩 빈칸 실습 3 $w = \text{np.} \underline{\hspace{1cm}} (N)$ 정답 : hanning

▶ 애니메이션 [D3-5 창 함수와 leakage](#)

잘라서 FFT 하고, 세워 붙이면 스펙트로그램



$$X[m, k] = \sum x[n + mH] \cdot w[n] \cdot e^{(-j2\pi kn/N)}$$


▶ 애니메이션 [D3-6 STFT 프레이밍](#)

(1 + N/2, 1 + [L/H])

상황	공식	예 (N=400, H=160)
center=False	$M = 1 + \lfloor (L - N)/H \rfloor$	L = 16,000 → 98
center=True (기본)	$M = 1 + \lfloor L/H \rfloor$	L = 16,000 → 101
30 초 (Whisper)	$1 + 480000 // 160$	3001 → 3000 사용
세로 (bin 수)	$1 + N/2$	201 (간격 40 Hz)
겹침	$(N - H)/N$	60%

 **빈칸 실습 4** hop = int(_____ * SR) # 10 ms 정답 : 0.010 → 160


시간과 주파수를 동시에 선명하게 볼 수 없다



$$(N / f_s) \times (f_s / N) = 1$$

▶ 애니메이션 [D3-7 시간-주파수 트레이드오프 \(실시간\)](#)


귀에 맞춘 주파수 축과 삼각형 필터



$$m = 2595 \cdot \log_{10}(1 + f/700) \quad \Leftrightarrow \quad f = 700(10^{(m/2595)} - 1)$$

▶ 애니메이션 [D3-8 Mel 필터뱅크](#)


Whisper 입력 80 × 3000 의 정체



단계	모양	수식
STFT 파워	(201, T)	$ X[k, t] ^2$
필터뱅크	(80, 201)	$H_m(k)$ 삼각형
Mel	(80, T)	$H \cdot X ^2$
Log-Mel	(80, T) 30 초 → (80, 3000)	$10 \cdot \log_{10}(\text{Mel})$


🧩 빈칸 실습 5 librosa.feature.melspectrogram(..., n_mels=____) 정답 : 80

Log-Mel 을 DCT 하면 앞쪽에 봉우리 모양이 모인다



$$c_n = \sum_m \log(\text{Mel}m) \cdot \cos[\pi \cdot n \cdot (m + 0.5) / M], \quad n = 0 \dots 12 \quad (c_0 = \text{전체 크기})$$

음 높이가 달라도 같은 모음이면 MFCC 가 비슷하다



" 아 "120 vs " 아 "240

MFCC 거리 약 91 (같은 모음)

" 아 "120 vs " 이 "120

MFCC 거리 약 169 (다른 모음)

▶ 애니메이션 [D3-9 MFCC](#)

🧩 빈칸 실습 6 `librosa.feature.mfcc(S=lm, n_mfcc=___)` 정답 : 13

extract_features(): 어떤 파일이든 Log-Mel 과 MFCC 로

```
def extract_features(src):  
    path = make_model_ready(src, "feat_in.wav")  
    y, sr = librosa.load(path, sr=16000)  
    mel = librosa.feature.melspectrogram(y=y, sr=sr,  
                                         n_fft=____, hop_length=____, n_mels=80)  
    logmel = librosa.power_to_db(mel, ref=np.max)  
    mfcc = librosa.feature.mfcc(S=logmel, n_mfcc=13)  
    return {"logmel": logmel, "mfcc": mfcc}
```

빈칸 실습 7

n_fft = 400 (25 ms)
hop_length = 160 (10 ms)

결과 : Log-Mel (80, T), MFCC (13, T), 1초에 약 100 frame

D6 부터 Whisper 가 이 Log-Mel 을 입력으로 받는다 .

오늘의 원리를 여덟 줄로

원리	수식	확인
푸리에 급수	$x(t) = \sum A_k \sin(2\pi k f_0 t + \varphi_k)$	배음 간격 = f_0
DFT	$X[k] = \sum x[n] e^{-j2\pi kn/N}$	<code>np.allclose(dft, fft)</code>
bin · 진폭	$f_k = k f_s / N, \quad A = 2 X[k] /N$	500 Hz → 0.5000
해상도	$\Delta f = f_s / N$	400 → 40 Hz
Hann 창	$w[n] = 0.5 - 0.5 \cos(2\pi n/(N-1))$	<code>np.hanning</code> 과 일치
STFT	$M = 1 + \lfloor L/H \rfloor, \quad \text{모양 } (1 + N/2, M)$	(201, 593)
Mel	$m = 2595 \log_{10}(1 + f/700), \quad H \cdot X ^2$	1000 Hz → 1000 mel
MFCC	$c_n = \sum \log \text{Mel}_m \cos[\pi n(m+0.5)/M]$	dct 직접 = librosa

오늘 헛갈리기 쉬운 것

헛갈리는 점	설명
직접 DFT 가 메모리 오류	$N \times N$ 복소수 행렬 . $N = 16,000$ 이면 약 4 GB → 실습은 $N = 1024$
frame 수가 3001	librosa center=True 는 $1 + L/H$. Whisper 는 마지막을 버려 3000
power_to_db vs amplitude_to_db	파워는 $10 \cdot \log_{10}$, 진폭은 $20 \cdot \log_{10}$. 결과 dB 는 같다
librosa mel 값이 HTK 공식과 다름	librosa 기본은 Slaney 방식 . HTK 와 비교할 때는 htk=True
Whisper mel 수	기본 80. large-v3 계열은 128 mel

frame 수와 **bin** 수는 항상 공식으로 먼저 예측하고 **shape** 로 확인한다 .

오디오 전처리 : 리샘플링 · 정규화 · 노이즈 제거 · VAD

- ☐ 도 - 미 - 솔 화음을 FFT 로 분해했다
- ☐ 직접 만든 `dft()` 가 `np.fft` 와 같음을 확인했다
- ☐ $\Delta f = f_s/N$ 과 Hann 창 의 효과를 실험했다
- ☐ `my_stft()` 로 스펙트로그램을 만들고 frame 수를 예측했다
- ☐ Whisper 입력 80×3000 Log-Mel 을 만들었다
- ☐ MFCC 가 음 높이보다 모음을 담는 것을 확인했다

다음 : Day 4

오늘 만든 스펙트로그램으로
잡음은 어디에 있고, 말소리는 언제 시작할까?

리샘플링 · 정규화 · 노이즈 제거 · Silero VAD

[worksheet.html](#)

40 문항

개념 워크시트 · 노션 제출

[animation.html](#)

9 개 탭

인터랙티브 애니메이션

[D3_실습.ipynb](#)

빈칸 7

실습 노트북

온라인 자료 imguru-mooc.github.io/AI_Voice/day03