음성 AI 전문가 과정 · Day 4 / 40

Day 04

오디오 전처리
정규화 · 노이즈 제거 · VAD

SNR → 정규화 · 필터 → 스펙트럼 차감 · Wiener → spectral gating → 에너지 VAD → Silero VAD
4 시간 · Colab CPU · 실습 노트북 Part 1 ~ 6

```
>>> R = preprocess("noisy_pink.wav")

구간 4개, 음성 비율 84%
  0.85 ~  5.91초  RMS -25.7 dBFS
  6.03 ~  8.66초  RMS -22.6 dBFS
  ...

>>> R.keys()
audio · segments · timestamps
speech_ratio
```

출력 예시 (값은 녹음마다 다름)

0.0 · 오늘 답할 질문

시끄러운 녹음을 모델이 좋아하는 음성으로 바꾸려면

1	얼마나 시끄러운지 숫자로 어떻게 말할까 ? 원하는 SNR 로 어떻게 섞을까 ?	Part 1
2	크기는 peak 로 맞출까 RMS 로 맞출까 ? 저음 험은 어떻게 지울까 ?	Part 2
3	잡음 스펙트럼을 빼면 왜 " 삐릭삐릭 " 소리가 남을까 ?	Part 3
4	noisereduce 는 무엇을 문턱으로 쓰고 , ASR 앞에서는 왜 조심할까 ?	Part 4
5	말소리 구간은 어떻게 찾고 , 잡음이 커져도 버티는 방법은 ?	Part 5 · 6

수업이 끝나면 다섯 질문 모두에 수식 하나와 한 문장으로 답할 수 있어야 한다 .

0.0 · 오늘의 흐름

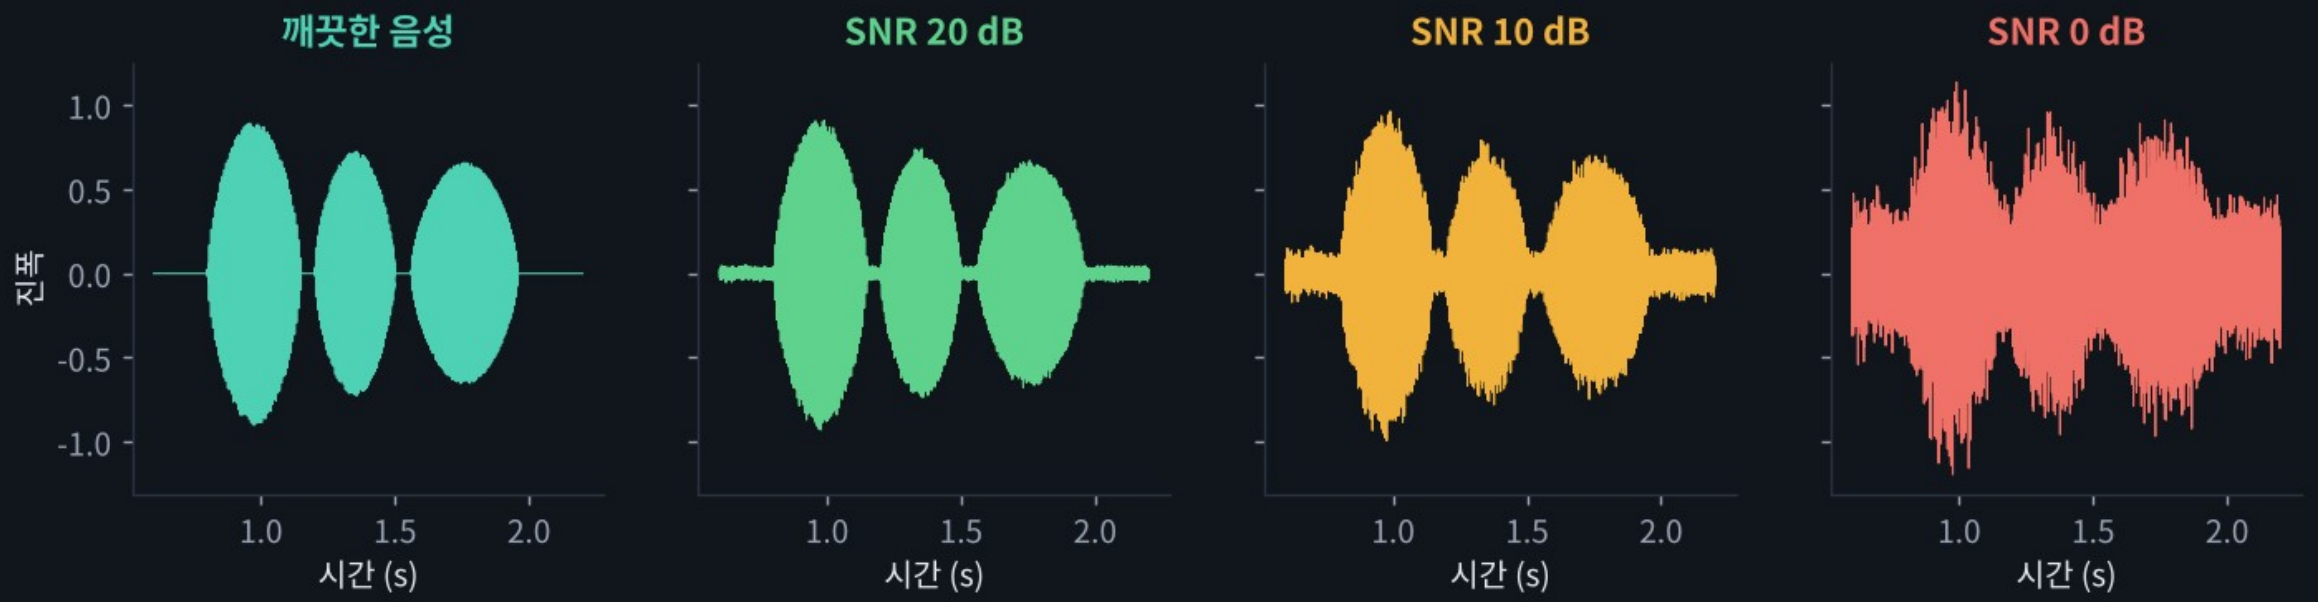
잡음과 SNR 에서 Silero VAD 파이프라인까지

Part 1 잡음 · SNR › **Part 2** 정규화 · 필터 › **Part 3** 차감 · Wiener › **Part 4** spectral gating › **Part 5** 에너지 VAD › **Part 6** Silero · 파이프라인

교시	내용	실습
1 교시	잡음과 SNR, dBFS, peak · RMS 정규화 , DC, pre-emphasis, high-pass	Part 1 ~ 2 · 빈칸 1 ~ 3 · 워크시트 1 교시
2 교시	스펙트럼 차감 , Wiener 이득 , spectral gating(noisereduce)	Part 3 ~ 4 · 빈칸 4 ~ 6 · 워크시트 2 교시
3 교시	VAD 원리 : 프레임 에너지 , ZCR, 두 문턱 , hangover	Part 5 · 빈칸 7 · 워크시트 3 교시
4 교시	Silero VAD, 전처리 파이프라인 preprocess()	Part 6 ~ 7 · 빈칸 8 ~ 9 · 워크시트 4 교시 · 노션 제출

▶ **애니메이션** D4-1 오늘의 흐름 (Part 1~6)

SNR = 10·log₁₀(Ps / Pn): 얼마나 시끄러운가



$P = (1/L)\cdot\Sigma\, x[n]^2$

$SNR(dB) = 10\cdot\log_{10}(Ps/Pn) = 20\cdot\log_{10}(RMSs/RMSn)$

20 dB = 파워 100 배 = 진폭 10 배 · 0 dB = 같음

잡음 세 가지

white(모든 주파수) · pink(1/f, 팬 · 바람) · hum(60 Hz 전원 + 배음)

▶ **애니메이션** D4-2 잡음과 SNR (슬라이더 · 소리)

g = √(Ps / (Pn·10^(SNR/10)))

단계	식
섞기	x = s + g·n
잡음 파워	P(g·n) = g²·Pn
SNR 대입	SNR = 10·log₁₀(Ps / (g²·Pn))
로그 풀기	10^(SNR/10) = Ps / (g²·Pn)
g 정리	g = √(Ps / (Pn·10^(SNR/10)))

SNR (dB)	파워 비 Ps / Pn	진폭 비 (RMS)
+30 dB	1000배	31.6배
+20 dB	100배	10배
+10 dB	10배	3.16배
0 dB	1배 (같음)	1배
-10 dB	0.1배	0.32배

🧩 **빈칸 실습 1** `g = np.sqrt(power(s) / (power(n) * 10 ** (____ / 10)))` 정답 : snr_db

```
목표 20 dB → 측정  20.00 dB
목표 10 dB → 측정  10.00 dB      목표 0 dB → 측정 0.00 dB
```

▶ **애니메이션** D4-2 g 유도 단계 (다음 단계 ▶)

peak 는 한 점을 , RMS 는 체감 크기를 맞춘다

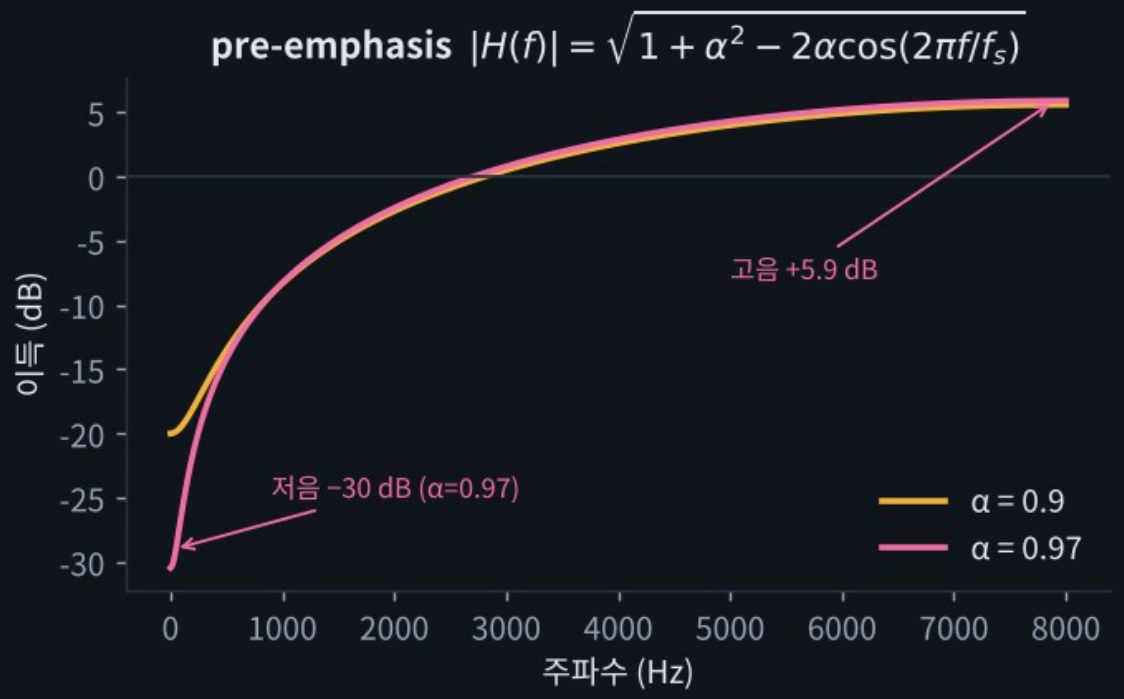


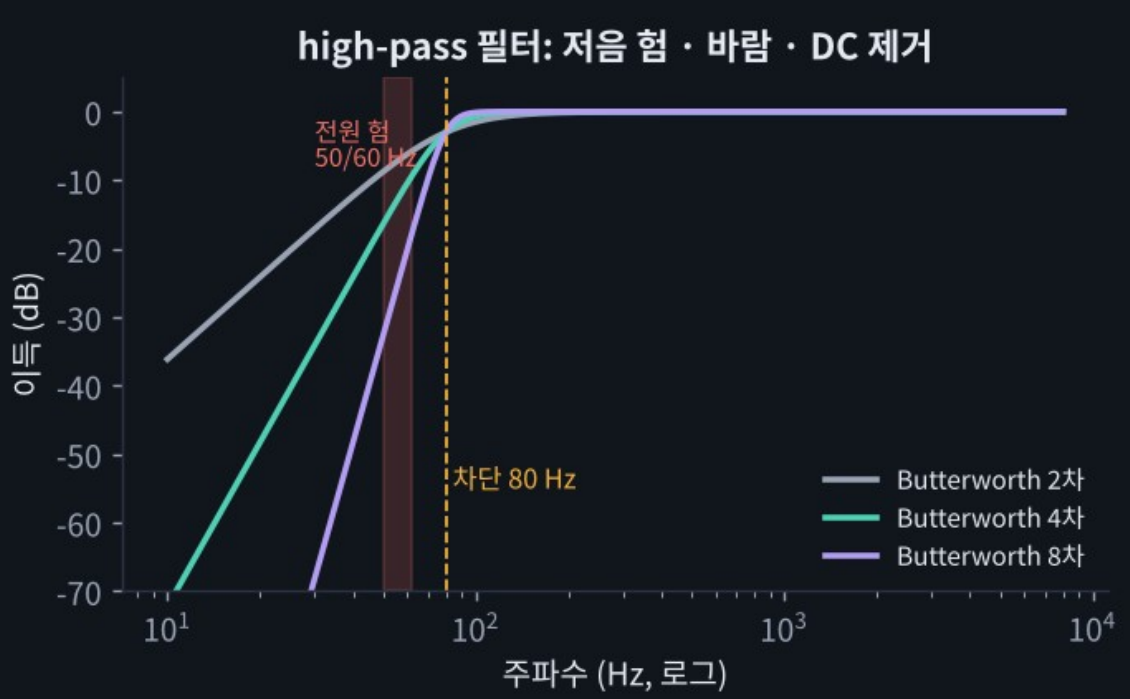
방법	식	약점
peak	x · 0.9 / max|x|	클릭 하나가 전체 크기 결정
RMS	x · 10^((T − RMSdB)/20)	결과가 1 을 넘으면 클리핑 → 0.99 제한
DC 제거	x − mean(x)	—

🧩 **빈칸 2** `10 ** (Δ / ____)` 정답 : 20

▶ **애니메이션** D4-3 정규화 (클리핑 · DC)

$y[n] = x[n] - \alpha \cdot x[n-1] \rightarrow |H|^2 = 1 + \alpha^2 - 2\alpha \cdot \cos \omega$



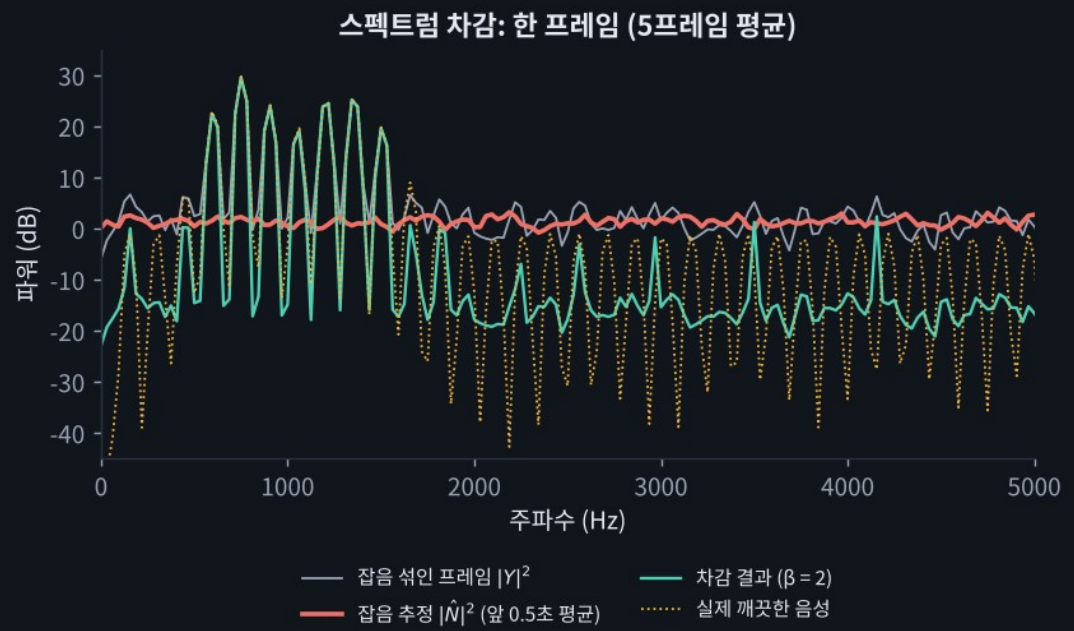


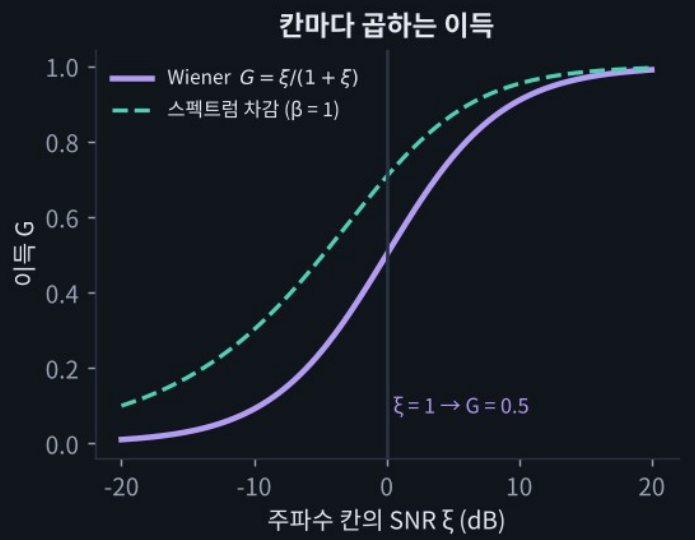

```
H(ω) = 1 − α·e^(−jω)
ω=0: 1−α = 0.03 (−30 dB)   ω=π: 1+α (+5.9 dB)
```

🧩 **빈칸 3** `x[1:] - ____ * x[:-1]` 정답 : alpha

▶ **애니메이션** D4-4 pre-emphasis · high-pass

$|Y|^2 \approx |S|^2 + |N|^2$: 잡음 파워를 빼자






```
N̂²[k] =
앞 M₀ 프레임
평균 |Y|²

|Ŝ|² = max(
 |Y|² − β·N̂²,
 γ·|Y|² )

Ŝ = |Ŝ|·e^(j∠Y)
→ ISTFT
```

🧩 **빈칸 실습 4** `np.maximum(P - ____ * Nhat, floor * P)` 정답 : beta

▶ **애니메이션** D4-5 스펙트럼 차감 · Wiener

β	SNR 5 dB →
1	8.9 dB
2	11.6 dB
4	13.2 dB

G = ξ / (1 + ξ): 칸마다 음성의 몫만 통과

단계	식
모델	$Y = S + N, \quad E\|Y\|^2 = \|S\|^2 + \|N\|^2$
오차	$E\|S - G \cdot Y\|^2 = (1 - G)^2\|S\|^2 + G^2\|N\|^2$
미분 = 0	$G = \|S\|^2 / (\|S\|^2 + \|N\|^2)$
ξ로	$G = \xi / (1 + \xi), \quad \xi = \|S\|^2/\|N\|^2$
추정	$\hat{\xi} = \max(\|Y\|^2/\hat{N}^2 - 1, 0)$

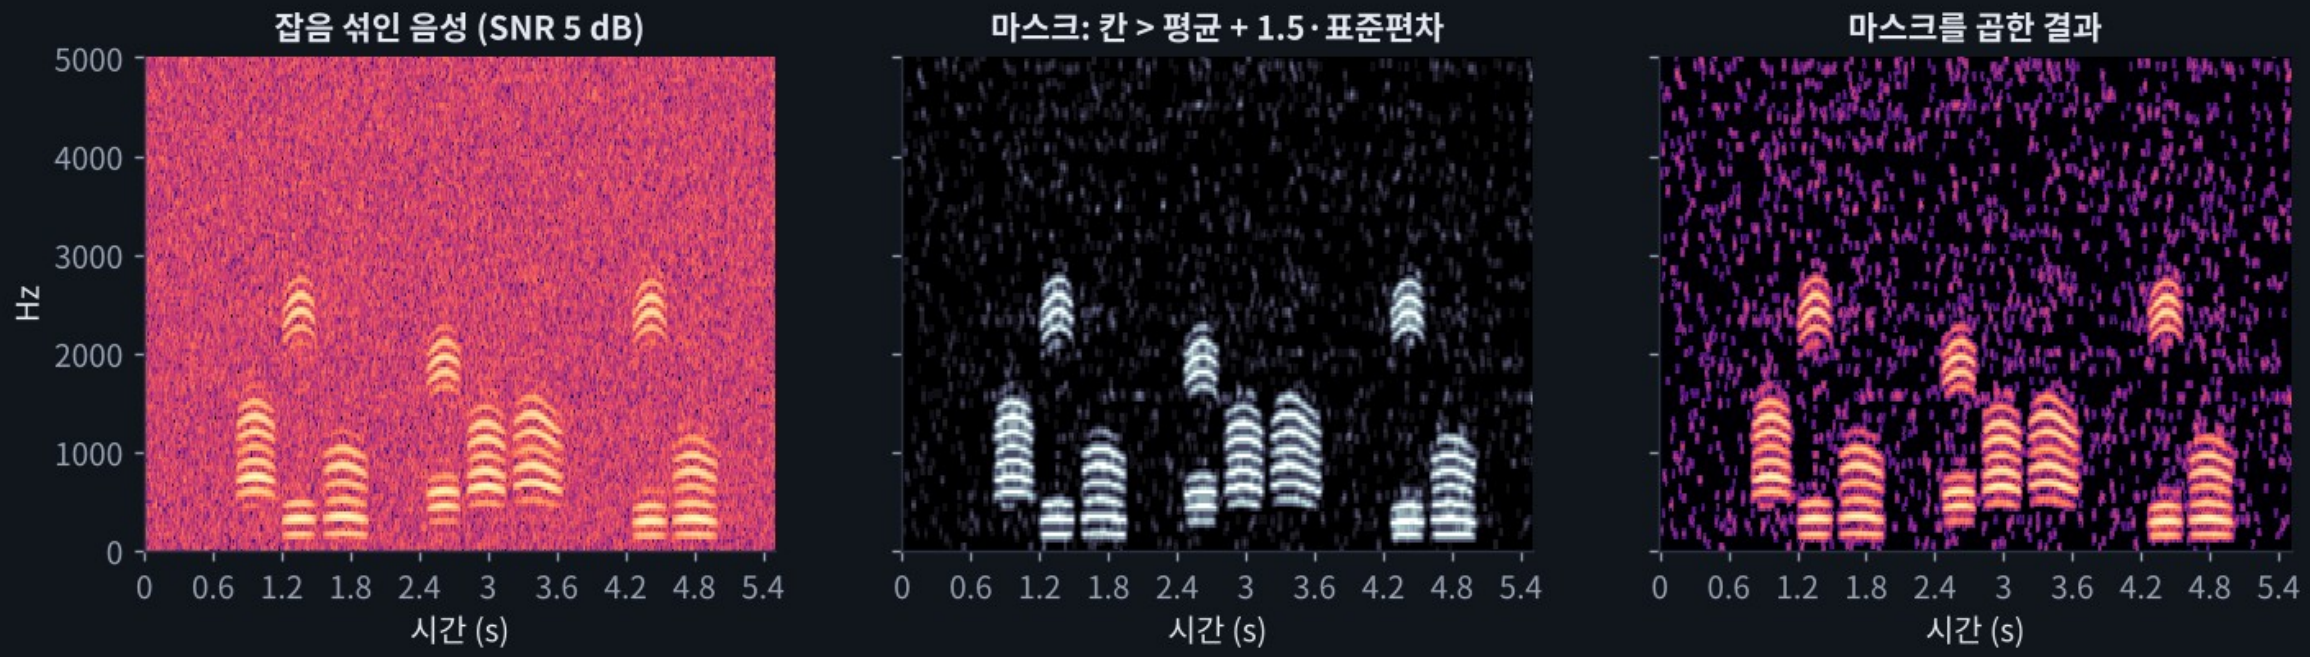
ξ (dB)	G
−10	0.091
0	0.500
+10	0.909
+20	0.990

🧩 **빈칸 실습 5** `G = xi / (____ + xi)` 정답 : 1

잡음 추정 구간	0.1 초	0.5 초	0.8 초	2.0 초 (음성까지 포함)
차감 β=2 결과 SNR	10.9 dB	11.6 dB	11.6 dB	9.9 dB

잡음 추정이 결과를 좌우한다 : 무음 구간만으로 , 충분히 길게 .

문턱 $T_k = \mu_k + 1.5 \cdot \sigma_k$ 로 만든 마스크



옵션	뜻
stationary=True	잡음이 일정하다고 보고 문턱 한 번
y_noise=	잡음만 있는 구간 → 정확한 문턱
prop_decrease=	1.0 완전히 · 0.5 절반만

🧩 **빈칸 6** `noisy[:int(____ * SR)]` 정답 : 0.5

▶ **애니메이션** D4-6 spectral gating

지표 하나로 판단하지 않는다

방법 (white 5 dB 입력)	SNR (파형)	무음 구간 잡음 감소	음성 구간 크기
그대로	5.0 dB	0 dB	0 dB
스펙트럼 차감 β=2	11.6 dB	9.4 dB	−1.1 dB
Wiener	10.7 dB	7.7 dB	−1.0 dB
noisereduce (전체로 문턱)	2.8 dB	34.6 dB	−10.5 dB
noisereduce (y_noise 0.5 초)	5.3 dB	27.7 dB	−6.6 dB

노트북 report() 출력 예 (값은 음성에 따라 다름)

사람이 들을 때

통화, 녹취 정리, TTS 학습 데이터 정제 → 효과 큼

ASR 입력일 때

강한 제거는 왜곡 (뮤지컬 노이즈, 깎인 자음) → 인식률이 떨어지기도. prop_decrease 0.5~0.8

딥러닝 잡음 제거

DeepFilterNet · RNNoise · Demucs: 변하는 잡음 (대화, 키보드) 까지 (선택 실습)

지금 사람이 말하고 있는가 : 에너지와 ZCR

무음 자르기

ASR 계산량 감소 , 무음에서 생기는 환각 방지

턴 감지

실시간 에이전트에서 말이 끝난 순간 → 응답 시작

잡음 견본

무음 구간 = 잡음만 → 잡음 제거 문턱 (Part 3 · 4)

$$E[m] = 20 \cdot \log_{10} \sqrt{\left(\frac{1}{N}\right) \cdot \Sigma\, x_m[n]^2}$$

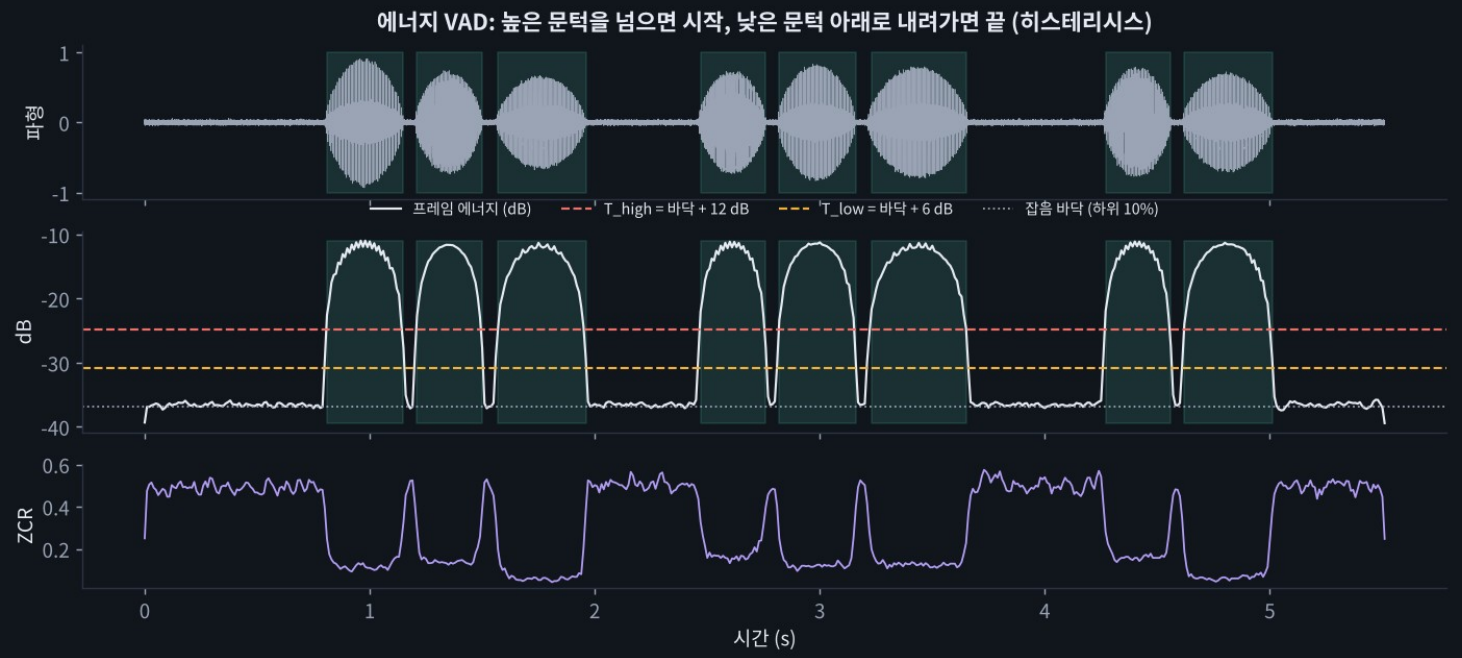
$$ZCR[m] = \left(\frac{1}{2N}\right) \cdot \Sigma\, |\operatorname{sgn} x[n] - \operatorname{sgn} x[n-1]|$$

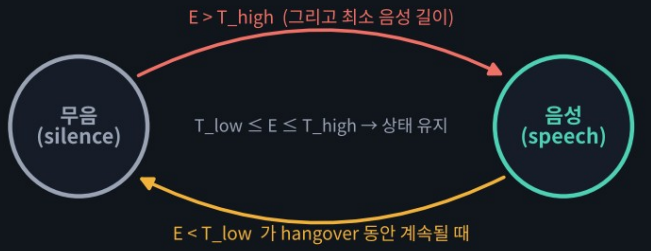
N = 400 (25 ms), hop 160 (10 ms) → 1 초 100 프레임

사인파 f Hz → ZCR ≈ 2f / fs

신호	ZCR (측정)	예측 2f/fs
150 Hz 사인파 (모음 f_0 근처)	0.017	0.019
1000 Hz 사인파	0.124	0.125
백색잡음 · 마찰음	≈ 0.50	—

문턱 두 개 + hangover + 최소 길이





파라미터	값
T_high	바닥 + 12 dB
T_low	바닥 + 6 dB
hangover	0.2 초
최소 음성	0.25 초

🧩 **빈칸 실습 7** `e = ____ * log10(rms)` · `if v < ____` 정답 : 20, T_lo

▶ **애니메이션** D4-7 에너지 • ZCR VAD (마이크)

두 문턱 사이에서는 상태를 유지한다 → 채터링 방지 .

잡음도 에너지가 크다

입력 SNR	검출 구간	깨끗한 음성 기준 일치율
20 dB	6 개	91.2%
10 dB	7 개	82.7%
5 dB	3 개	34.9%
0 dB	0 개	17.0%

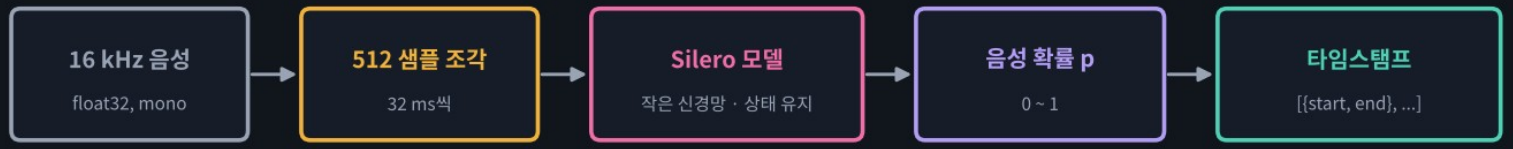
노트북 수식 검증 5 출력 예

왜 무너질까 ?

floor = 하위 10% 에너지
잡음이 크면 floor 가 올라와
T_high = floor + 12 dB 를 음성이 넘지 못함
→ 구간 0 개

에너지는 " 소리가 있다 " 만 안다 . " 말소리다 " 를 알려면 학습된 모델이 필요하다 → Silero VAD

32 ms 마다 음성 확률 , 같은 히스테리시스



threshold 0.5 · neg_threshold = threshold − 0.15 (히스테리시스)

min_speech_duration_ms 250 · min_silence_duration_ms 100 · speech_pad_ms 30

```
from silero_vad import
  load_silero_vad,
  get_speech_timestamps
model = load_silero_vad()
ts = get_speech_timestamps(
  wav, model,
  sampling_rate=16000)
```

파라미터	기본값	뜻
threshold	0.5	음성 시작 확률 θ
neg_threshold	θ − 0.15	음성 끝 확률 (낮은 문턱)
min_speech_duration_ms	250	이보다 짧은 구간 버림
min_silence_duration_ms	100	이만큼 조용해야 끊음 (hangover)
speech_pad_ms	30	앞뒤 여유 (첫 자음 보호)
return_seconds	False	False 면 샘플 번호 → 바로 자르기

▶ **애니메이션** D4-8 Silero VAD 파라미터

잡음이 커져도 확률은 0 과 1 로 갈린다



🧩 **빈칸 실습 8** `CHUNK = ____  # 32 ms` 정답 : 512

```
VAD_MODEL.reset_states()
p = VAD_MODEL(wav[i:i+512], 16000).item()
```

입력 SNR	Silero	에너지 VAD
10 dB	97.3%	83.2%
5 dB	95.2%	35.3%
0 dB	93.8%	17.5%

preprocess(): 정리된 구간들을 돌려주는 전처리기

1 형식 (16 kHz mono) › 2 DC · HPF (80 Hz) › 3 VAD (Silero) › 4 잡음 제거 (y_noise = 무음) › 5 정규화 (RMS −20 dBFS) › 6 자르기 (seg_00.wav ...)

```
ts = get_speech_timestamps(torch.from_numpy(y),
        VAD_MODEL, sampling_rate=SR, speech_pad_ms=50)
noise_mask = np.ones(len(y), bool)
for d in ts:
    noise_mask[d["start"]:d["end"]] = ____
y = nr.reduce_noise(y=y, sr=SR, y_noise=y[noise_mask],
        stationary=True, prop_decrease=0.8)
y = rms_normalize(y, target_db=-20)
```

🧩 빈칸 실습 9

정답 : False
음성 구간을 " 잡음 아님 " 으로 → 남은 무음만 잡음 견본

돌려주는 값

audio · segments · timestamps · speech_ratio

▶ **애니메이션** D4-9 전처리 파이프라인 (단계 켜고 끄기)

D2 make_model_ready → D4 preprocess → D3 extract_features → 모델 (D6~ Whisper)

오늘의 원리를 열두 줄로

원리	수식	확인
SNR	$10 \cdot \log_{10}(P_s/P_n)$, $P = \text{mean}(x^2)$	측정 SNR = 목표
SNR 섞기	$g = \sqrt{P_s / (P_n \cdot 10^{(SNR/10)})}$	빈칸 1
dBFS	$20 \cdot \log_{10} \max\|x\|$, $20 \cdot \log_{10}$ RMS	1.0 = 0 dBFS
RMS 정규화	$g = 10^{((T - RMSdB)/20)}$, peak ≤ 0.99	빈칸 2
pre-emphasis	$x[n] - \alpha x[n-1]$, $\|H\|^2 = 1 + \alpha^2 - 2\alpha \cdot \cos\omega$	−30 / +5.9 dB
스펙트럼 차감	$\max(\|Y\|^2 - \beta \cdot \hat{N}^2, \gamma \cdot \|Y\|^2)$, 위상 $\angle Y$	빈칸 4
Wiener	$\xi = \|Y\|^2/\hat{N}^2 - 1$, $G = \xi/(1+\xi)$	빈칸 5
gating	$T_k = \mu_k + 1.5 \cdot \sigma_k$ (dB)	빈칸 6
에너지 · ZCR	$20 \cdot \log_{10}$ RMS, ZCR ≈ 2f/fs	수식 검증 5
히스테리시스	floor + 12 / floor + 6 dB, hangover 0.2 s	빈칸 7
Silero	512 샘플 = 32 ms, p > 0.5 시작 , < 0.35 끝	빈칸 8
preprocess	DC·HPF → VAD → 잡음 제거 → 정규화 → 자르기	빈칸 9

오늘 헷갈리기 쉬운 것

헷갈리는 점	설명
10·log10 vs 20·log10	파워 (SNR, |Y|²) 는 10, 진폭 (RMS, peak, dBFS) 은 20. 같은 비율이면 같은 dB
SNR 이 생각보다 낮다	SNR 은 전체 평균 파워 기준 . 앞뒤 무음이 길면 Ps 가 작아져 SNR 이 낮게 나옴
RMS 가 목표보다 낮다	peak 0.99 제한 (클리핑 방지) 이 전체를 다시 낮춘 것 . peak_limit 를 끄면 정확히 목표
librosa preemphasis 첫 샘플	librosa 는 첫 샘플을 다르게 처리 (zi). 두 번째 샘플부터 같음
잡음 제거 후 SNR 하락	음성까지 깎이면 파형 SNR 은 떨어짐 . 무음 잡음 감소 · 음성 크기 · 귀로 함께 판단
Silero 모델 다운로드	pip 패키지 안에 모델 포함 . 인터넷 없이 load_silero_vad()
VAD 결과 단위	return_seconds=True 면 초 , 기본은 샘플 번호

dB 를 볼 때마다 " 파워인가 , 진폭인가 " 를 먼저 묻는다 .

오늘 만든 것과 다음 단계

- ☐ 원하는 SNR 로 잡음을 섞고 측정 SNR 로 확인했다
- ☐ RMS 정규화와 클리핑 제한 , DC 제거를 구현했다
- ☐ pre-emphasis 응답을 예측하고 측정값과 비교했다
- ☐ 스펙트럼 차감 · Wiener · noisereduce 를 세 지표로 비교했다
- ☐ 히스테리시스 에너지 VAD 를 만들고 잡음에서 무너지는 것을 봤다
- ☐ Silero VAD 와 preprocess() 로 구간을 잘라 저장했다

다음 : Day 5 이후

오늘 만든 preprocess()(정리) → D3 extract_features()(특징) 흐름을 데이터 준비와 Whisper(D6~) 입력에서 계속 씁니다 .

과제 1 의 녹음 파일을 가져오세요 .

worksheet.html	40 문항
개념 워크시트 · 노션 제출	

animation.html	9 개 탭
인터랙티브 애니메이션	

D4_ 오디오전처리 _ 실습 .ipynb	빈칸 9
실습 노트북	

온라인 자료 imguru-mooc.github.io/AI_Voice/day04