음성 AI 전문가 과정 · Day 7 / 40

Day 07

Whisper 심층 분석
구조 · 크기 · 언어 · 디코딩 · 환각

30 초 창과 특수 토큰 → 모델 크기별 속도 · 정확도 → 언어 감지 · 번역 → greedy · beam · temperature · 타임스탬프 · 프롬프트 → 환각 만들기와 막기
2 주차 M2 · 4 시간 · Colab T4 권장 · 실습 노트북 Part 1 ~ 5

```
[ 안전장치 없음 ]
안녕하세요 .  오늘은 위스퍼를 알아보겠습니다 .
시청해 주셔서 감사합니다 .
네 .  네 .  네 .  네 .  네 .  네 .  네 .  네 .  네 .

[VAD + 안전장치 ]
안녕하세요 .  오늘은 위스퍼를 알아보겠습니다 .
네 ,  그렇게 진행하겠습니다 .
```

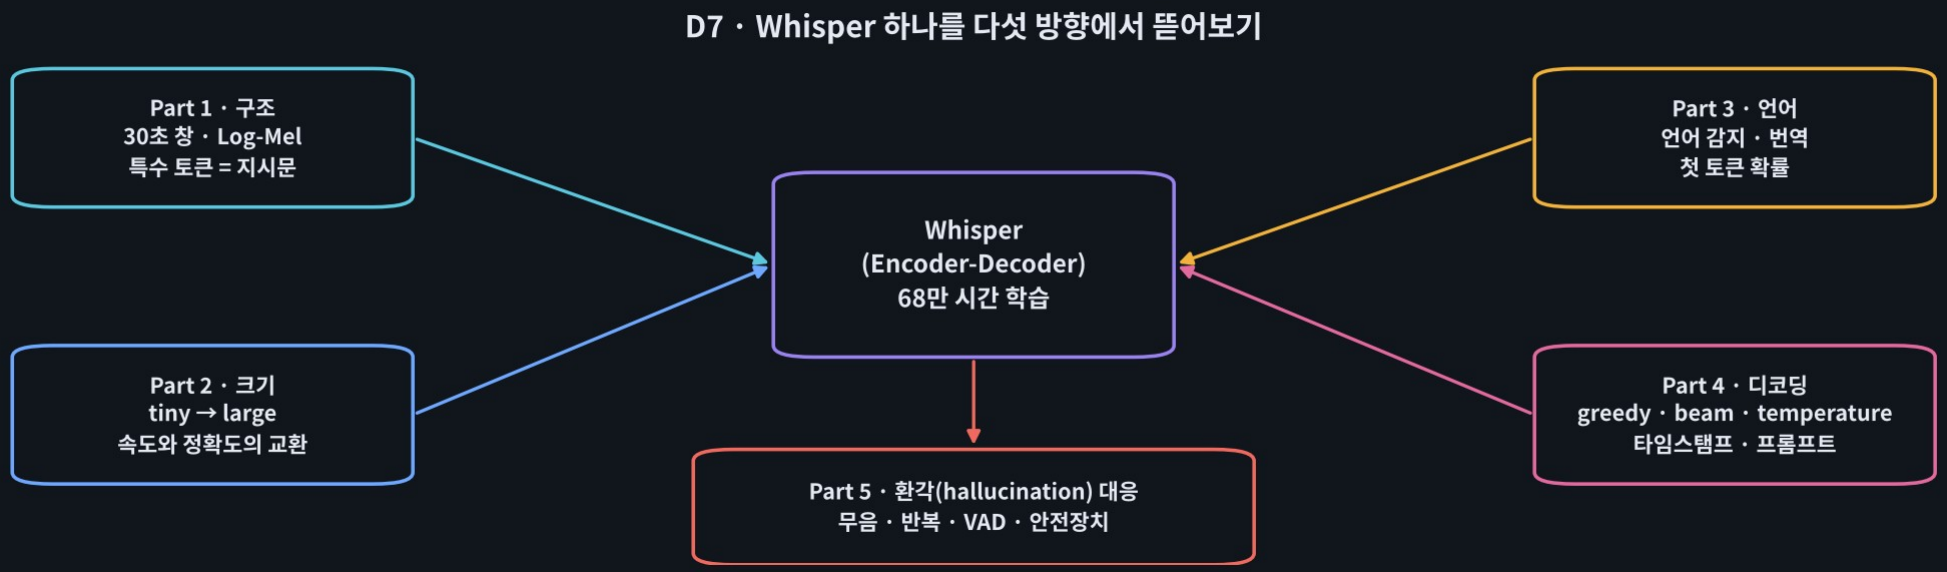
출력 예시 · 오늘 4 교시에 직접 만들고 막아 봅니다

0.0 · 오늘 답할 질문

Whisper 를 " 잘 쓰는 " 사람이 되기 위한 다섯 질문

1	3 초를 넣어도 30 초만큼 일하는 이유는 ? 특수 토큰은 무슨 일을 하나 ?	Part 1
2	tiny 와 large, turbo 중 무엇을 고를까 ? RTF 와 CER 로 어떻게 비교하나 ?	Part 2
3	Whisper 는 언어를 어떻게 알아내고 , 언제 언어를 고정해야 하나 ?	Part 3
4	beam · temperature · 타임스탬프 · 프롬프트는 결과를 어떻게 바꾸나 ?	Part 4
5	무음에서 " 시청해 주셔서 감사합니다 " 가 나오는 이유와 막는 방법은 ?	Part 5

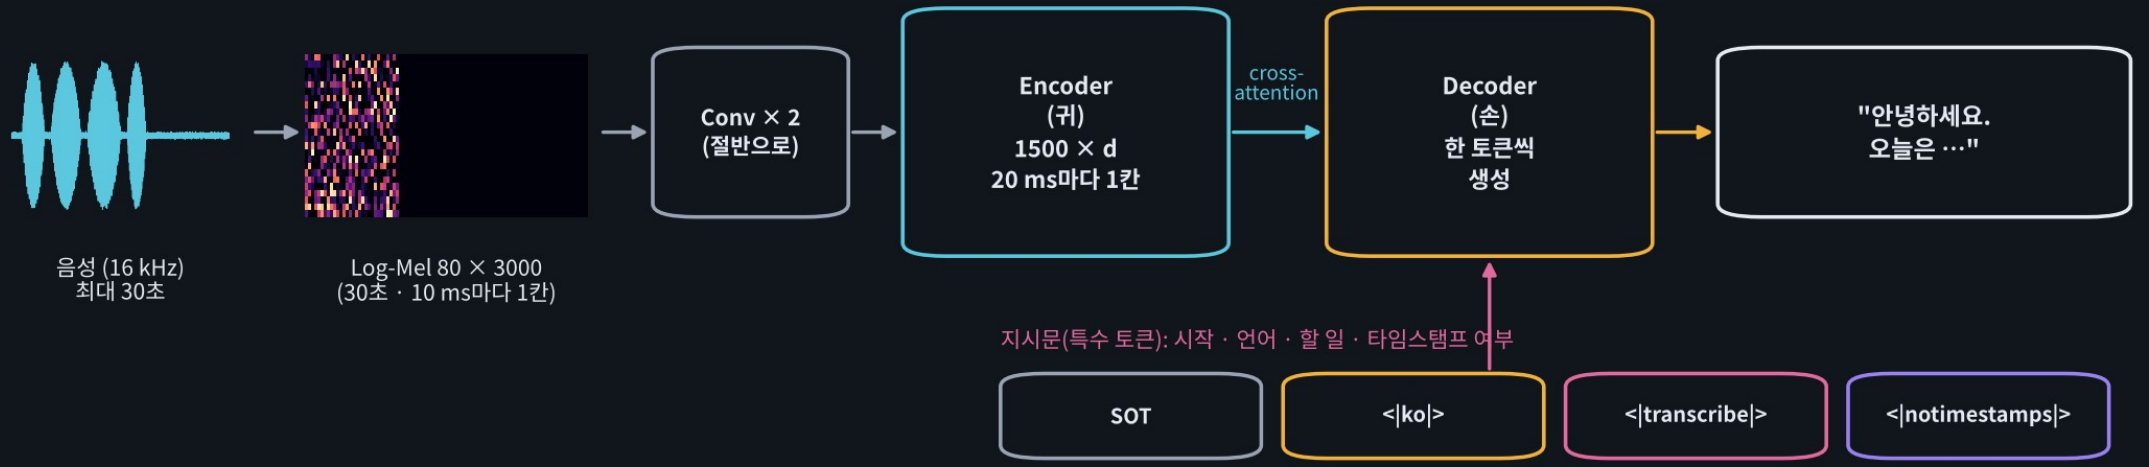
Whisper 하나를 다섯 방향에서



교시	내용	실습
1 교시	구조 : 30 초 창 · Log-Mel · Encoder(귀) · Decoder(손) · 특수 토큰	Part 0 ~ 1 · 빈칸 1 ~ 2
2 교시	모델 크기 (RTF · CER), 언어 감지 , 번역	Part 2 ~ 3 · 빈칸 3 ~ 5
3 교시	greedy vs beam, temperature, 타임스탬프 , 프롬프트	Part 4 · 빈칸 6 ~ 7
4 교시	환각 : 무음 확률 · 압축률 · fallback · VAD	Part 5 ~ 6 · 빈칸 8 ~ 9 · 노션

귀 (Encoder) 가 30 초를 한 번 듣고 , 손 (Decoder) 이 한 토큰씩 적는다

Whisper 한 장 요약: 귀(Encoder)가 30초를 한 번 듣고, 손(Decoder)이 지시문을 보며 한 토큰씩 받아 적는다



🍎 통역 부스의 두 사람

귀 담당은 30 초 녹음을 한 번 듣고 20 ms 마다 메모 (1500 줄) 를 남김 . 손 담당은 메모를 보며 한 글자씩 받아 적음 . 맨 앞엔 " 한국어로 · 받아 적어 " 주문서 .

특별한 것은 데이터

인터넷 " 음성 + 자막 " 68 만 시간 (약한 지도 학습) → 99 개 언어 . 대신 자막 습관 (환각) 도 배움

짧으면 0 으로 채우고 , 길면 30 초씩 자른다



단계	모양
파형	`480,000` 샘플
Log-Mel	`80 × 3000`
Conv × 2	보폭 `2 → 1500`
Encoder	`1500 × d (20 ms)`

💬 **쉽게 말하면** 3 초를 넣어도 30 초만큼 일하고 , 1 분을 그냥 넣으면 뒤 30 초는 잘린다 .

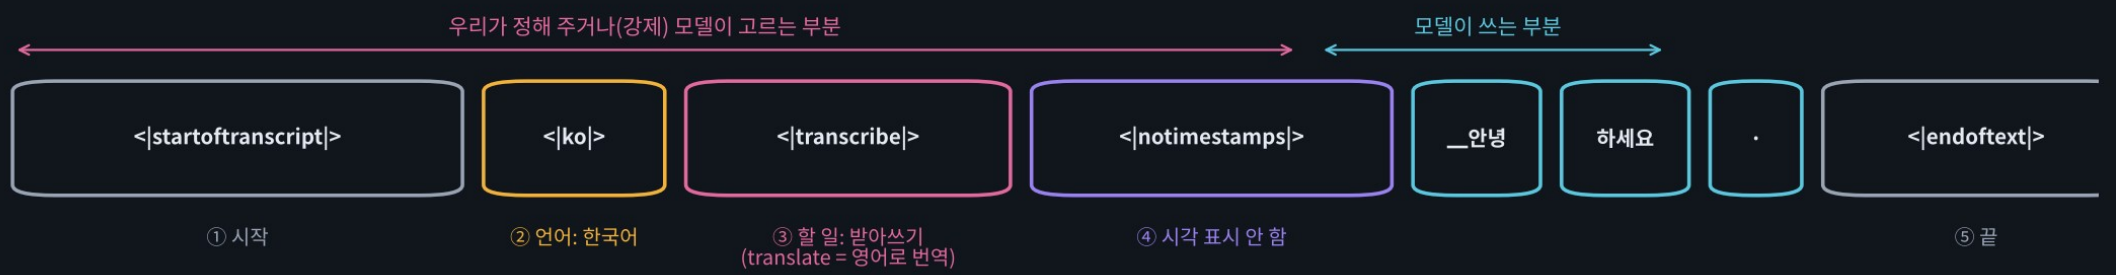
🧩 **빈칸 실습 1**

CHUNK_SEC = ____ 정답 : 30

▶ 애니메이션 D7-2 30초 창 (길이 슬라이더)

긴 음성 → truncation=False (5-4)

Decoder 맨 앞 4 칸 = 주문서



칸	토큰	바꾸면
②	<|ko|> <|en|> … (99 개)	비우면 모델이 언어를 고름 (Part 3)
③	<|transcribe|> / <|translate|>	translate → 영어로 번역
④	<|notimestamps|>	빼면 시각 토큰이 끼워짐 (Part 4)

🍎 식당 주문서

맨 위에 " 포장 · 매운맛 · 수저 빼고 ". 요리사 (Decoder) 는 지시를 보고 같은 재료로 다른 요리를 낸다 .

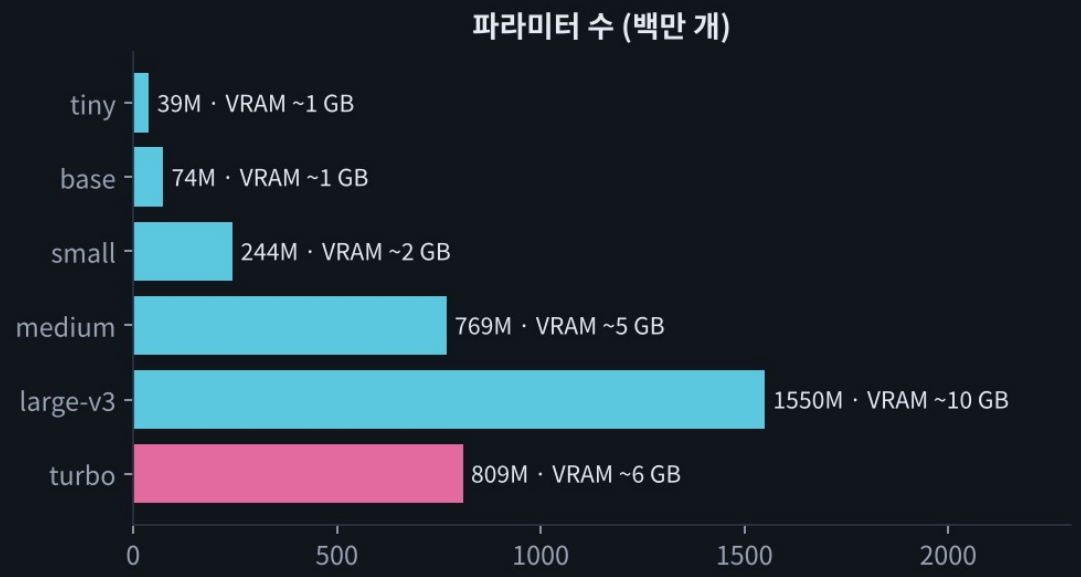
🧩 빈칸 실습 2

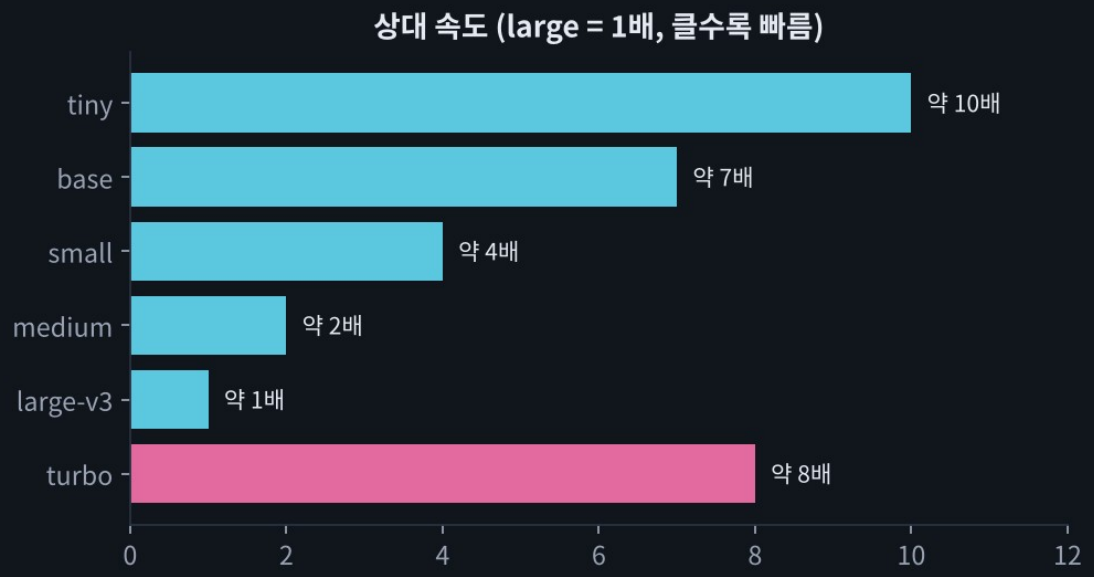
정답 : "<|ko|>"

▶ 애니메이션 D7-3 특수 토큰 주문서

작으면 빠르고 , 크면 정확하다

모델 크기: 작을수록 빠르고, 클수록 정확하다 · turbo = large의 Decoder를 4층으로 줄인 것 (OpenAI 공개 기준 대략값)





🍎 자동차 배기량

경차 (tiny) 는 빠르고 가볍지만 짐이 적고 , 트럭 (large) 은 다 싣지만 느리다 .
turbo = 큰 엔진은 그대로 , 무거운 짐칸 (Decoder) 만 줄인 차 .

상황	먼저 시험할 모델
CPU · 기기 안	tiny / base
Colab T4 입문	small
정확 + 빠르게	turbo (번역 X)
정확도 최우선	large-v3

RTF(얼마나 빠른가) 와 CER(얼마나 틀리나)

지표	쉽게 말하면	좋은 값
RTF	1 초 음성을 받아 적는 데 몇 초 ?	작을수록 . 1 미만 = 실시간보다 빠름
CER	정답을 만들려면 몇 % 의 글자를 고쳐야 ?	작을수록 . 0 = 완벽

1. RTF 가 1 보다 충분히 작은가 ? (실시간 자막의 기본 조건)
2. CER 이 몇 % 인가 ? (회의록이면 5% 이하가 목표)
3. 고유명사 (아이구루 · 라이브킷) 는 ? → 안 고쳐지면 프롬프트 · Fine-tuning
4. 첫 실행은 워밍업으로 버리고 잰다

RTF = 걸린 시간 ÷ 음성 길이

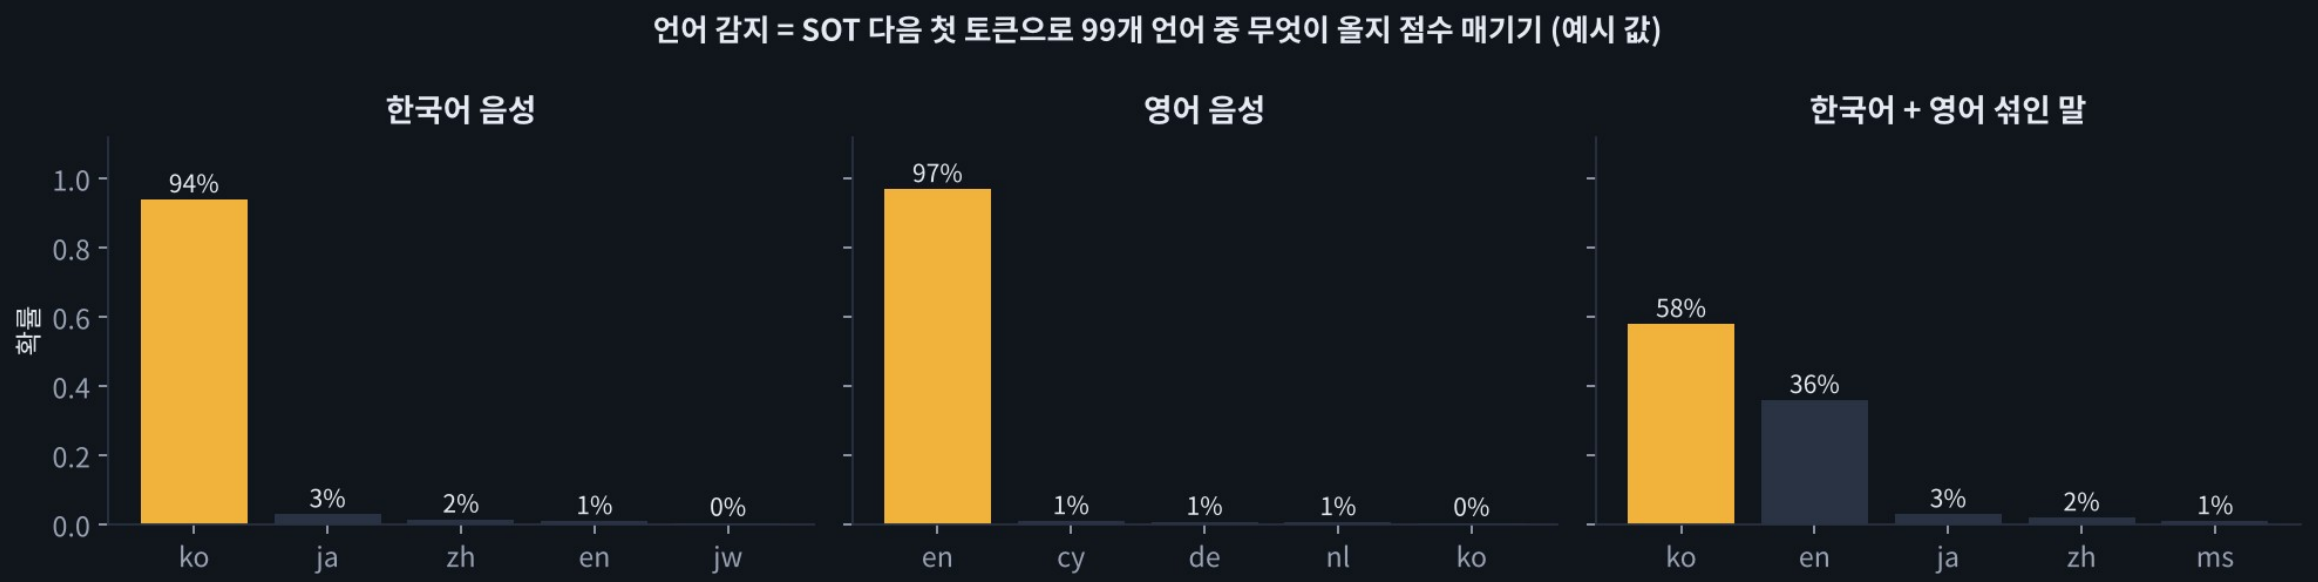
60 초를 15 초에 → 0.25
= 실시간보다 4 배 빠름

🧩 **빈칸 실습 3**

RTF = ____ / dur 정답 : elapsed

▶ 애니메이션 D7-4 모델 고르기 · RTF 계산기

SOT 다음 첫 토큰으로 99 개 언어에 점수 매기기



1. Encoder 로 소리를 듣는다
2. Decoder 에 SOT 하나만 넣고 다음 토큰 점수를 받는다
3. 언어 토큰 99 칸만 골라 softmax → 1 등 언어

🧩 **빈칸 실습 4**

logits[0, -1, ____] 정답 : LANG_IDS

서비스 언어를 알면 언제나 language= 고정

▶ 애니메이션 D7-5 언어 감지 (짧은 말 · 섞인 말)

task="translate": 어떤 언어 음성이든 → 영어 문장

```
transcribe(audio["ko"], language="ko", task="transcribe")
→ 안녕하세요 . 오늘은 음성 인식 모델 위스퍼를 자세히 알아보겠습니다 .

transcribe(audio["ko"], language="ko", task="translate")
→ Hello. Today, we will take a closer look at the speech recognition model
Whisper.
```

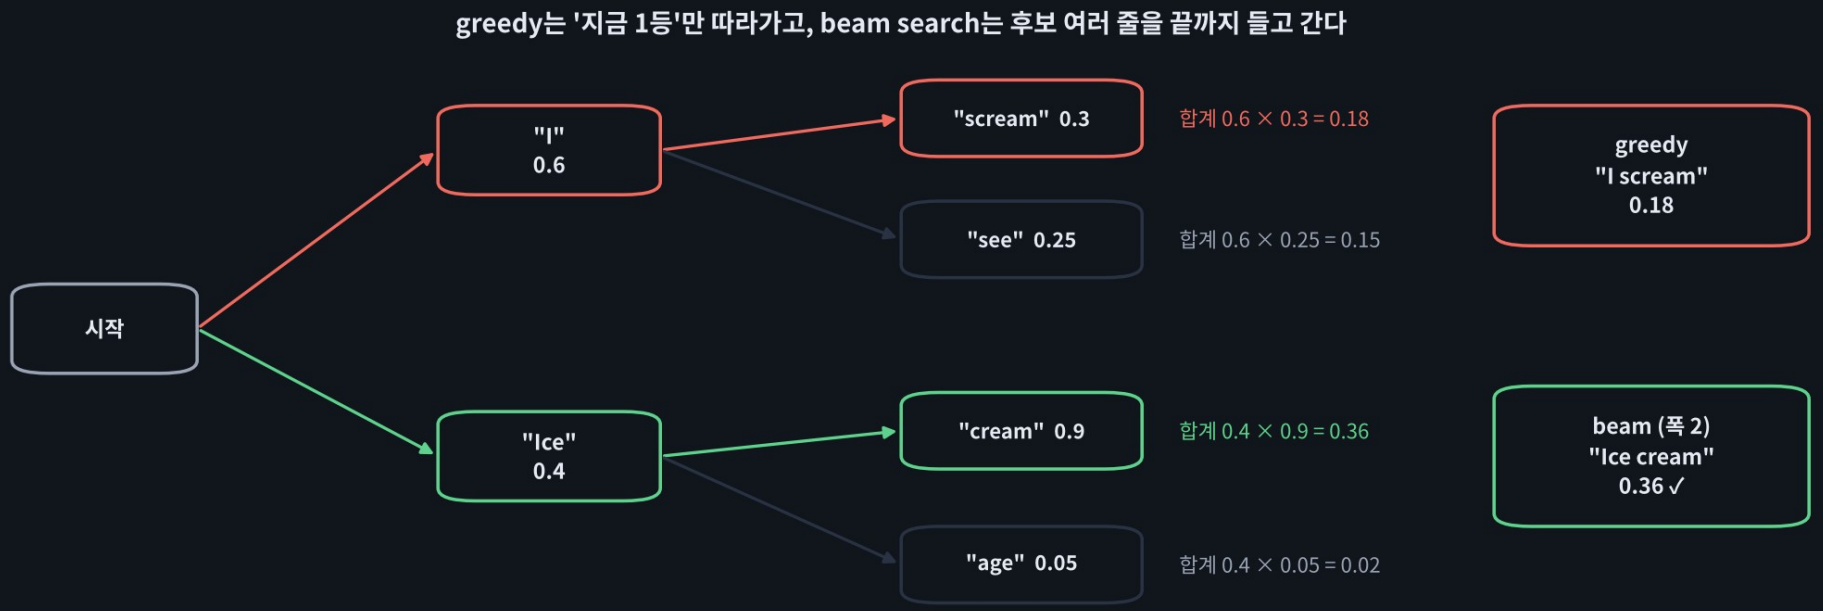
주의	
영어 → 한국어	안 됨
turbo	번역 학습 X
고유명사	받아쓰기서 틀리면 번역도 틀림

🧩 **빈칸 실습 5**

TASK = ____ 정답 : "translate"

💬 **쉽게 말하면** 주문서 ③번 칸만 <|translate|> 로 바꾸면 번역기가 된다 . 단 , 영어로만 .

지금 1등만 따라갈까, 후보 여러 줄을 끝까지 들고 갈까



🍎 길 찾기

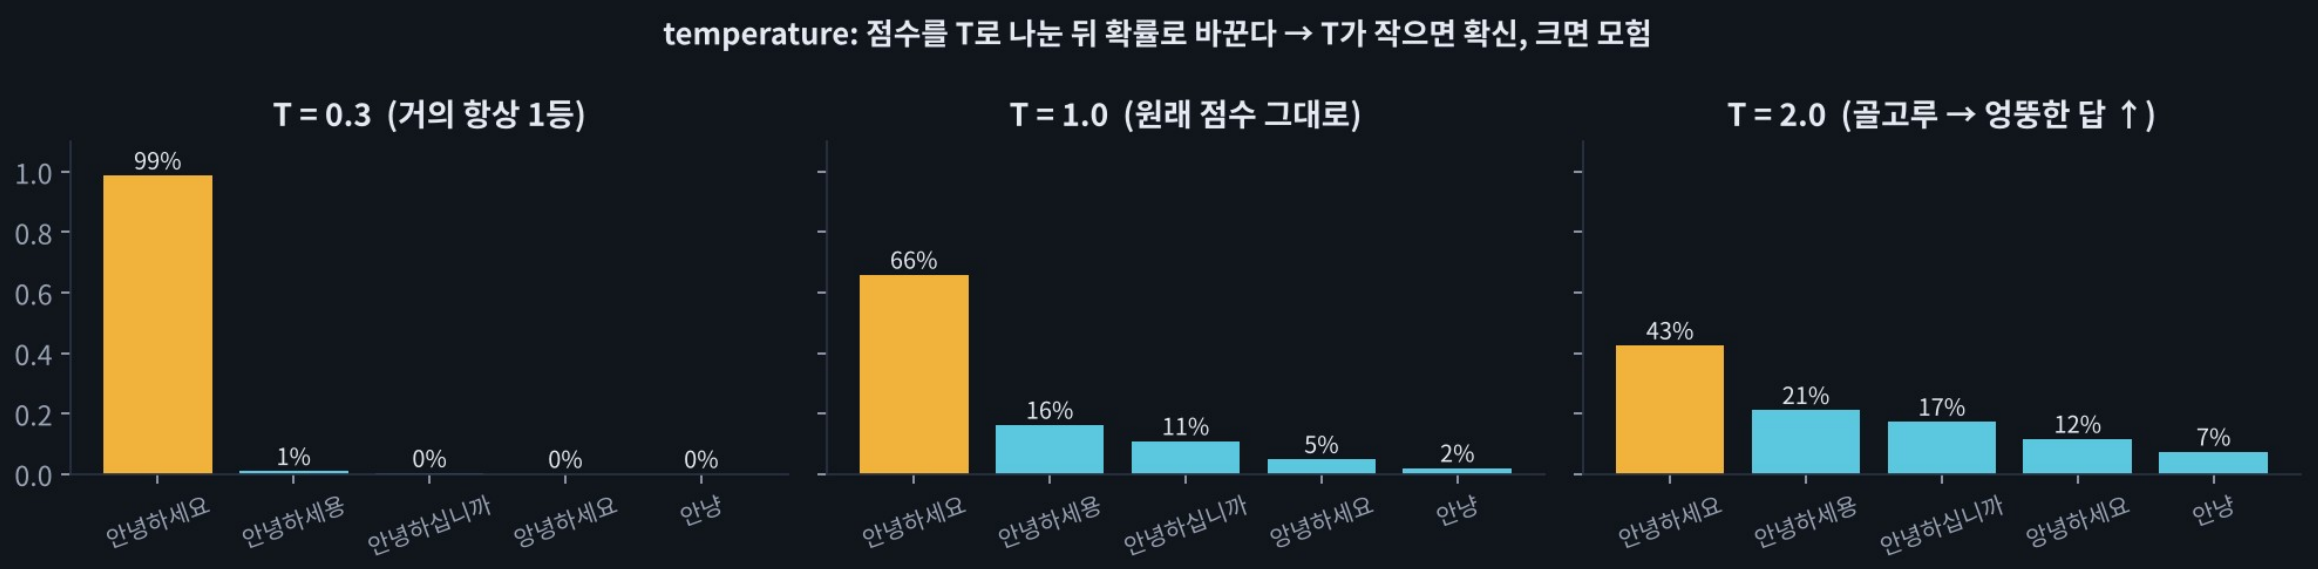
greedy = 갈림길마다 지금 가장 넓은 길로만 가는 운전자 . beam = 정찰병 5 명을 동시에 보내 끝까지 가 본 뒤 가장 좋은 길을 고름 . 정찰병 수만큼 기름 (계산) 이 든다 .

🧩 빈칸 실습 6

NUM_BEAMS = ____ 정답 : 5

▶ 애니메이션 D7-6 빔 서치 (폭 1~4)

점수를 T 로 나눈 뒤 확률로 : T 가 작으면 확신 , 크면 모험




```
p_k = softmax(z_k / T)
T = 0 → 항상 1등 = greedy
```

💬 **쉽게 말하면** T 는 " 얼마나 모험할지 ". 받아쓰기는 0, 막혔을 때만 올린다 .

▶ 애니메이션 D7-7 temperature 슬라이더 · 주사위

시각 토큰으로 " 언제 ", 용어 쪽지로 " 어떻게 쓸지 "

```
<|0.00|> 안녕하세요 . 오늘은 … <|4.86|>
<|5.56|> 아이구루 교육센터에서 … <|10.30|>

시각 토큰 : 0.00 ~ 30.00 초 , 0.02 초 간격 1501 개 · 문장 ( 구간 ) 단위
```

프롬프트	예시 결과
없음	아이 구로 · 라이브 킷
있음	아이구루 · 라이브킷
있음 + 무음	프롬프트를 그대로 베낌 ⚠

1. 힌트 문장을 토큰으로 : <|startofprev|> 아이구루 , 라이브킷 …
2. 그 뒤에 원래 주문서 : <|startoftranscript|> <|ko|> …
3. Decoder 는 힌트를 " 바로 앞 문장 " 으로 여겨 표기를 따라 함

🧩 빈칸 실습 7

get_prompt_ids(____, ...) 정답 : PROMPT

▶ 애니메이션 D7-8 타임스탬프 • 프롬프트

프롬프트는 짧게 , 받아 쓴 문장처럼

소리 단서가 약하면 , 자주 본 자막을 지어낸다

Whisper 환각(hallucination): 소리에 없는 글자를 만들어 낸다 — 네 가지 대표 유형

① 무음 · 잡음

[아무 말 없음]

"시청해 주셔서 감사합니다."

인터넷 자막 끝에 흔한 문장을 언어 모델처럼 '지어냄'

② 반복 고리

[긴 회의 녹음]

"네. 네. 네. 네. 네. 네. 네. …"

앞에서 쓴 글자를 보고 같은 말을 계속 이어 씀

③ 프롬프트 새어 나옴

[무음 + 프롬프트]

"아이구루, LiveKit, Pipecat"

힌트로 준 단어를 소리 없이 그대로 출력

④ 언어 · 작업 혼동

[한국어 음성]

"Hello, today we will learn …"

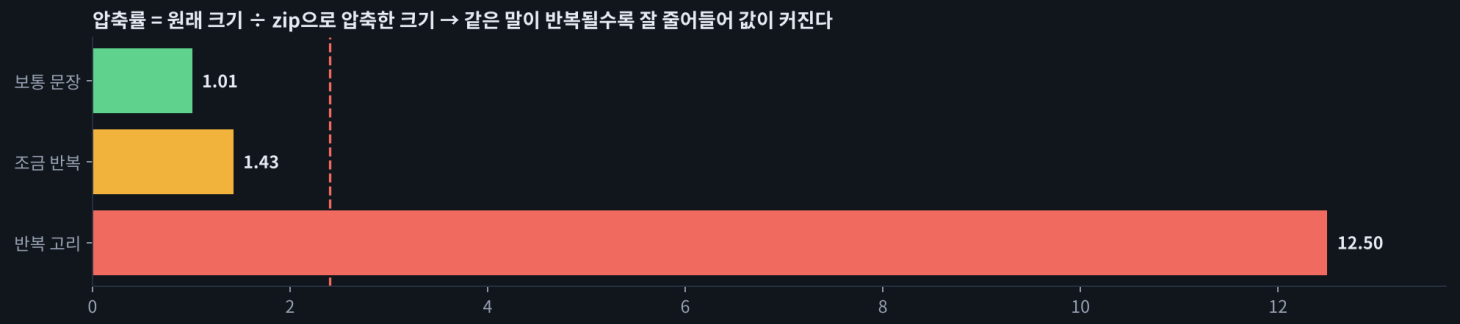
언어 감지 실패 또는 번역해 버림

🍎 빈칸을 못 견디는 학생

들리지 않는 문제를 만나면 빈칸으로 두지 않고 " 평소 자주 나오던 답 " 을 적어 낸다 . 모델도 학습 중 빈칸 제출로 상을 받은 적이 거의 없다 .

유형	대응
① 무음 → 상투 문장	무음 확률 · VAD
② 반복 고리	압축률 · fallback
③ 프롬프트 베끼기	VAD · 짧은 프롬프트
④ 언어 혼동	language= 고정

무음 확률 (쓸 게 있었나 ?) 과 압축률 (같은 말 반복 ?)



P(<|nospeech|>) > 0.6
→ " 말이 없었다 " 의심

압축률 = 원래 바이트
÷ zlib 압축 바이트
→ 2.4 초과면 반복 의심

🍎 쪽지 줄이기

" 네 네 네 … " 40 번 쓴 쪽지는 " 네 × 40" 한 줄로 줄어든다 . 많이 줄어든다 = 같은 내용이 반복된다 .

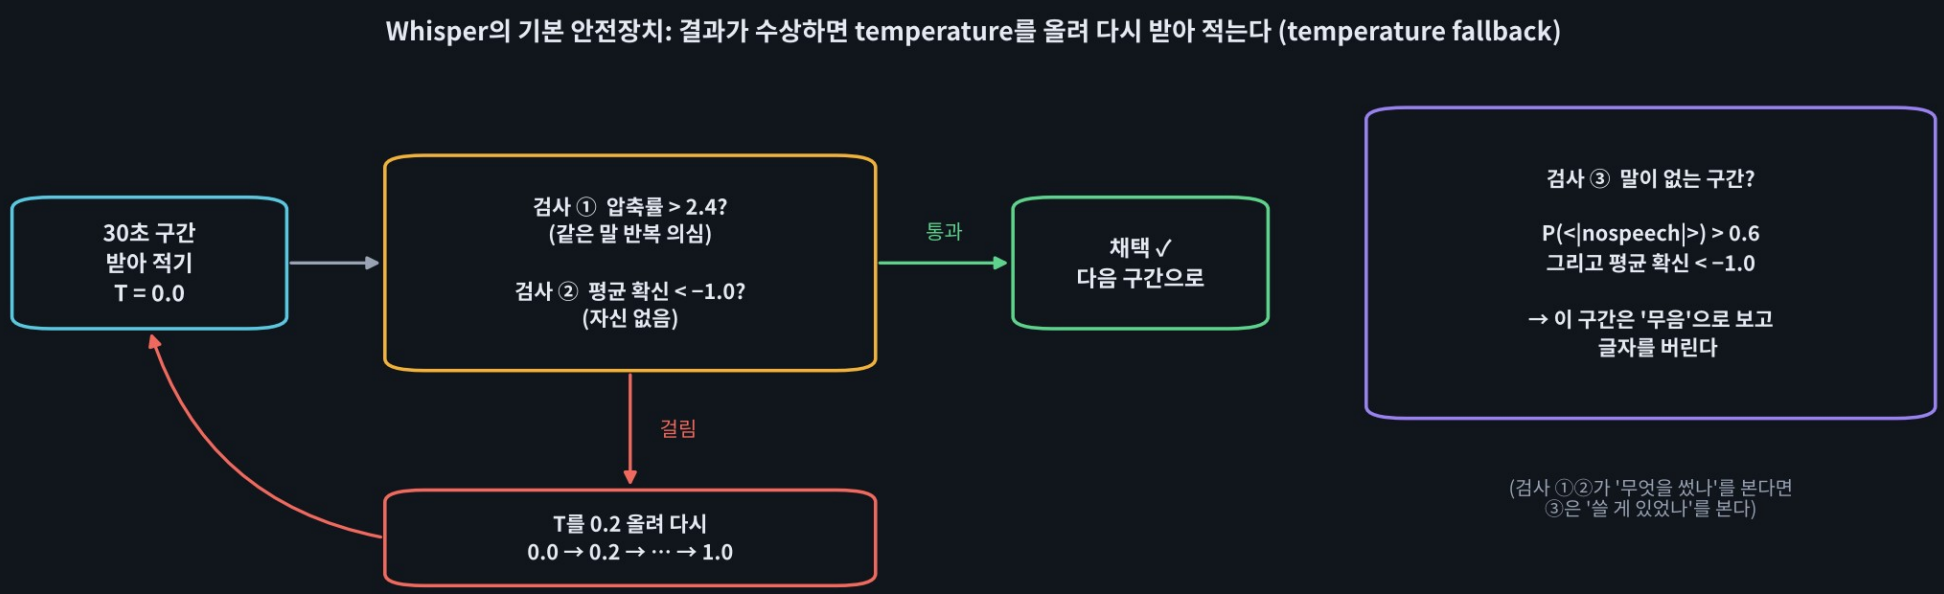
🧩 빈칸 실습 8

probs[___] 정답 : NOSPEECH

🧩 빈칸 실습 9

zlib.___(b) 정답 : compress

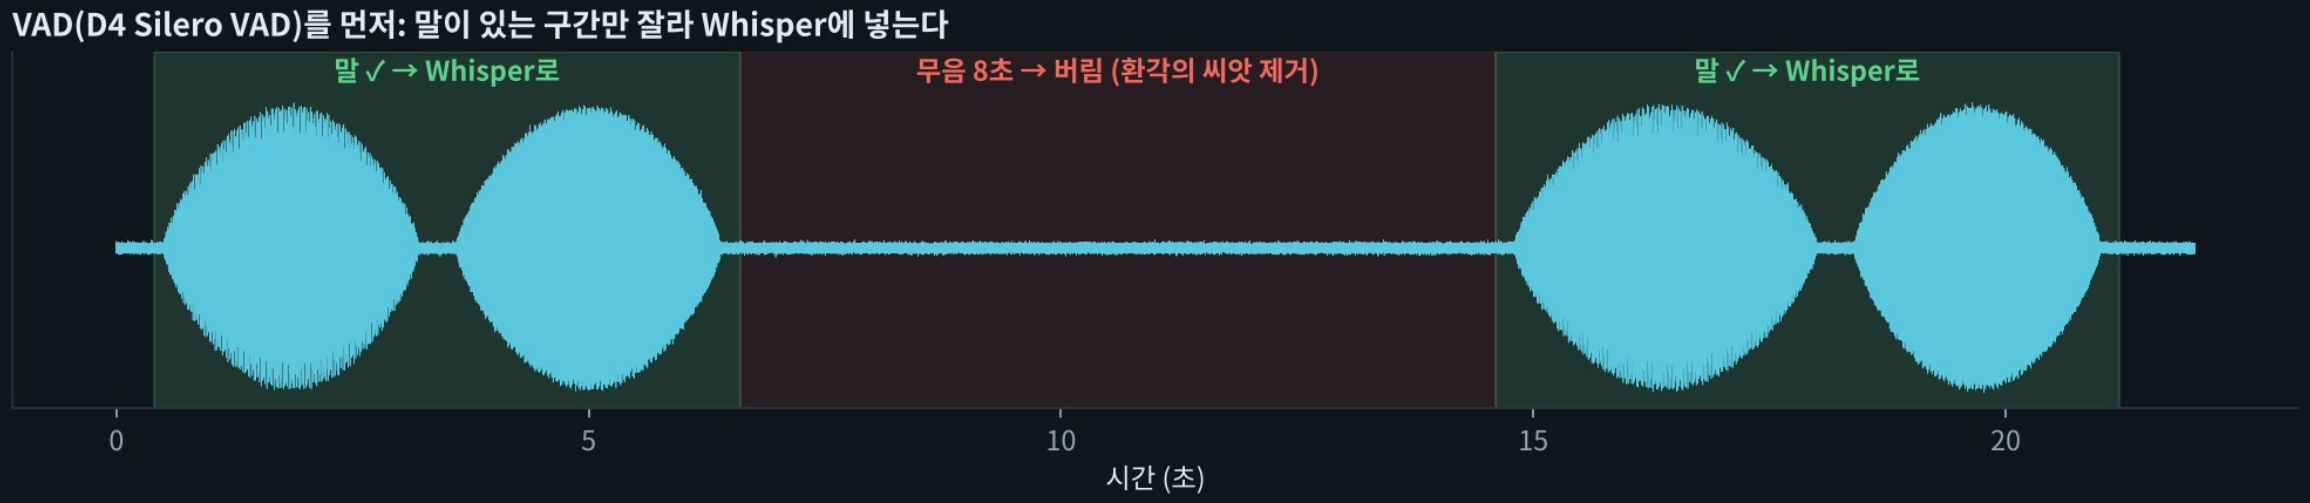
수상하면 온도를 올려 다시 , 말이 없으면 버린다




```
model.generate(**inputs, language="ko", return_timestamps=True,
    temperature=(0.0, 0.2, 0.4, 0.6, 0.8, 1.0),
    compression_ratio_threshold=1.35, logprob_threshold=-1.0,
    no_speech_threshold=0.6, condition_on_prev_tokens=False)
```

값	감각
평균 확신 – 1.0	토큰당 약 37%
압축률 2.4 (원본)	1.35 (transformers)
무음 0.6	+ 확신 낮을 때만

말이 있는 구간만 Whisper 에 넣는다



1. Silero VAD 로 말 구간 (시작 , 끝) 을 찾는다
2. 앞뒤로 0.2 초씩 여유를 두고 자른다
3. 구간마다 받아 적고 이어 붙인다 → 무음은 계산하지 않음

▶ 애니메이션 D7-9 환각 실험실 (안전장치 켜기)

환각 ↓ · 속도 ↑ — 일석이조

서비스에 넣기 전에 확인할 일곱 가지

☐	할 일	막는 환각
☐	서비스 언어를 알면 language= 고정	④ 언어 혼동
☐	VAD 로 말 구간만 넣기 (가장 효과 큼)	① 무음 · ③ 프롬프트 베끼기
☐	긴 음성은 안전장치 세트 (temperature 사다리 · 압축률 · 확신 · 무음)	① · ②
☐	환각이 걱정되면 condition_on_prev_tokens=False	② 반복 전염
☐	프롬프트는 짧게 , 받아 쓴 문장처럼	③
☐	" 시청해 주셔서 감사합니다 " 같은 흔한 환각 문장 목록과 비교해 경고	①
☐	중요한 기록은 사람이 확인 , 원본 녹음 보관	전부

오늘 헷갈리기 쉬운 것

헷갈리는 점	설명
language= 의 뜻	" 들어오는 음성의 언어 ". 번역에서도 출력 언어가 아님 (출력은 항상 영어)
turbo 로 번역 ?	turbo 는 받아쓰기만 다시 학습 . 번역은 small · medium · large-v3
CLI 와 결과가 다름	CLI 기본 beam 5 + fallback, generate() 기본 greedy
타임스탬프 정밀도	문장 단위 , ±0.5 초 . 단어 단위는 D9 WhisperX
압축률 2.4 vs 1.35	원본은 글자 (바이트), transformers 는 토큰 번호를 압축
무음 확률 하나로 버림 ?	아님 . 무음 확률 > 0.6 그리고 평균 확신 < −1.0 일 때
3 초 = 빠르다 ?	아님 . 30 초로 채워 계산하므로 3 초도 30 초만큼 걸림
1 분을 넣으면 ?	기본 설정은 앞 30 초만 남음 . truncation=False 로 long-form

오늘 만든 것과 다음 단계

- ☐ 30 초 창과 Log-Mel · Encoder 모양을 직접 확인했다
- ☐ 주문서 (특수 토큰) 를 직접 써서 generate() 와 같은 결과를 냈다
- ☐ 모델 크기별 RTF · CER 을 재고 상황에 맞는 모델을 골랐다
- ☐ 언어 감지 확률을 계산하고 번역을 실행했다
- ☐ beam · temperature · 타임스탬프 · 프롬프트를 비교했다
- ☐ 환각을 만들고 무음 확률 · 압축률 · VAD 로 막았다

다음 : Day 8 · 추론 최적화 & Streaming

오늘 본 약점 (30 초를 다 계산 , Decoder 반복) 을 빠르게 : faster-whisper(CTranslate2), whisper.cpp, int8 양자화 , 그리고 말하는 도중 자막을 띄우는 청크 기반 스트리밍 . 오늘의 VAD 와 안전장치가 그대로 다시 나옵니다 .

worksheet.html	40 문항
개념 워크시트 · 노션 제출	

animation.html	9 개 탭
인터랙티브 애니메이션	

D7_Whisper 심층분석 _ 실습 .ipynb	빈칸 9
실습 노트북	

온라인 자료 imguru-mooc.github.io/AI_Voice/day07