음성 AI 전문가 과정 · Day 9 / 40

Day 09

Timestamp & 화자 분리
언제 · 무엇을 · 누가 말했나

```
# 회의록 (자동 생성)
[00:00] 김팀장 : 오늘 회의는 음성 비서 프로젝트
        진행 상황을 점검하겠습니다.
[00:05] 이연구원 : 받아쓰기 모델은 위스퍼 스몰로
        정했고 정확도는 충분합니다.
[00:10] 박대리 : 그런데 회의 녹음에서 누가
        말했는지 구분이 안 됩니다.

DER 4.8% · 단어별 화자 정확도 96%
```

출력 모양 예시 · 숫자는 녹음에 따라 달라집니다

Whisper 단어 시각의 한계 → 강제 정렬 (CTC 격자) → WhisperX 단어 시각 · SRT → 화자 분리 직접 만들기 → pyannote · DER → 화자별 회의록
2 주차 M2 · 4 시간 · Colab T4 권장 · 실습 노트북 Part 1 ~ 6

0.0 · 오늘 답할 질문

받아쓰기 글자에 " 언제 " 와 " 누가 " 를 붙이려면

1	Whisper 의 단어 시각은 어떻게 만들어지고 , 왜 어긋나나 ?	Part 1
2	정답 글자를 소리에 맞추는 강제 정렬은 어떻게 하나 ?	Part 2
3	WhisperX 는 무엇을 조립했고 , 단어 시각 · 자막은 어떻게 만드나 ?	Part 3
4	" 같은 목소리끼리 묶기 " 는 어떤 세 단계로 하나 ?	Part 4
5	화자 분리를 어떻게 평가하고 (DER), 단어에 화자를 어떻게 붙이나 ?	Part 5 ~ 6

▶ 애니메이션 D9-1 오늘의 흐름

" 언제 "(1~2 교시) → " 누가 "(3~4 교시) → 회의록

D9 · 회의 녹음에서 '언제 · 무엇을 · 누가' 말했는지 찾기



1~2교시: '언제' (단어 시각) → 3~4교시: '누가' (화자 분리) → D10: 회의록 생성기 미니 프로젝트

교시	내용	실습
1 교시	시각이 필요한 곳 · Whisper 단어 시각의 한계 · 강제 정렬 격자	Part 0 ~ 2 · 빈칸 1 ~ 3
2 교시	WhisperX: 배치 받아쓰기 → wav2vec2 정렬 → 단어 시각 · 점수 · SRT	Part 3 · 빈칸 4 ~ 5
3 교시	화자 분리 직접 : 말 구간 · ECAPA 지문 · 코사인 · 응집형 군집	Part 4 · 빈칸 6 ~ 7
4 교시	pyannote · DER · 단어에 화자 · 이름 붙이기 · 회의록	Part 5 ~ 7 · 빈칸 8 ~ 9 · 노션

글자만으로는 부족하다 : 단어마다 시작 · 끝

자막
글자가 화면에 뜰 때 · 사라질 때

검색
" 예산 " 이 나온 순간으로 바로 이동

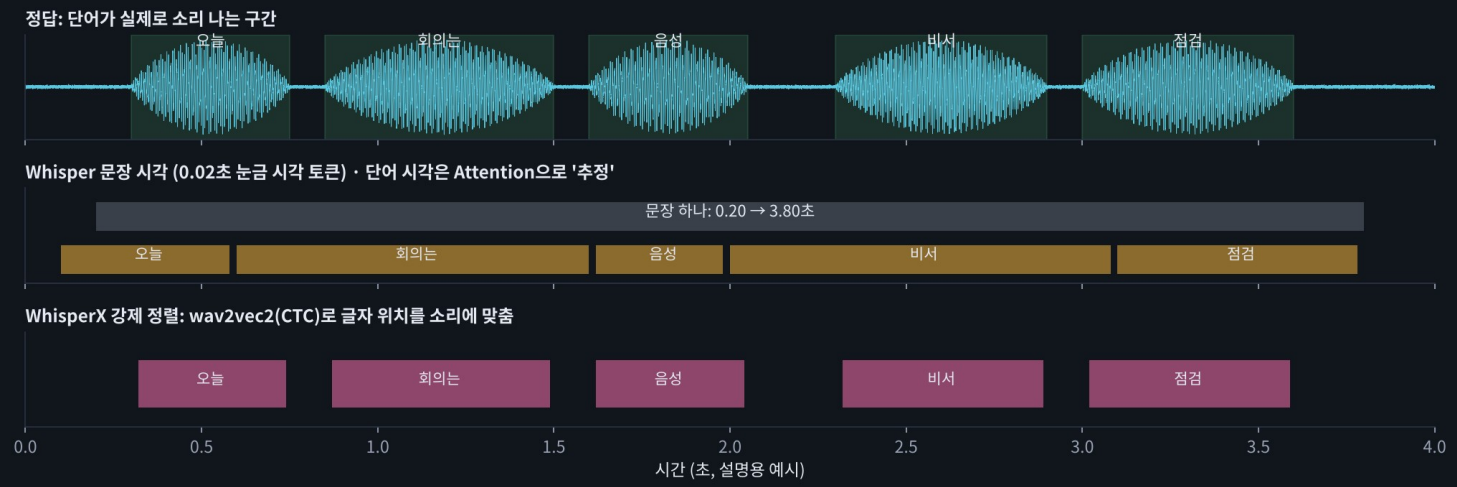
노래방 자막
지금 말하는 단어만 강조

회의록
단어마다 누가 말했는지 붙이기

시각의 종류	Whisper 는 어떻게	정확도
문장 (구간) 시각	받아 적으며 시각 토큰 <|1.20|> (0.02 초 눈금 , D7)	문장 경계는 대체로 맞음
단어 시각 (word_timestamps=True)	받아 적은 뒤 cross-attention 을 보고 DTW 로 추정	수백 ms 어긋남 , 무음에 끌려감

🍎 **받아 적은 속기사에게 나중에 묻기**
" 이 단어 몇 초에 나왔어요 ?" → 속기사는 기억으로 " 대충 이쯤 "(attention 추정). 강제 정렬은 원고를 들고 녹음을 다시 틀며 글자마다 손가락으로 짚는 것 .

추정은 어긋난다 : 특히 발화 경계에서




```
segs, info = fw.transcribe(
    meeting, language="ko",
    word_timestamps=True)
segs = list(segs)
for w in s.words: w.start, w.end
```

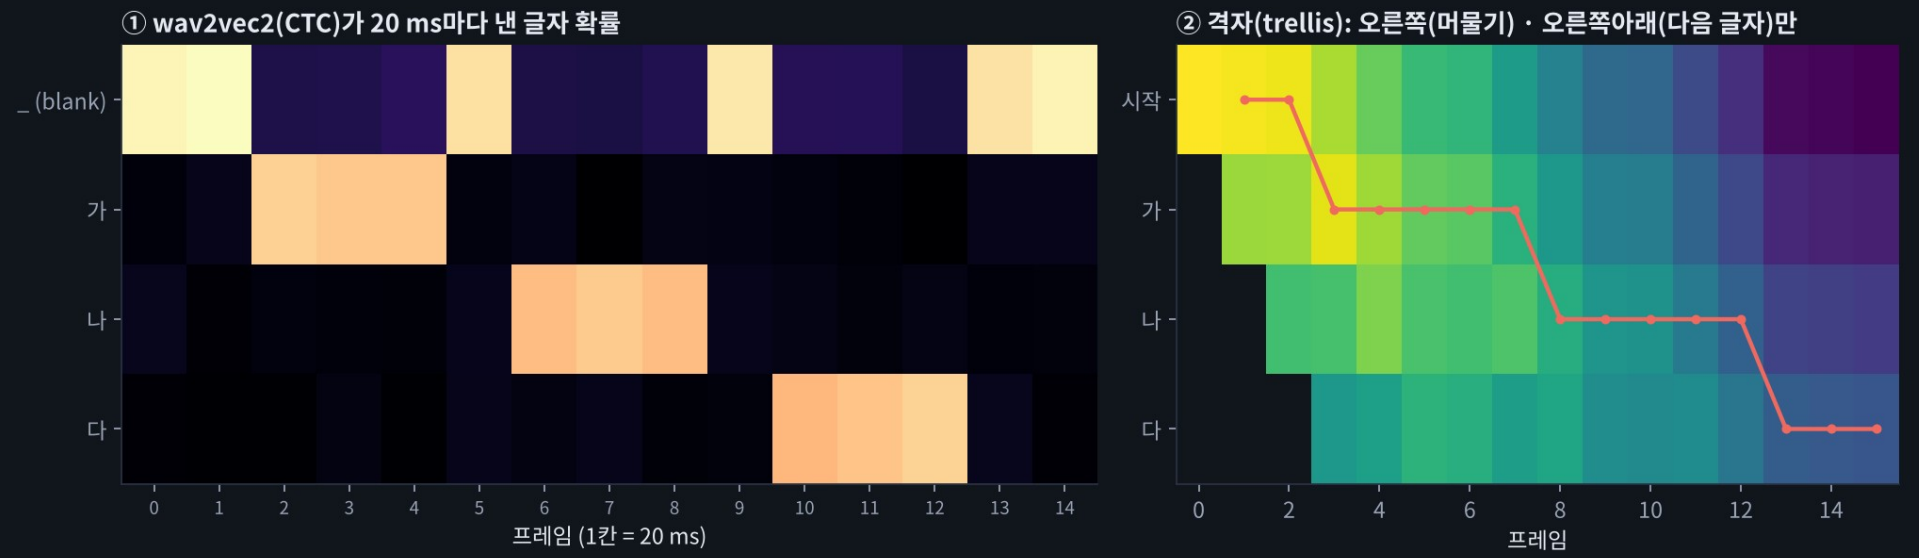
🧩 **빈칸 실습 1**

word_timestamps=____ → True

💬 **쉽게 말하면** " 단어 시각 " 은 Whisper 가 기억으로 짐작한 값 . 경계가 수백 ms 흔들린다 .

▶ 애니메이션 D9-2 문장 시각 vs 단어 시각

글자는 이미 안다 . " 언제 " 만 찾는다



🍎 노래방 가사 자막 맞추기

가사 (정답 글자) 는 이미 있다 . 노래를 틀어 놓고 각 글자를 언제 부르는지만 맞춘다 . 길게 부를 수는 있어도 가사 순서를 바꿀 수는 없다 .

1. wav2vec2: 20 ms 마다 글자 확률표
2. 격자 : 칸마다 머물기 vs 넘어가기
3. 끝 칸에서 거꾸로 따라가기
4. 시작 프레임 × 0.02 초 = 시각

칸마다 " 머물기 " vs " 넘어가기 " 중 큰 쪽

📐 핵심 식 하나

격자 [t+1, j] = max(격자 [t, j] + blank 점수 , 격자 [t, j−1] + 글자 j 점수)

읽는 법 : 다음 순간 j 번째 글자에 있으려면 , j 에 있다가 머물렀거나 j−1 에서 넘어왔거나 . 더 그럴듯한 쪽을 적는다 .

```
for t in range(T):
    trellis[t + 1, 0] = trellis[t, 0] + em[t, blank]
    stay = trellis[t, 1:] + em[t, blank]
    move = trellis[t, :-1] + em[t, tokens]
    trellis[t + 1, 1:] = np.maximum(stay, move)
```

글자	시작 프레임	시각
가	2	0.04 초
나	6	0.12 초
다	10	0.20 초

320 샘플 ÷ 16000 = 0.02 초 = 20 ms

🧩 빈칸 실습 2

em[t, ____] → tokens

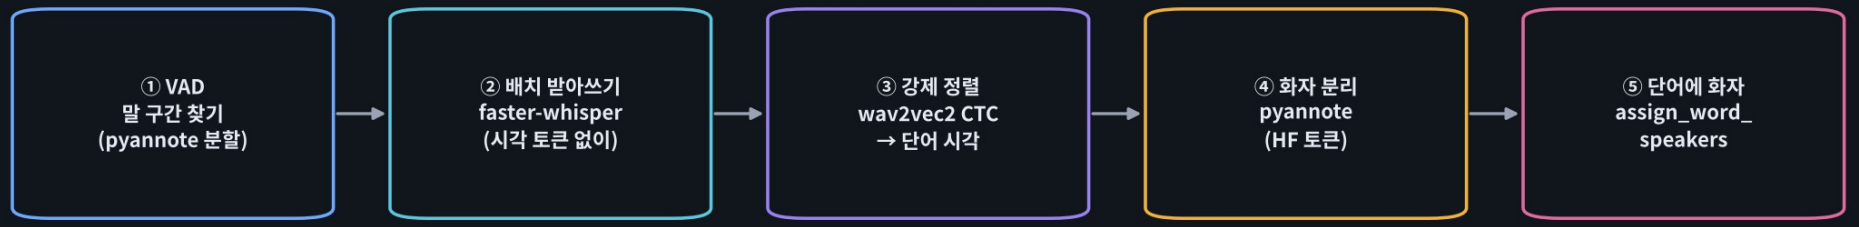
🧩 빈칸 실습 3

FRAME_SEC = ____ / SR → 320

▶ 애니메이션 D9-3 격자 따라가기

새 모델이 아니라 조립품

WhisperX = faster-whisper 배치 받아쓰기 + wav2vec2 강제 정렬 + pyannote 화자 분리



Part 3 = ①②③ · Part 4 = ④를 직접 만들기 · Part 5 = ④ pyannote · Part 6 = ⑤

🍎 속기사 + 교정 담당

속기사 (Whisper) 는 빠르게 받아 적기만 하고 시각은 안 적는다 . 교정 담당 (wav2vec2) 이 원고를 들고 녹음을 다시 들으며 글자마다 시각 도장을 찍는다 .

단계	함수
받아쓰기	`load_model → transcribe(batch_size)`
정렬 모델	`load_align_model(language_code="ko")`
정렬	`align(segments, model, meta, audio, device)`

▶ 애니메이션 D9-4 WhisperX 파이프라인

받아쓰기 구간은 " 묶음 ", 단어 시각은 정렬에서

```
import whisperx
wx = whisperx.load_model("small", DEVICE, compute_type=CT, language="ko")
result = wx.transcribe(meeting, batch_size=8, language="ko")

align_model, meta = whisperx.load_align_model(language_code="ko",
device=DEVICE)
aligned = whisperx.align(result["segments"], align_model, meta,
                         meeting, DEVICE, return_char_alignments=False)
w = aligned["segments"][0]["words"][0]   # word · start · end · score
```

정렬 점수 (score) 쓰는 법

0~1: 그 자리에서 얼마나 그 글자 소리 같았나

점수 낮은 단어 =

· 받아쓰기가 틀렸을 수 있음

· 소리가 뭉개짐 · 경계가 애매

정렬은 " 언제 " 만 찾고 틀린 글자를 고치지는 못함

🧩 빈칸 실습 4

load_align_model(language_code=____, ...) → "ko"

시 : 분 : 초 , 밀리초 — 쉼표에 주의

```
def srt_time(t):
    ms = int(round(t * 1000))
    h, ms = divmod(ms, 3_600_000)
    m, ms = divmod(ms, 60_000)
    s, ms = divmod(ms, 1000)
    return f"{h:02d}:{m:02d}:{s:02d},{ms:03d}"
```

```
1
00:00:00,500 --> 00:00:04,120
오늘 회의는 음성 비서 프로젝트
진행 상황을 점검하겠습니다 .

2
00:00:04,780 --> 00:00:09,010
```

🧩 **빈칸 실습 5**

ms = int(round(t * ____)) → 1000

💬 **쉽게 말하면** 단어 시각이 정확해야 자막이 말과 함께 뜨고 사라진다 . 노래방 자막이면 더 그렇다 .

" 누구인가 " 가 아니라 " 같은 사람끼리 묶기 "

1. 말 구간 자르기 (segmentation)
2. 조각마다 목소리 지문 (embedding, 192 차원)
3. 비슷한 지문끼리 묶기 (clustering)

🍎 **목소리만 들리는 전화 회의**

이름은 몰라도 " 아까 그 낮은 목소리 분 ", " 그 밝은 목소리 분 " 처럼 목소리로 구분해 A, B, C 라고 메모한다 . 이름은 나중에 .

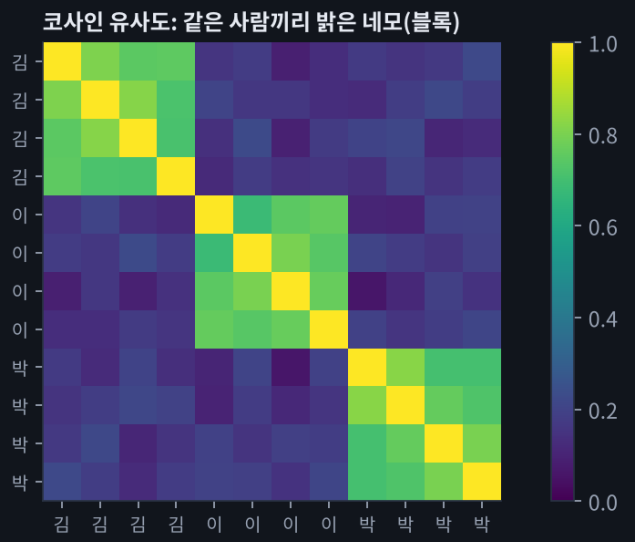
	화자 분리	화자 식별
질문	같은 사람끼리 ?	이 사람은 누구 ?
결과	SPEAKER_00 …	김팀장 …
필요	녹음만	등록 음성
오늘	Part 4 · 5	Part 6-2

```
iv = librosa.effects.split(meeting, top_db=30)
# 0.3 초보다 짧은 쉼은 이어 붙이기
```

💬 **쉽게 말하면** 화자 분리는 글자 없이 소리만으로 동작한다 . 그래서 받아쓰기와 따로 돌리고 나중에 시각으로 합친다 .

ECAPA-TDNN: 조각 하나 → 192 개 숫자





📐 핵심 식 하나 : cos(a, b) = (a · b) ÷ (‖a‖ × ‖b‖)

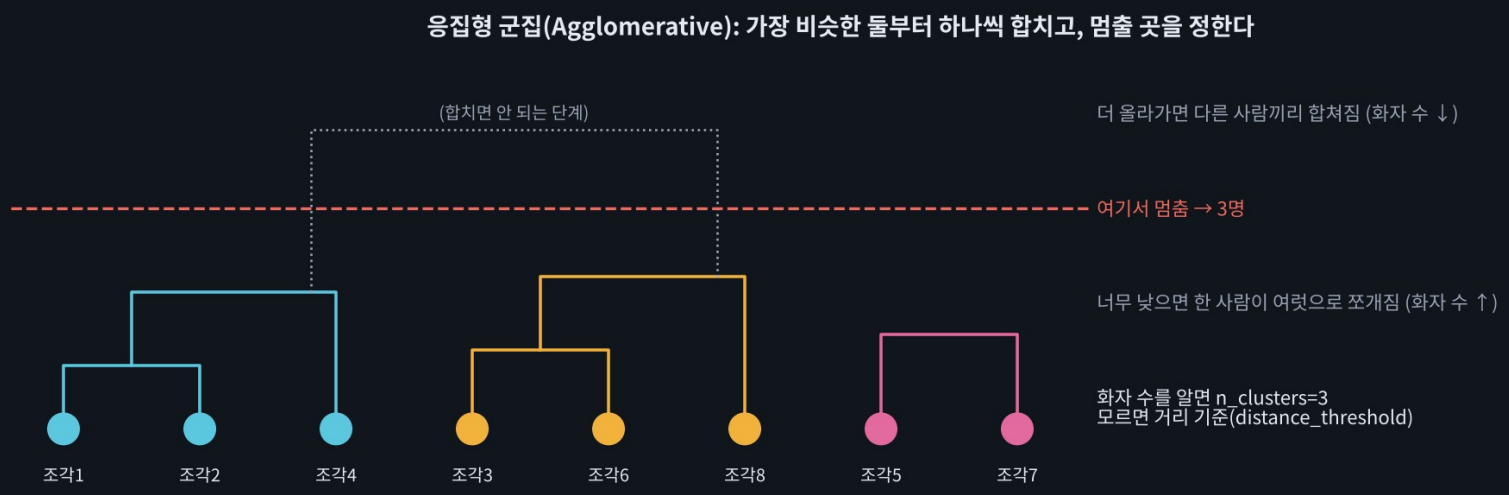
읽는 법 : 두 화살표가 같은 방향이면 1, 무관하면 0. 길이 (소리 크기) 로 나눠 방향만 비교한다 .

🧩 빈칸 실습 6

np.linalg.norm(a) * np.linalg.norm(____) → b

▶ 애니메이션 D9-5 목소리 지문 지도

가장 가까운 둘부터 합치고 , 멈출 곳을 정한다




```
N_SPK = 3
labels = AgglomerativeClustering(n_clusters=N_SPK, metric="cosine",
                                 linkage="average").fit_predict(E)
```

▶ 애니메이션 D9-6 군집 합치기

번호 (SPK_0 …) 의 순서는 의미 없음

🧩 **빈칸 실습 7**

N_SPK = ___ → 3

그래서 학습된 도구 (pyannote) 를 쓴다

약점	왜	pyannote 는
겹쳐 말하기	한 조각에 한 사람만 붙임	분할 모델이 동시에 말하는 여러 사람을 표시
조각 경계	소리 크기에만 의존 , 쉼 없으면 두 사람이 한 조각	학습된 분할 모델이 화자 바뀌는 순간을 찾음
화자 수	우리가 3 을 알려 줌	학습 · 조정된 기준 , min/max_speakers 로 범위
비슷한 목소리	지문이 가까워 합쳐짐	더 큰 지문 모델 · 정교한 군집 (그래도 어려움)

💬 **쉽게 말하면** 원리는 같다 : 구간 → 지문 → 묶기 . 각 단계를 학습된 모델로 바꾼 것이 pyannote.

speaker-diarization-community-1 (HF 토큰 필요)

```
from whisperx.diarize import DiarizationPipeline
diar = DiarizationPipeline(token=HF_TOKEN, device=DEVICE)
df_pya = diar(meeting, num_speakers=3)
# DataFrame: start · end · speaker (SPEAKER_00 …)
```

옵션	언제
num_speakers=3	정확히 알 때
min/max_speakers	범위만 알 때
없음	알아서

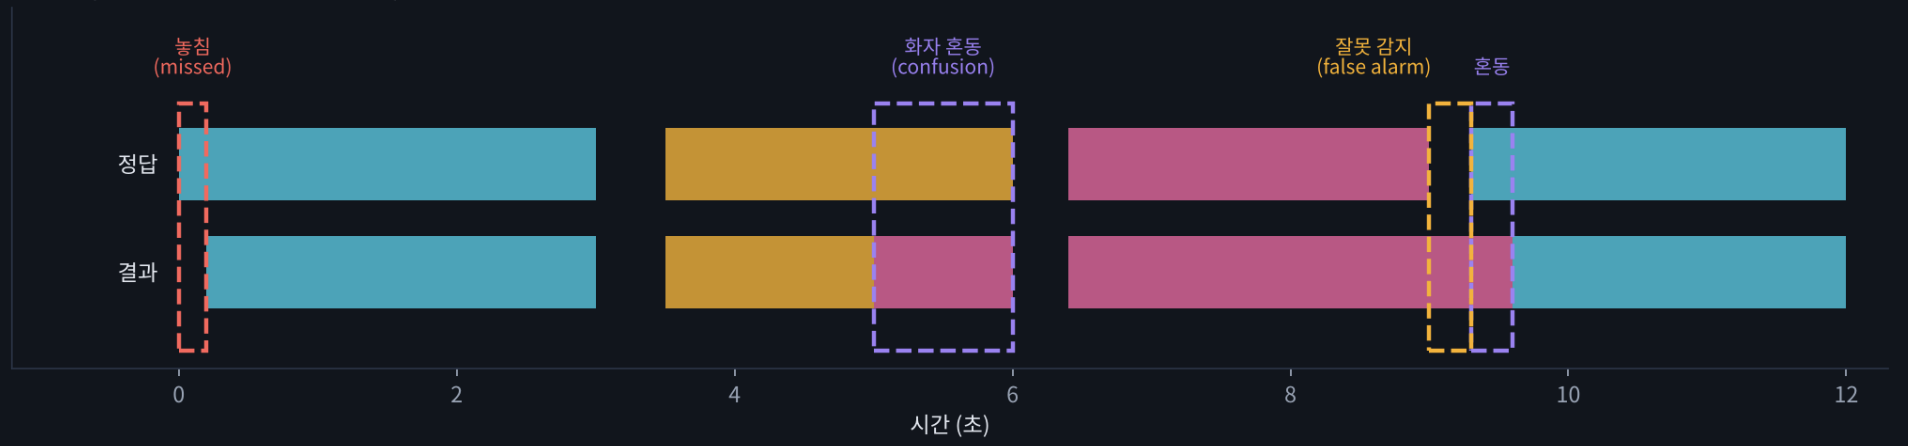
1. huggingface.co 로그인 → community-1 페이지에서 동의
2. Settings → Access Tokens → Read 토큰
3. Colab 🔑 보안 비밀 : HF_TOKEN, 노트북 액세스 켜기

🍎 숙련된 회의 속기사

우리가 만든 것은 첫날 신입 : 말 끊기는 곳만 보고 나눈다 . pyannote 는 수많은 회의를 겪은 속기사 : 끼어들기 · 겹쳐 말하기도 알아챈다 .

정답 말 시간 중 틀린 시간의 비율

DER = (놓침 + 잘못 감지 + 화자 혼동) ÷ 정답 말 시간 전체



오류	뜻	고칠 곳
놓침	말했는데 " 말 없음 "	VAD · 분할
잘못 감지	안 말했는데 " 말함 "	VAD · 분할
화자 혼동	다른 사람으로	지문 · 군집

🧩 빈칸 실습 8

(d["missed detection"] + d["false alarm"] + d[____]) / d["total"] → "confusion"

▶ 애니메이션 D9-7 DER 계산기

가장 많이 겹치는 화자 → 단어 시각이 정확해야




```
spk = whisperx.assign_word_speakers(df_use, aligned, fill_nearest=True)
for w in words_spk:
    spk = w.get("speaker", "?")
    if minutes and minutes[-1]["speaker"] == spk:
        minutes[-1]["text"] += " " + w["word"]
    else: minutes.append(...)
```

🧩 빈칸 실습 9

minutes[-1]["speaker"] == ____ → spk

▶ 애니메이션 D9-8 단어에 화자 붙이기

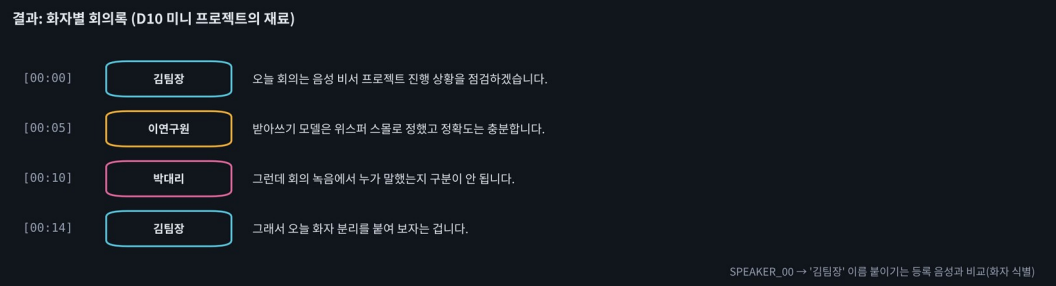
등록 음성 지문과 비교해 짝 찾기

	김팀장	이연구원	박대리
SPEAKER_00	0.82	0.21	0.35
SPEAKER_01	0.18	0.79	0.24
SPEAKER_02	0.30	0.22	0.76

코사인 유사도 (예시)

```
r, c = linear_sum_assignment(-sim)
NAME = {labels[i]: names[j] for i, j in zip(r, c)}
# {"SPEAKER_00": "김팀장", ...}
```

▶ 애니메이션 D9-9 회의록 만들기



SPEAKER_00 → '김팀장' 이름 붙이기는 등록 음성과 비교(화자 식별)

🍎 출입 명부와 대조하기

회의 전에 명부 (등록 음성) 를 받아 두고 , 회의 중 들린 목소리를 명부와 비교해 이름을 적는다 . 명부에 없는 사람은 " 알 수 없음 ".

자주 틀리는 일곱 가지

헷갈림	바른 이해
Whisper 단어 시각은 모델이 직접 배운 값 ?	아니다 . cross-attention 으로 추정
WhisperX transcribe() 구간 시각 = 정확한 시각 ?	VAD 묶음 시각일 뿐 . 정확한 시각은 align() 에서
정렬이 틀린 글자를 고쳐 준다 ?	아니다 . " 언제 " 만 찾고 점수만 낮게 나옴
화자 분리 결과에 이름이 나온다 ?	번호만 . 이름은 등록 음성으로 식별
SPK_0 은 처음 말한 사람 ?	번호 순서는 의미 없음
번호를 바꿔 붙이면 DER 이 바뀐다 ?	같다 . 가장 잘 맞는 짝을 자동으로 찾음
DER 이 낮으면 회의록도 정확 ?	단어 시각이 흔들리면 경계 단어 화자가 틀림

오늘 만든 것과 다음 단계

- ☐ Whisper 단어 시각의 경계 오차를 재 봤다
- ☐ 격자를 채우고 거꾸로 따라가 글자 시각을 구했다
- ☐ WhisperX 로 단어 시각 · 정렬 점수 · SRT 를 만들었다
- ☐ 말 구간 · ECAPA 지문 · 군집으로 화자 분리를 직접 했다
- ☐ pyannote 결과를 DER 로 평가했다
- ☐ 단어에 화자 · 이름을 붙여 회의록을 만들었다

다음 : Day 10 · ASR 평가 + 미니 프로젝트

WER · CER 을 제대로 재는 법 (jiwer, 한국어 띄어쓰기 · 숫자 · 문장 부호 정규화) 을 배우고 , 미니 프로젝트로 자동 회의록 생성기를 만듭니다 . 오늘의 화자별 회의록을 LLM 에 넘겨 요약 · 결정 사항 · 할 일까지 뽑아냅니다 .

worksheet.html	40 문항
개념 워크시트 · 노션 제출	
animation.html	9 개 탭
인터랙티브 애니메이션	
D9_ 타임스탬프 _ 화자분리 _ 실습 .ipynb	빈칸 9
실습 노트북	

온라인 자료 imguru-mooc.github.io/AI_Voice/day09