음성 AI 전문가 과정 · Day 13 / 40

Day 13

PEFT · LoRA Fine-tuning
저사양 GPU 로 도메인 용어 가르치기

LoRA 원리 (W + B·A) → 도메인 데이터 (용어 × 문장 틀) → 용어 정확도 · 프롬프트 기준선 → get_peft_model → 학습 → 4 자 비교 → 어댑터 저장 · 병합 · 갈아 끼우기 → 8-bit
3 주차 M3 · 4 시간 · T4 GPU · 실습 노트북 Part 0 ~ 9

```
trainable params: 3,538,944
  || all params: ≈ 245M || trainable%: ≈ 1.44

                  도메인 CER   용어정확도   일반 CER
① 원래 모델          …          …          …
② + 프롬프트         …          …          …
③ LoRA               …          …          …

lora-medical/adapter_model.safetensors  14 MB
```

출력 모양 예시 · 숫자는 도메인 · GPU 에 따라 다릅니다

0.0 · 오늘 답할 질문

전부 고치지 않고도 우리 분야 용어를 가르칠 수 있을까

1	LoRA 는 무엇을 고치고 , 왜 메모리가 적게 드나 ?	Part 1
2	도메인 학습 · 시험 데이터는 어떻게 만들어야 공정한가 ?	Part 2
3	용어를 잘 맞혔는지 어떻게 재나 ? 프롬프트만으로는 안 되나 ?	Part 3
4	Whisper 에 LoRA 를 어떻게 붙이고 학습하나 ?	Part 4 ~ 5
5	LoRA 가 정말 도움이 됐고 , 원래 실력은 지켰나 ?	Part 6
6	어댑터를 어떻게 저장 · 병합 · 갈아 끼우나 ?	Part 7 ~ 8

▶ 애니메이션 D13-1 오늘의 흐름

원리 → 데이터 → 기준선 → LoRA 학습 → 비교 → 어댑터

D13 · 원래 모델은 그대로 두고, 약 1%짜리 덧붙임(LoRA)만 학습해 '우리 분야 용어'를 가르치기



D12 Full Fine-tuning (전부 고치기) → D13 LoRA (약 1%만 고치기) → D14 비교 · 상용 API · Hub 업로드 → D15 미니 프로젝트

교시	내용	실습
1 교시	PEFT · LoRA 원리 , 파라미터 · 메모리 , 도메인 데이터 만들기	Part 0 ~ 2 · 빈칸 1 ~ 2
2 교시	용어 정확도 , 원래 모델 vs 프롬프트 기준선	Part 3 · 빈칸 3 ~ 4
3 교시	LoRA 붙이기 · 학습 (5~10 분) · 4 자 비교 · 원래 실력 확인	Part 4 ~ 6 · 빈칸 5 ~ 7
4 교시	어댑터 저장 · 병합 · 갈아 끼우기 , (선택) 8-bit, 정리	Part 7 ~ 9 · 빈칸 8 ~ 9 · 노션

Full Fine-tuning 의 세 가지 부담

부담	Full (D12)	LoRA (오늘)
학습 파라미터	2.4 억 (100%)	약 354 만 (1.4%)
기울기 + Adam	≈ 2.9 GB	≈ 0.04 GB
결과 파일	약 1 GB	약 14 MB
도메인 3 개	모델 3 개 (3 GB)	원래 1 개 + 어댑터 3 개
학습률	1e-5	1e-3

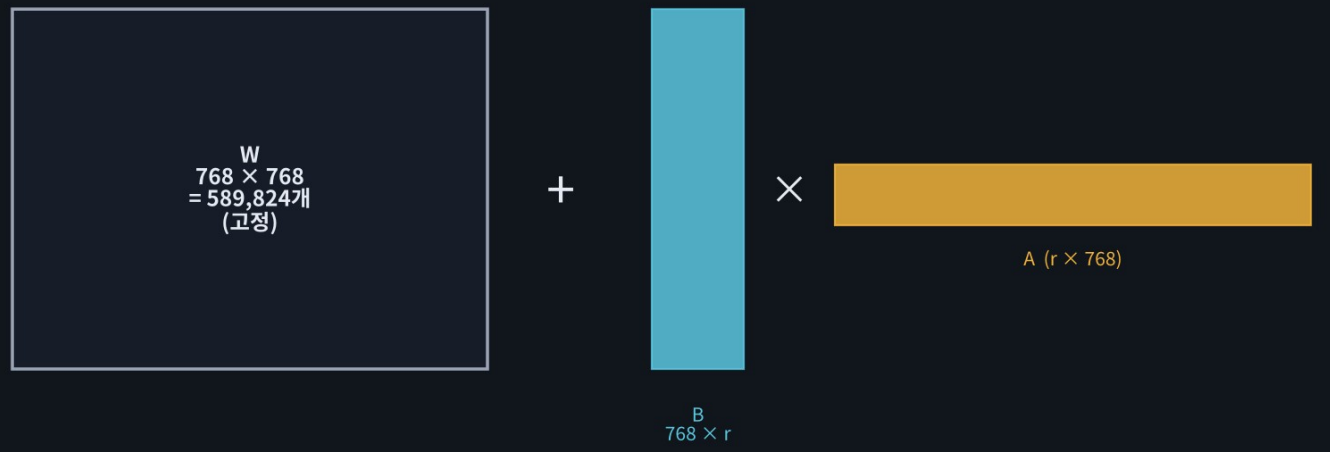
🍎 **교과서에 포스트잇**

두꺼운 교과서 (W) 를 다시 쓰지 않고 고칠 곳에 포스트잇 (B · A) 을 붙인다 . 과목 (도메인) 마다 다른 포스트잇으로 갈아 붙이고 , 마음에 들면 교과서에 옮겨 적는다 (merge).

💬 **쉽게 말하면** PEFT = 모델 대부분은 얼리고 아주 일부만 학습하는 방법들의 이름 . LoRA 가 가장 널리 쓰인다 .

W 는 고정 , 작은 B · A 만 학습해 더한다

LoRA: 큰 행렬 W는 얼려 두고(고정), 작은 두 행렬 B·A의 곱만 학습해 더한다



r = 32 이면

B · A 학습 수 = 32 × (768 + 768)
= 49,152개 (W의 8%)

처음엔 B = 0 → B·A = 0
→ 학습 시작 때 원래 모델과 똑같음

출력 = W·x + (α / r)·B·A·x

📐 **핵심 식 하나 : 출력 = W·x + (α / r) · B·A·x**

W(d × d) 고정 · B(d × r) · A(r × d) 학습 · r 은 보통 8~64

▶ 애니메이션 D13-2 LoRA 행렬 놀이터

768 × 768 행렬에 r = 32

```
W = rng.normal(0, 0.02, (d_out, d_in))    # 고정
A = rng.normal(0, 0.02, (r, d_in))
B = np.zeros((d_out, r))                   # 처음엔 0
lora_params = r * (d_in + d_out)           # 49,152

y_lora = W @ x + (alpha / r) * (B @ (A @ x))
np.allclose(W @ x, y_lora)   # True
np.linalg.matrix_rank(B_trained @ A)   # 32
```

🧩 빈칸 실습 1

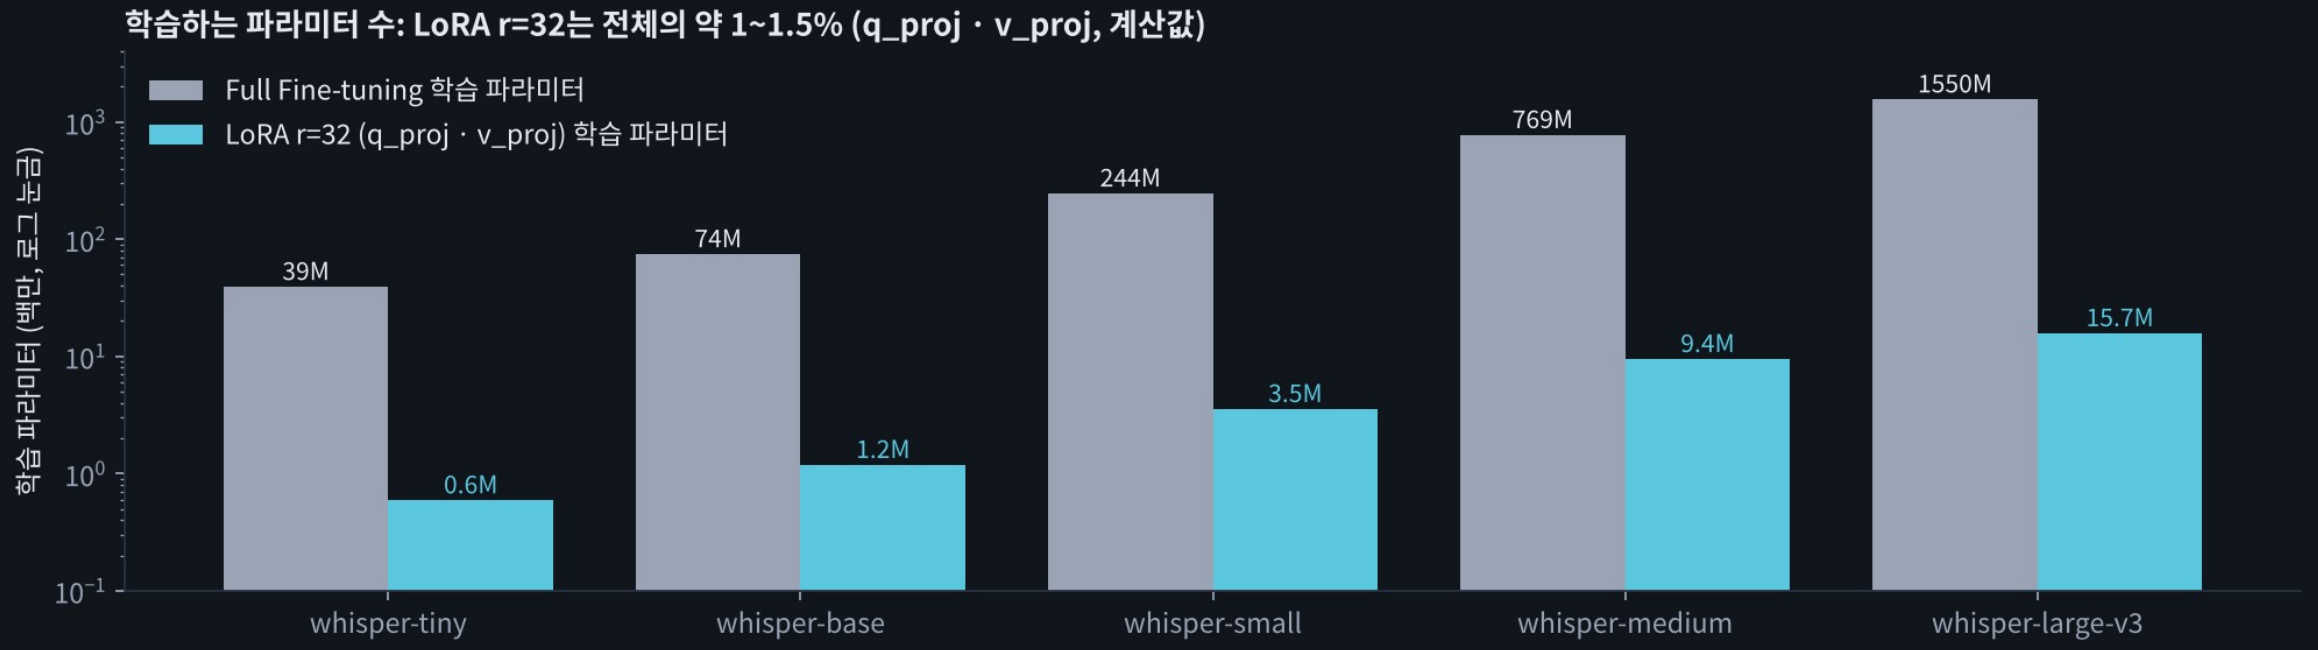
r * (d_in + ____) → d_out

🧩 빈칸 실습 2

B = np.____(...) → zeros

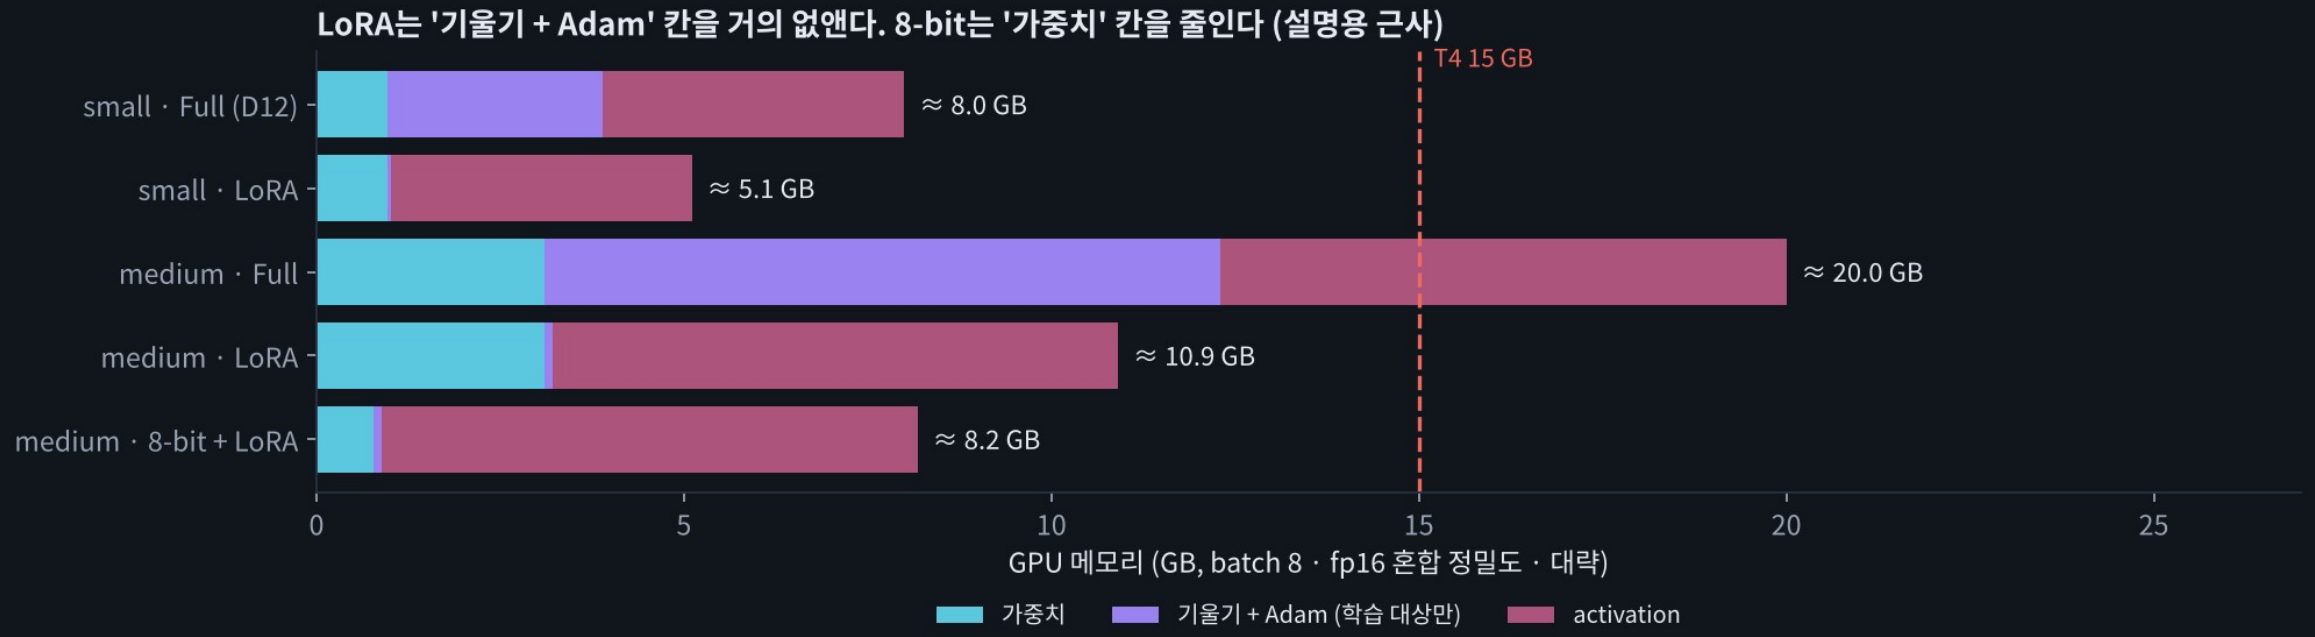
A 까지 0 이면 ? → 기울기 0, 못 배움

LoRA r = 32 는 전체의 약 1~1.5%



💬 **쉽게 말하면** 모델이 커질수록 LoRA 비율은 더 작아진다 → 큰 모델일수록 LoRA 의 이득이 크다 .

LoRA 는 기울기 + Adam 을 , 8-bit 는 가중치를 줄인다



▶ 애니메이션 D13-6 GPU 메모리 비교

⚠ activation 은 LoRA 여도 줄지 않는다

▶ 애니메이션 D13-3 도메인 데이터 설계

용어 20 × 문장 틀 10 → gTTS → 증강 → 틀 단위 분할



같은 용어라도 시험 문장은 '처음 보는 문장 틀' → 문장을 외운 게 아니라 용어를 익혔는지 확인
+ Zeroth 일반 문장 200개를 섞어(replay) 원래 실력을 지키기

도메인	용어 예
의료	심방세동 · 트로포닌 · 와파린 · 메트포르민 · 당화혈색소 · 폐색전증 …
법률	소멸시효 · 가압류 · 근저당권 · 집행유예 · 기판력 · 공시송달 …
산업	서보모터 · 공압 실린더 · 용접 비드 · 사출 성형 · 예지 정비 …

캐시 · 증강 · replay

```
def augment(y, rng):
    y2 = librosa.effects.time_stretch(y, rate=rng.uniform(0.9, 1.1))
    noise = rng.normal(0, 1, len(y2)) * np.sqrt(np.mean(y2**2)) / 10
    return y2 + noise

for ti, tpl in enumerate(TEMPLATES):
    for term in TERMS:
        y = tts(tpl.format(t=term))
        if ti < 7: dom_train += [row, 증강(row)]
        else:      dom_test.append(row)
```

세트	개수
도메인 학습	140 × 2 = 280
도메인 시험	60
replay (Zeroth)	200
일반 시험 (Zeroth)	50

핵심 용어 하나를 틀리면 쓸모가 없다

```
def term_accuracy(terms, preds):
    hits = [normalize(t) in normalize(p)
            for t, p in zip(terms, preds)]
    return 100 * float(np.mean(hits))
```

예측	판정
심방 세동이라고	✅ (띄어쓰기 무시)
와파린 경과를	✅
공압실린다 설명	❌ (글자 틀림)

3 개 중 2 개 → 66.7%

🧩 빈칸 실습 3

zip(terms, ____) → preds

▶ 애니메이션 D13-4 프롬프트 vs LoRA

학습 없이 용어 목록을 힌트로

용어를 맞히게 하는 두 방법: 프롬프트(힌트 쪽지) vs LoRA(과외)

프롬프트 (D7 initial_prompt)

<|startofprev|> 심방세동, 트로포닌, …
<|startoftranscript|><|ko|><|transcribe|> …

+ 학습 없음 · 바로 적용
– 용어가 많으면 프롬프트가 길어짐 (최대 224 토큰)
– 엉뚱한 곳에 용어를 끼워 넣기도 함
– 발음이 어려운 용어는 한계

LoRA Fine-tuning

용어가 들어간 소리 · 전사로 몇 분 학습
→ 수 MB짜리 어댑터 파일

+ 소리 → 용어 연결을 직접 배움
+ 프롬프트와 함께 쓸 수도 있음
– 학습 데이터(소리 + 전사)가 필요
– 학습에 없던 용어는 여전히 약함

```
prompt_ids = processor.get_prompt_ids(PROMPT, return_tensors="pt")
model.generate(input_features=f, prompt_ids=prompt_ids, language="korean")
```

🧩 빈칸 실습 4

get_prompt_ids(____) → PROMPT

LoraConfig + get_peft_model 한 줄




```
lora_cfg = LoraConfig(r=32, lora_alpha=64, lora_dropout=0.05, bias="none",
                      target_modules=["q_proj", "v_proj"])
model = get_peft_model(model, lora_cfg)
model.print_trainable_parameters()   # trainable%: 1.44
```

🧩 빈칸 실습 5

["q_proj", ____] → "v_proj"

🧩 빈칸 실습 6

____(model, cfg) → get_peft_model

D12 부품 그대로, 학습률만 100 배

설정	D12 Full	D13 LoRA
learning_rate	1e-5	1e-3
batch × accum	8 × 2	16 × 1
max_steps	300	200
데이터	Zeroth 2,000	도메인 280 + Zeroth 200
label_names	(자동)	["labels"]
학습 시간 (T4)	20~30 분	5~10 분

🧩 빈칸 실습 7

learning_rate=____ → 1e-3

▶ 애니메이션 D13-7 LoRA 학습률

Full 에 1e-3 → 원래 실력 무너짐

원래 · 프롬프트 · LoRA · LoRA + 프롬프트

```
pred_lora = transcribe(model, dom_test)
pred_both = transcribe(model, dom_test, prompt_ids=prompt_ids)
with model.disable_adapter():
    again = transcribe(model, dom_test[:4])
again == pred_base[:4]   # True
```

방법	용어	일반
① 원래	낮음	기준
② 프롬프트	↑	부작용?
③ LoRA	↑↑	≈ 기준
④ 둘 다	↑↑↑	—

💬 **쉽게 말하면** 숫자 하나보다 용어별 표를 보라: 원래 0% 이던 용어가 100% 가 됐다면 소리 → 용어 연결을 새로 배운 것.

세 가지를 꼭 확인

1. 원래 실력 : 일반 문장 CER 이 떨어지지 않았나 (replay · 작은 lr · 적당한 step)
2. 진짜 목소리 : 사람이 녹음한 문장으로 다시 시험 (과제 3)
3. 새 용어 : 학습에 없던 용어는 ? → 데이터 추가 · 프롬프트 · 사전

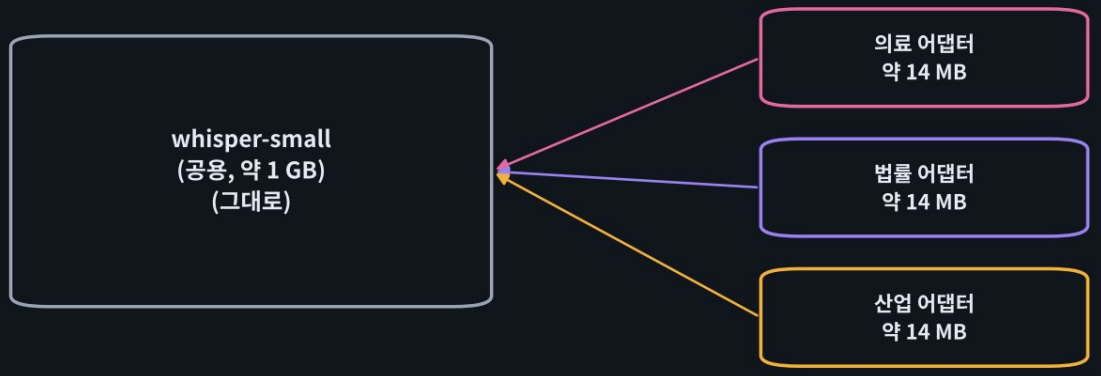
❓ 처음 보는 약 이름도 맞힐까 ?

대체로 아니다 . LoRA 는 학습 문장의 소리 · 글자 연결을 배운 것 → 자주 쓰는 핵심 용어는 LoRA, 새 용어는 프롬프트 · 사전 .

▶ 애니메이션 D13-8 어댑터 갈아 끼우기

수십 MB 만 나눠 주면 된다

원래 모델 하나 + 도메인별 어댑터 여러 개: 필요할 때 갈아 끼우기



PeftModel.from_pretrained(base, '의료')
model.load_adapter('법률', adapter_name='law')
model.set_adapter('law')

배포할 때: merge_and_unload()
→ 어댑터를 W에 더해 보통 모델로
(속도 손해 없음)

```
model.save_pretrained("lora-medical")
# adapter_config.json · adapter_model.safetensors (약 14 MB)
```

🧩 **빈칸 실습 8**

model.____(DIR) → save_pretrained

배포는 merge, 여러 도메인은 set_adapter

```
base = WhisperForConditionalGeneration.from_pretrained("openai/whisper-small")
lora_model = PeftModel.from_pretrained(base, "lora-medical")
merged = lora_model.merge_and_unload()

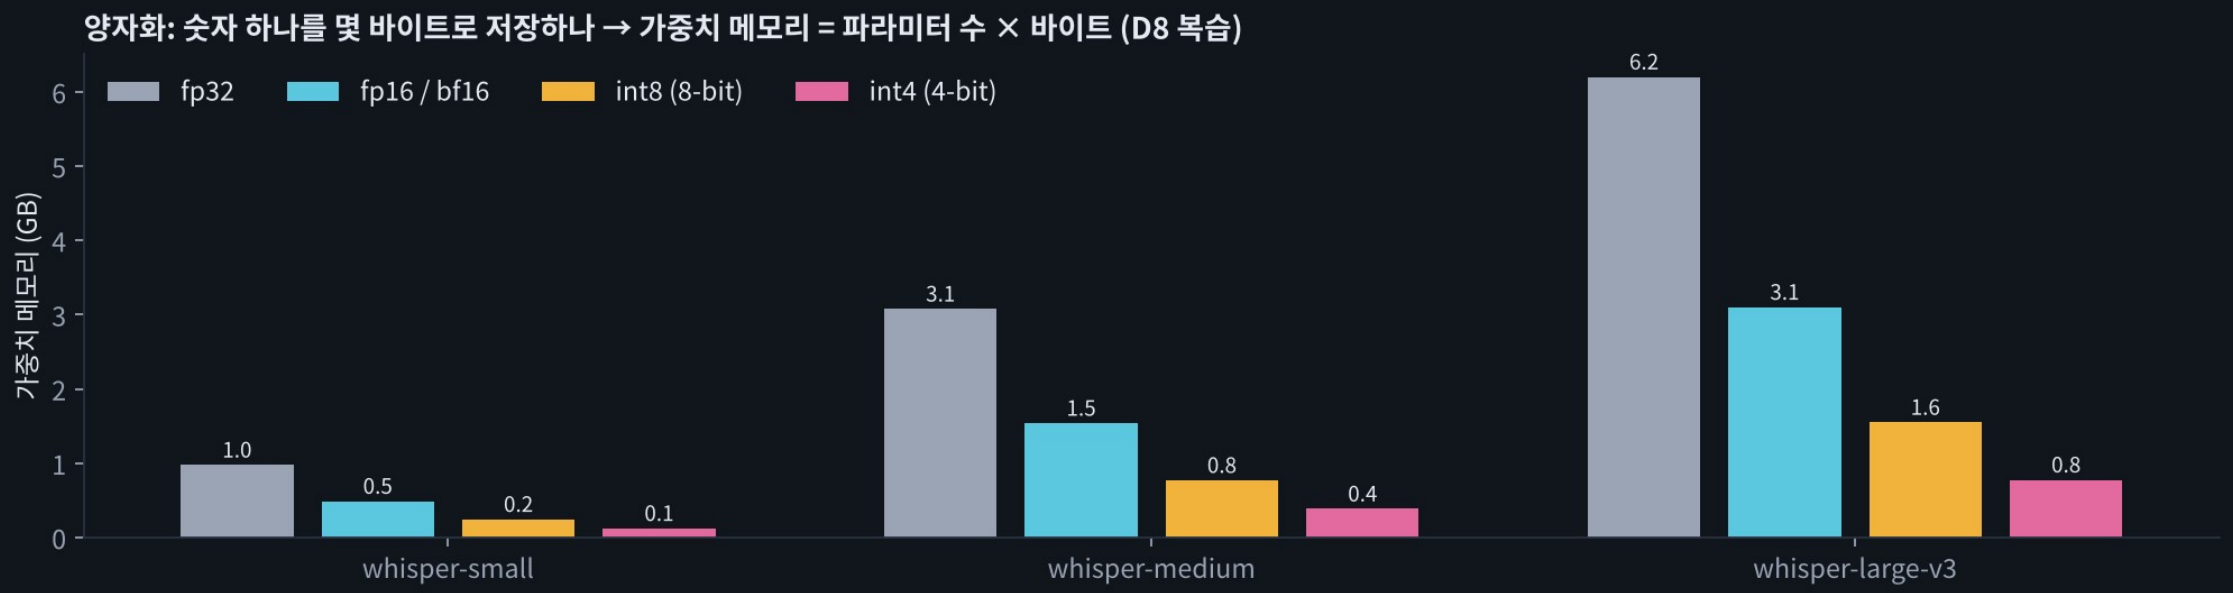
# 여러 도메인
lora_model.load_adapter("lora-legal", adapter_name="legal")
lora_model.set_adapter("legal")
```

🧩 **빈칸 실습 9**

lora_model.____() → merge_and_unload

	merge	어댑터 유지
추론 속도	원래와 같음	약간 느림
갈아 끼우기	불가	가능
배포 파일	모델 전체	원래 + 어댑터

얼린 W 는 낮은 비트로 , LoRA 는 정밀하게




```
WhisperForConditionalGeneration.from_pretrained("openai/whisper-medium",
    quantization_config=BitsAndBytesConfig(load_in_8bit=True), device_map="auto")
```

▶ 애니메이션 D13-9 양자화와 메모리

1.4% 만 고쳐 우리 분야 용어를 가르쳤다

- ☐ LoRA 식과 B = 0 초기화를 설명했다
- ☐ 학습 파라미터 · 메모리를 계산했다
- ☐ 용어 × 문장 틀로 도메인 데이터를 만들었다
- ☐ 용어 정확도 · 프롬프트 기준선을 쟀다
- ☐ get_peft_model 로 LoRA 학습 · 4 자 비교를 했다
- ☐ 어댑터를 저장 · 병합 · 갈아 끼웠다

다음 : D14 성능 비교 & 상용 API

원래 Whisper · D12 Full · D13 LoRA 를 같은 시험 세트로 비교하고 , OpenAI · Google · CLOVA Speech 같은 상용 API 와 정확도 · 속도 · 비용을 벤치마크합니다 . 만든 모델 · 어댑터는 Hugging Face Hub 에 업로드합니다 .

worksheet.html	40 문항
개념 워크시트 · 노션 제출	
animation.html	9 개 탭
인터랙티브 애니메이션	
D13_PEFT_LoRA_ 실습 .ipynb	빈칸 9
실습 노트북 · T4	

온라인 자료 imguru-mooc.github.io/AI_Voice/day13