음성 AI 전문가 과정 · Day 14 / 40

Day 14

성능 비교 & 상용 API
같은 시험지로 채점 · 고르기 · 공개하기

공정한 비교 → 원래 · D12 Full · D13 LoRA → OpenAI · Google · CLOVA REST 호출 → 과금 · 비용 → 리더보드 → 부트스트랩 → 오류 분석 → Hugging Face Hub
3 주차 M3 · 4 시간 · T4 GPU · API 키는 선택 · 실습 노트북 Part 0 ~ 9

시스템	일반 CER	용어	1 시간당 $	외부전송
① 원래 Whisper	…	…	…	아니요
② D12 Full	…	…	…	아니요
③ D13 LoRA	…	…	…	아니요
OpenAI gpt-transcribe	…	…	…	예
Google STT v1	…	…	…	예

원래 − D12: 95% 구간 [… , …] → 개선 ✓ ?
https://huggingface.co/ 사용자명 /…-lora

출력 모양 예시 · 숫자는 각자 실행 결과

0.0 · 오늘 답할 질문

우리 모델은 정말 나아졌고, 무엇을 써야 할까

1	여러 시스템을 공정하게 비교하려면 무엇을 맞춰야 하나?	Part 1 ~ 2
2	내 모델들은 얼마나 정확하고 빠른가 (RTF)?	Part 3
3	상용 API 는 어떻게 부르고, 비용은 어떻게 계산하나?	Part 4
4	정확도 · 속도 · 비용 · 개인정보를 한 표에서 어떻게 고르나?	Part 5
5	그 차이는 진짜인가, 우연인가?	Part 6 ~ 7
6	모델을 어떻게 공유하고 다시 쓰나?	Part 8

▶ 애니메이션 D14-1 오늘의 흐름

채점 → API → 리더보드 → 통계 → 공개

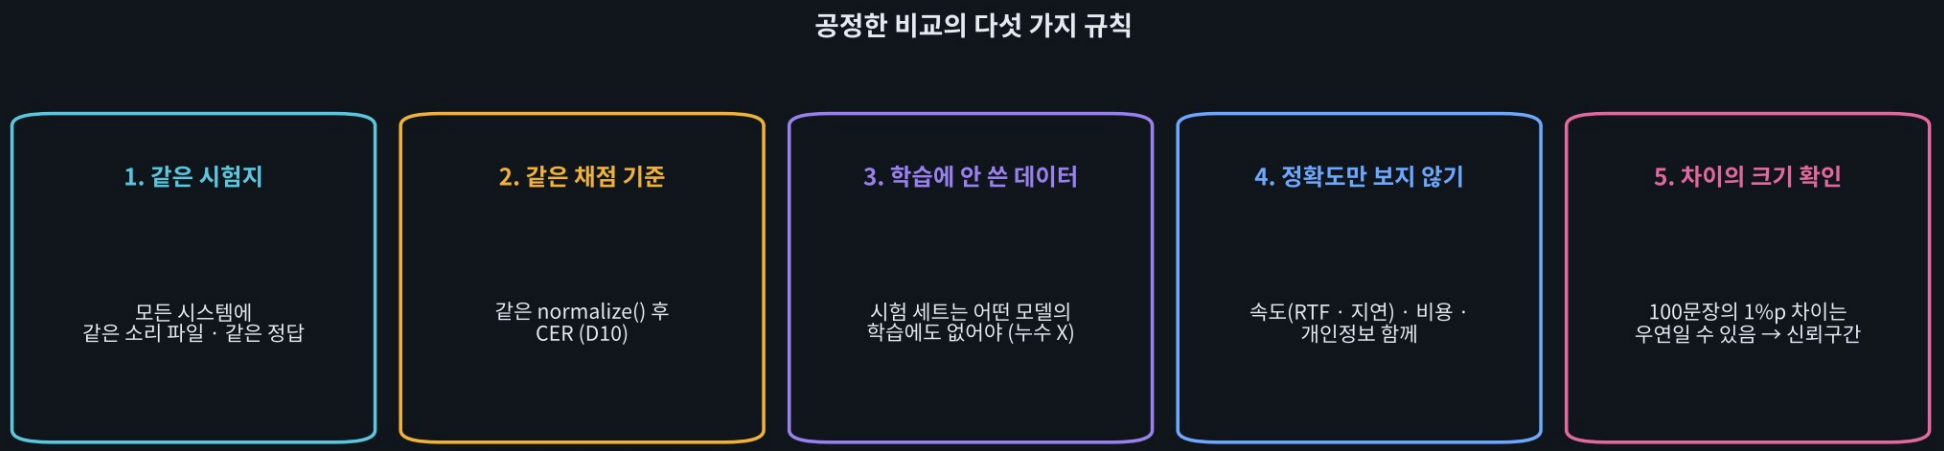
D14 · 같은 시험지로 모두 채점하고, 정확도 · 속도 · 비용 · 개인정보로 고른다



D11 데이터 → D12 Full → D13 LoRA → D14 비교 · 선택 · 공개 → D15 미니 프로젝트 (도메인 특화 ASR + 성능 리포트)

교시	내용	실습
1 교시	공정한 비교 규칙 , 시험 세트 (일반 + 도메인), 내 모델 채점 · RTF	Part 0 ~ 3 · 빈칸 1
2 교시	상용 API 3 종 REST 호출 , 지연 , 과금 단위 · 비용	Part 4 · 빈칸 2 ~ 4
3 교시	리더보드 , 부트스트랩 신뢰구간 , 오류 분석	Part 5 ~ 7 · 빈칸 5 ~ 6
4 교시	Hugging Face Hub 업로드 · 모델 카드 , 정리	Part 8 ~ 9 · 빈칸 7 ~ 9 · 노션

같은 시험지 · 같은 채점 · 누수 없음



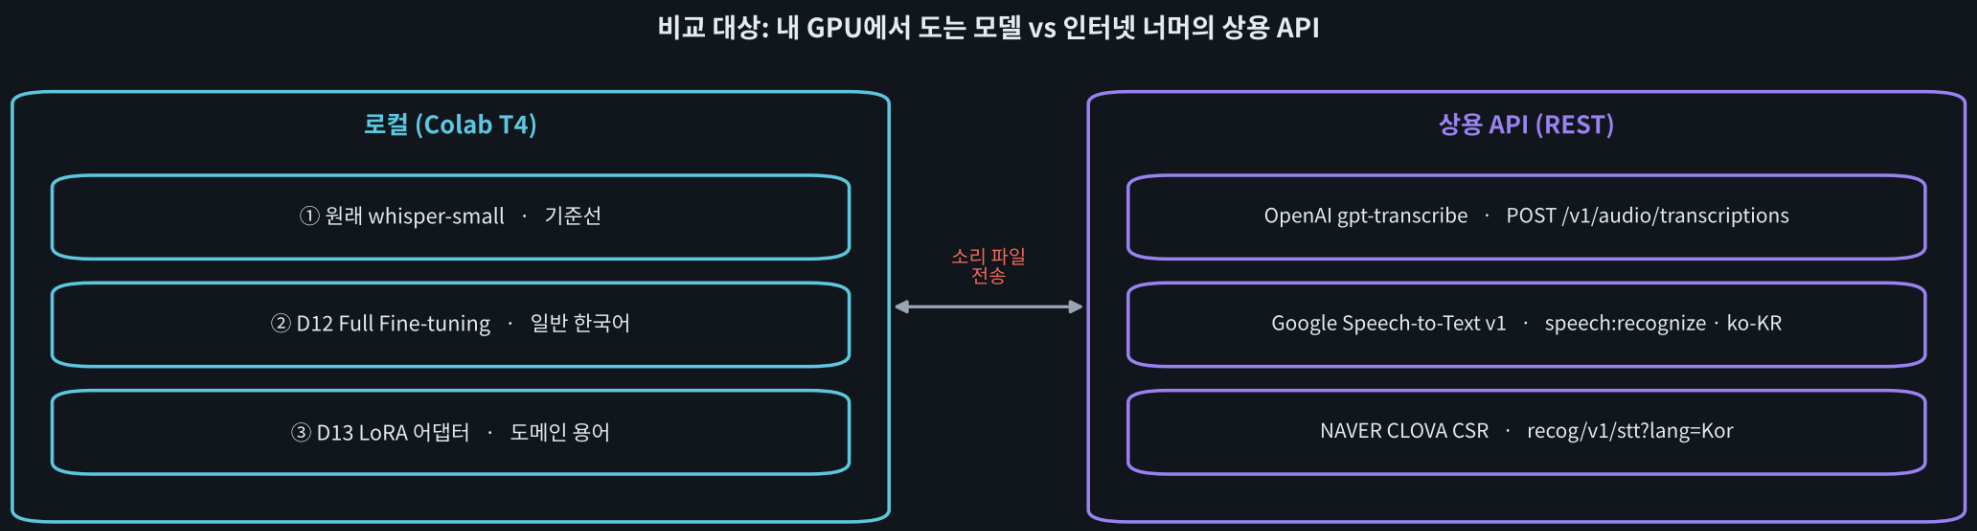
상용 API는 언제 학습됐는지 · 무엇으로 학습됐는지 알 수 없다 → 공개 시험 세트는 API가 이미 봤을 수도 있음 (내 녹음으로도 시험)

🍎 맛집 비교

같은 메뉴를 같은 기준으로 맛보되 , 가격 · 대기 시간 · 배달 가능 여부 (데이터 외부 전송) 까지 따져야 우리 회사 점심을 고를 수 있다 .

▶ 애니메이션 D14-2 불공정한 비교 찾기

내 GPU 의 모델 vs 인터넷 너머의 API

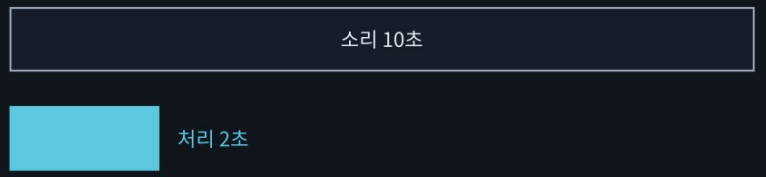


로컬: 데이터가 밖으로 안 나감 · GPU 비용 · 직접 관리 | API: 설치 없음 · 사용량만큼 과금 · 소리가 외부 서버로 전송 (개인정보 · 약관 확인, D34)

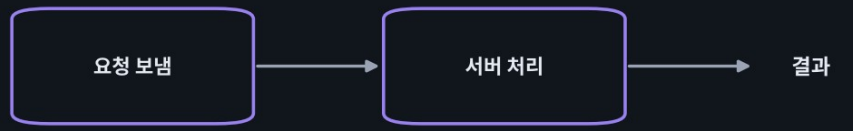
시험 세트	출처	개수	재는 것
일반	Zeroth 공식 test 무작위	100	일반 낭독 한국어 (D12 가 강해야)
도메인	D13 용어 20 × 시험용 문장 틀 3, gTTS	60	전문 용어 (D13 이 강해야)

RTF = 처리 시간 ÷ 소리 길이

속도 지표 두 가지: RTF(처리량)와 지연(latency)



RTF = 처리 시간 ÷ 소리 길이 = 2 ÷ 10 = 0.2
→ 1보다 작으면 실시간보다 빠름 (D8)



지연 = 요청 ~ 결과까지 벽시계 시간 (네트워크 + 대기 + 처리)
→ API는 네트워크 · 대기 시간이 더해짐 · 짧은 파일일수록 비중 큼

```
if GPU: torch.cuda.synchronize()
t0 = time.time(); preds = transcribe_local(m, ROWS)
if GPU: torch.cuda.synchronize()
rtf = (time.time() - t0) / AUDIO_SEC
```

🧩 빈칸 실습 1

elapsed / ____ → AUDIO_SEC

▶ 애니메이션 D14-3 RTF와 지연

주소 · 인증 · 소리 · 옵션 → JSON

	OpenAI	Google Cloud	NAVER CLOVA CSR
주소	/v1/audio/transcriptions	/v1/speech:recognize	/recog/v1/stt
인증	Authorization: Bearer	URL key=	X-NCP-APIGW-API-KEY(-ID)
소리	multipart 파일 (25 MB)	JSON base64 (동기 1 분)	본문 그대로 (60 초)
언어	languages[]=ko	languageCode: ko-KR	lang=Kor
결과	{"text": …}	results[].alternatives[0]	{"text": …}

▶ 애니메이션 D14-4 API 요청 해부

🔒 **소리는 회사 서버로 전송 → 동의 · 약관 · 보관 정책 확인**

requests 하나로 세 회사 모두

```
def openai_request(wav):
    return dict(url=".../v1/audio/transcriptions",
        headers={"Authorization": f"Bearer {KEY}"},
        data=[("model", "gpt-transcribe"), ("languages[]", "ko")],
        files={"file": ("audio.wav", wav, "audio/wav")})

def google_request(wav):
    return dict(url=".../v1/speech:recognize?key=" + KEY,
        json={"config": {"encoding": "LINEAR16", "sampleRateHertz": 16000,
                         "languageCode": "ko-KR"},
              "audio": {"content": base64.b64encode(wav).decode()}})

resp = requests.post(timeout=60, **openai_request(wav)); resp.json()["text"]
```

🧩 빈칸 실습 2

("languages[]", ____) → "ko"

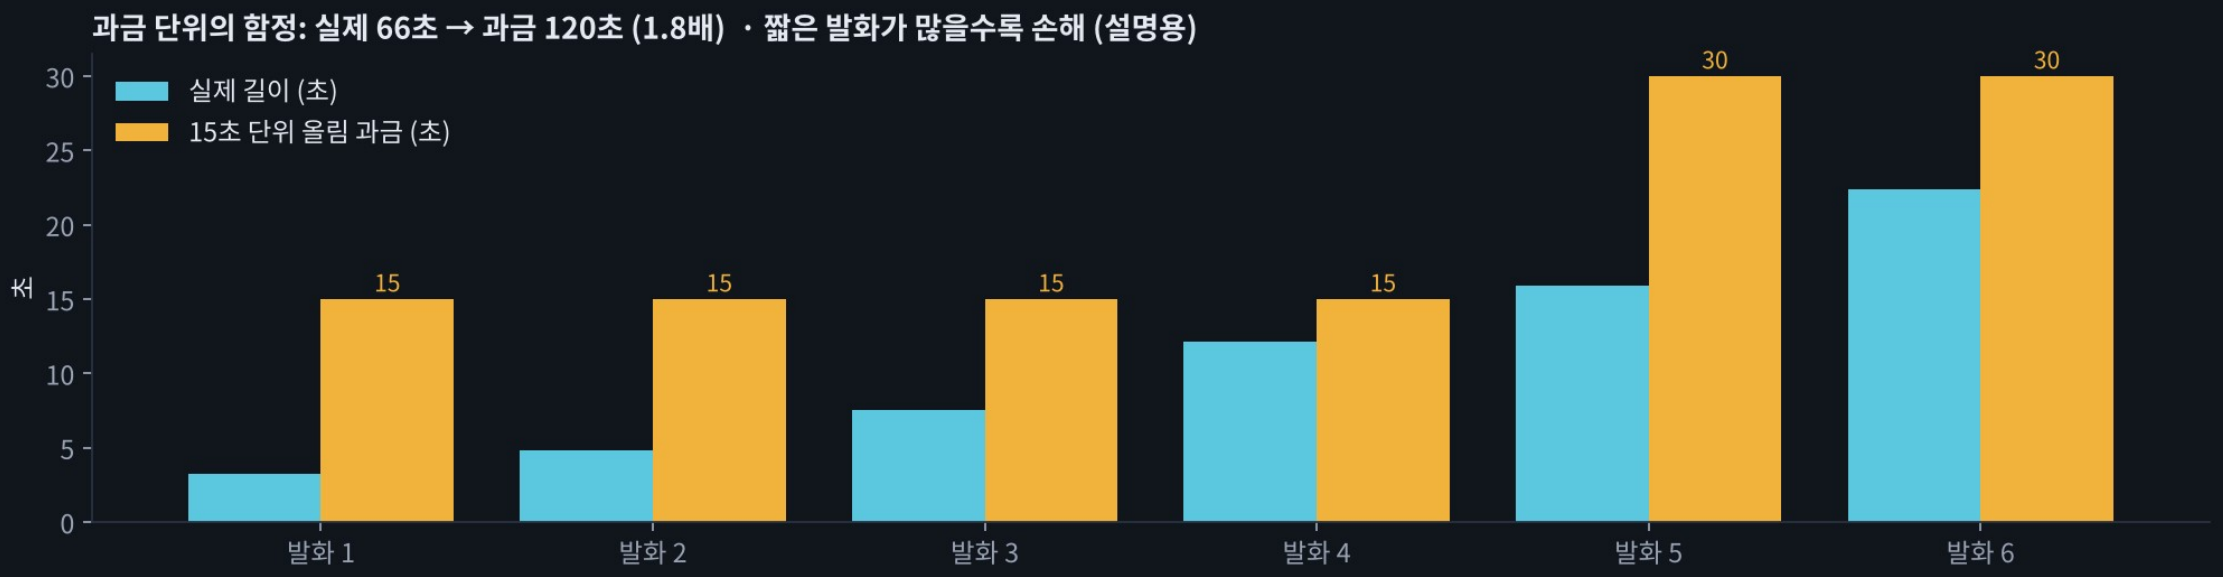
🧩 빈칸 실습 3

"languageCode": ____ → "ko-KR"

처음 3 개 모두 실패 → 멈춤 (키 · 권한)

▶ 애니메이션 D14-5 비용 계산기

요청마다 단위 시간으로 올림




```
def billed_seconds(durs, unit):
    return sum(math.ceil(d / unit) * unit for d in durs)
```

🧩 빈칸 실습 4

math.____(d / unit) → ceil

쓴 만큼 vs 켜 둔 만큼

	상용 API	로컬 GPU
비용 구조	처리한 소리 분 × 단가	GPU 켜 둔 시간 × 시간당
적게 쓸 때	유리	노는 시간도 비용
많이 쓸 때	선형으로 증가	유리 (손익분기 이후)
데이터	외부 서버로 전송	안에 머묾
관리	없음	설치 · 업데이트 · 장애 대응

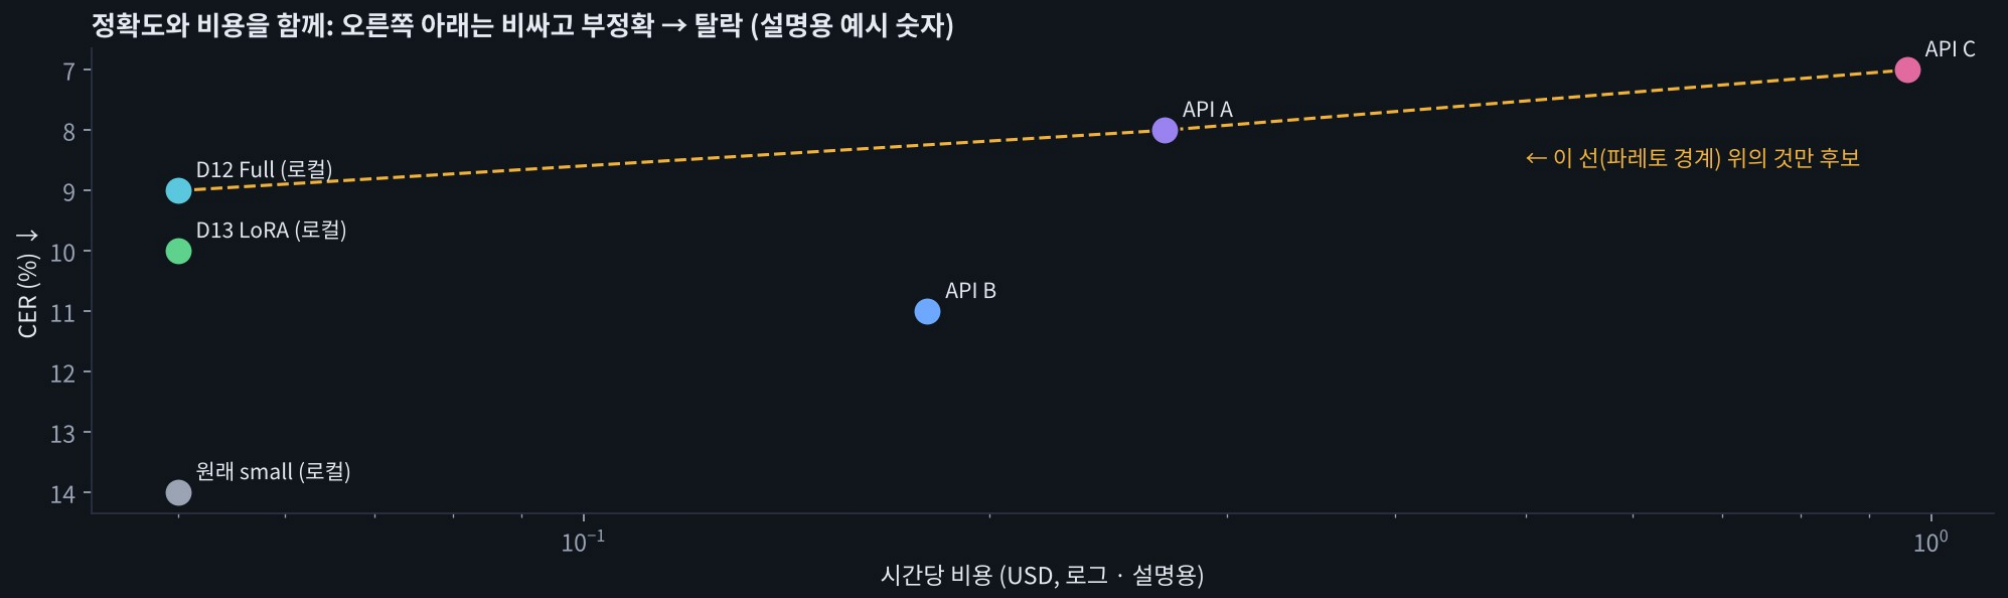
📐 손익분기 (하루 소리 시간)

= GPU 월 비용 ÷ (API 분당 × 60 × 30)

$360 ÷ ($0.0045 × 1,800) ≈ 44 시간 / 일

💬 **쉽게 말하면** 사용량이 적으면 API, 많고 민감하면 로컬. 섞어 쓰기도 흔하다.

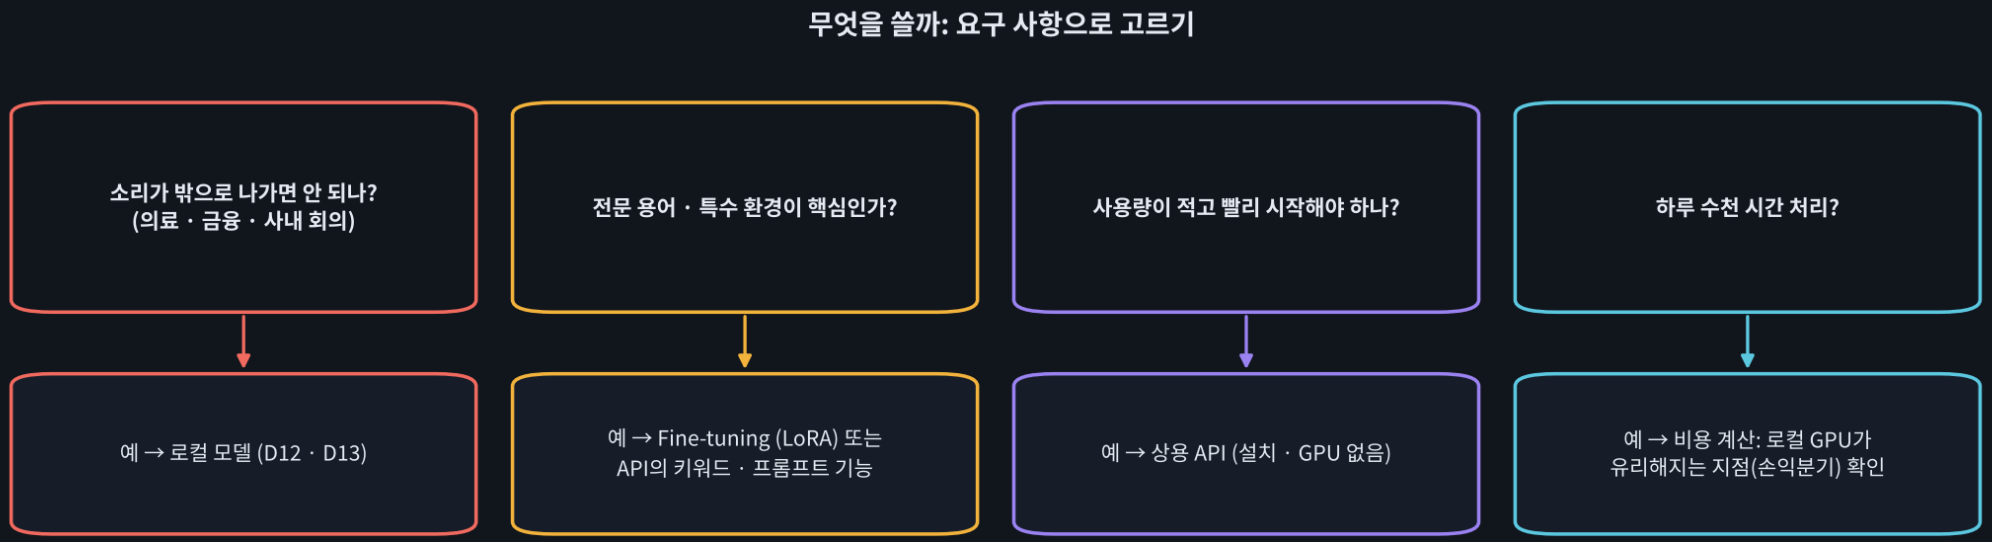
한 열만 보고 고르지 않기



열	뜻
일반 · 도메인 CER	같은 normalize() 후
용어 정확도	도메인 문장의 용어 포함 비율
RTF · 요청당 지연	처리량 · 체감 속도
소리 1시간당 USD · 외부 전송	비용 · 개인정보

▶ 애니메이션 D14-6 나만의 리더보드

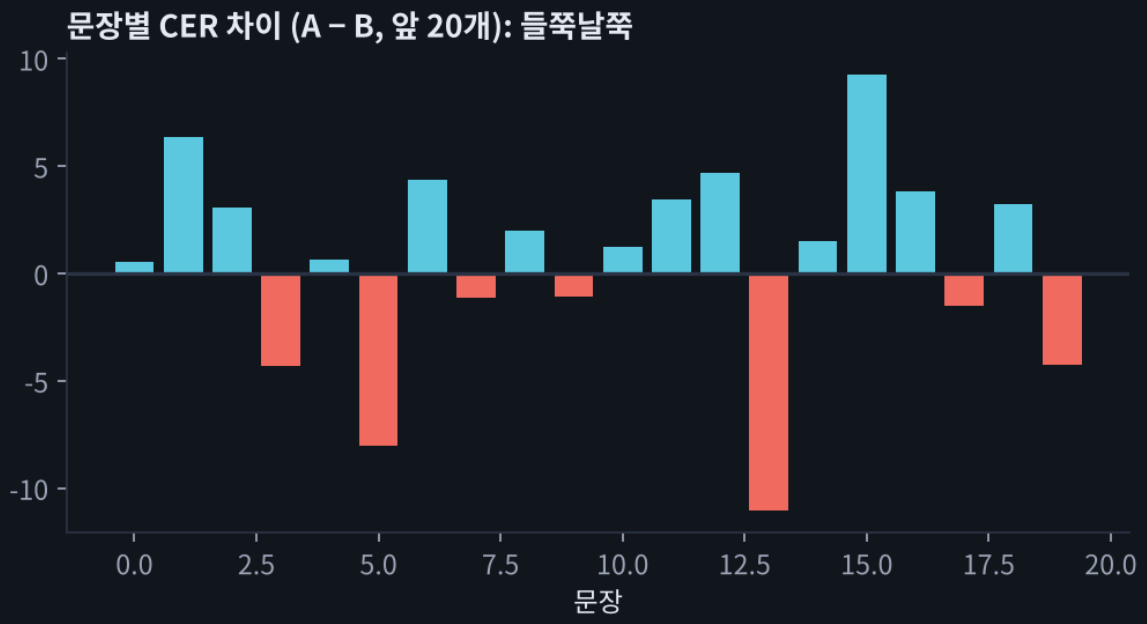
요구 사항이 먼저 , 점수는 그다음

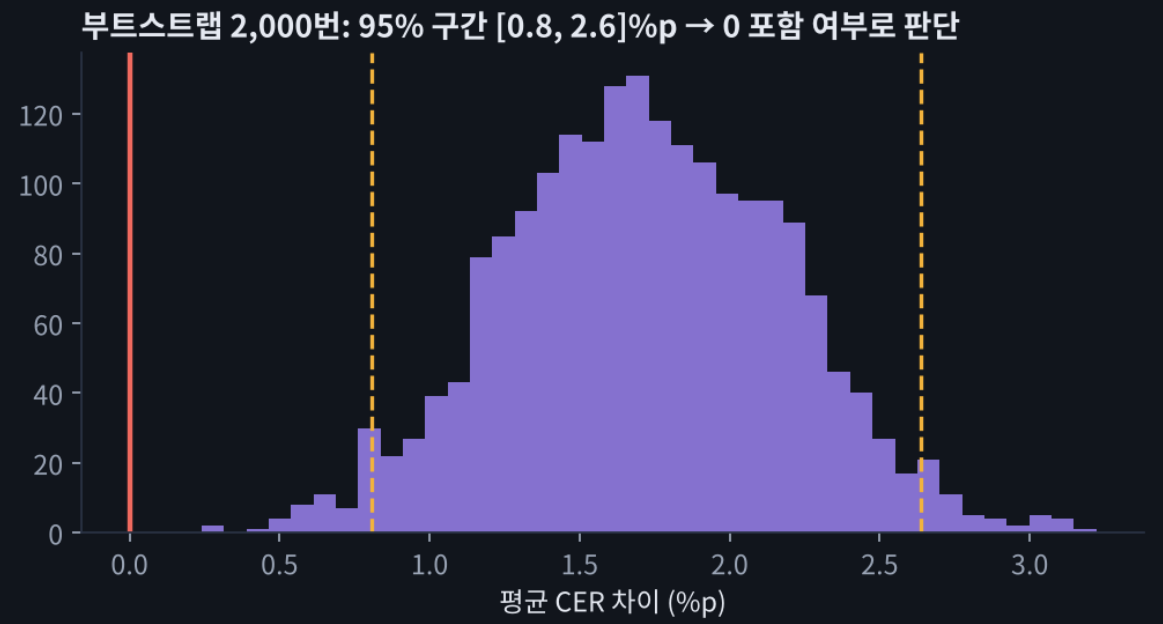


💬 **쉽게 말하면** 외부 전송 불가 → 로컬 · 용어가 핵심 → LoRA 또는 API 키워드 · 적게 쓰고 빨리 → API · 많이 쓰면 → 손익분기 계산 .

▶ 애니메이션 D14-7 부트스트랩 실험

그 차이 , 진짜인가요 ?





1 문장별 CER 짝 → 같은 크기 n 으로 복원 추출 → 평균 차이 → 2,000 번 → 2.5 ~ 97.5% 구간

rng.integers(0, n, n) 과 [2.5, 97.5]

```
def bootstrap_diff(a, b, n_boot=2000, seed=0):
    a, b = np.asarray(a), np.asarray(b); n = len(a)
    rng = np.random.default_rng(seed); diffs = []
    for _ in range(n_boot):
        idx = rng.integers(0, n, n)          # 복원 추출
        diffs.append(a[idx].mean() - b[idx].mean())
    lo, hi = np.percentile(diffs, [2.5, 97.5])
    return a.mean() - b.mean(), lo, hi, np.array(diffs)
```

🧩 빈칸 실습 5

rng.integers(0, n, ____) → n

🧩 빈칸 실습 6

[2.5, ____] → 97.5

구간	판정
[0.8, 2.6]	개선 ✓
[−0.4, 1.8]	차이 불확실
[−2.1, −0.3]	악화 ✗

종류별로 세면 고칠 곳이 보인다

종류	판정 규칙	고치는 방법
용어	도메인 문장인데 용어가 결과에 없음	LoRA · 키워드 힌트 · 용어 사전
숫자 표기	정답이나 결과에 숫자	정규화 (D10) · 표기 통일
크게 틀림	문장 CER 50% 초과	VAD(D4) · 환각 대응 (D7) · 더 큰 모델
일부 글자	그 밖의 틀림	데이터 추가 · Fine-tuning

▶ 애니메이션 D14-8 오류 종류 탐색기

❓ API 가 일반 CER 1 등 , 용어는 D13 이 1 등이면 ?

외부 전송 불가 → D13. 가능하면 API 키워드부터 시도 → 부족하면 LoRA. 섞어 쓰기도 흔함 . 어떤 경우든 내 녹음으로 재확인 .

모델의 GitHub

Hugging Face Hub 업로드: 토큰 → 저장소 만들기 → 폴더 올리기 → 모델 카드 → 어디서든 불러오기



⚠ 학습 데이터 라이선스 확인 (AIHub 데이터로 학습한 모델은 공개 전 약관 확인) · 토큰을 노트북에 직접 쓰지 않기

올릴 것	크기	쓰는 쪽 코드
D13 LoRA 어댑터 (우선)	약 14 MB	PeftModel.from_pretrained(원래 모델 , repo_id)
D12 Full 모델	약 1 GB	WhisperForConditionalGeneration.from_pretrained(repo_id)

무엇을 · 무엇으로 · 얼마나 · 어디서 약한지

```
---
language: ko
license: apache-2.0
base_model: openai/whisper-small
library_name: peft
pipeline_tag: automatic-speech-recognition
datasets: [kresnik/zeroth_korean]
metrics: [cer]
---
## 성능 (D14 시험 세트 · normalize 후 CER)
| 시스템 | 일반 CER | 도메인 CER | 용어 정확도 |
## 학습 데이터 · ## 한계 · ## 사용법
```

▶ 애니메이션 D14-9 모델 카드 만들기

⚠ 공개 전 확인

- Zeroth: CC BY 4.0 → 출처 표시
- AIHub 데이터로 학습 : 약관상 공개 제한 가능
- 직접 녹음 : 동의 범위에 모델 공개 포함 ?
- 토큰 · 개인정보를 카드에 쓰지 않기

create_repo → upload_folder → from_pretrained(repo_id)

```
api = HfApi(token=KEYS["HF_TOKEN"])
repo_id = f"{api.whoami()['name']}/whisper-small-ko-medical-lora"
api.create_repo(repo_id, private=True, exist_ok=True)
shutil.copytree(UPLOAD_SRC, "hub_upload"); README.md 쓰기
api.upload_folder(folder_path="hub_upload", repo_id=repo_id)

base = WhisperForConditionalGeneration.from_pretrained("openai/whisper-small")
back = PeftModel.from_pretrained(base, repo_id)
```

🧩 빈칸 실습 7

private=____ → True

🧩 빈칸 실습 8

api.____(...) → upload_folder

🧩 빈칸 실습 9

from_pretrained(..., ____) → repo_id

데이터 → Full → LoRA → 비교 · 공개

날	한 일	핵심 산출물
D11	한국어 데이터셋 · 목록표 · 품질 필터 · 화자 단위 분할	ko_asr_manifest.csv
D12	Full Fine-tuning · Collator · compute_metrics · 곡선	whisper-small-ko (약 1 GB)
D13	LoRA · 도메인 용어 · 프롬프트 비교	lora-medical (약 14 MB)
D14	공정한 비교 · API · 비용 · 부트스트랩 · Hub	리더보드 · 모델 카드 · Hub 저장소
D15	도메인 특화 ASR 미니 프로젝트	성능 리포트 · 발표

같은 시험지로 채점하고, 요구 사항으로 고르고, 카드와 함께 공개했다

- ☐ 공정한 비교 규칙으로 시험 세트를 만들었다
- ☐ 내 모델들의 CER · RTF 를 쟀다
- ☐ REST 로 상용 API 를 부르고 비용을 계산했다
- ☐ 리더보드로 요구 사항에 맞는 시스템을 골랐다
- ☐ 부트스트랩으로 차이가 진짜인지 확인했다
- ☐ 모델 카드와 함께 Hub 에 올리고 다시 불러왔다

다음 : D15 미니 프로젝트

팀별 도메인을 정해 데이터 만들기 → LoRA 학습 → 오늘의 비교 · 부트스트랩 · 오류 분석 → Hub 업로드와 모델 카드까지 하루에 완성하고 성능 리포트로 발표합니다. 내 목소리 시험 세트 (과제 1) 를 꼭 준비해 오세요.

worksheet.html	40 문항
개념 워크시트 · 노션 제출	
animation.html	9 개 탭
인터랙티브 애니메이션	
D14_성능비교_상용 API_실습.ipynb	빈칸 9
실습 노트북 · T4	

온라인 자료 imguru-mooc.github.io/AI_Voice/day14