음성 AI 전문가 과정 · Day 16 / 40

Day 16

TTS 원리
글자가 소리가 되기까지

텍스트 정규화 → G2P(g2pk2) → Acoustic Model(mel · duration) →
Vocoder(Griffin-Lim · HiFi-GAN) → VITS → ASR 역검증
4 주차 M4 · 4 시간 · T4 GPU 권장 · 실습 노트북 Part 0 ~ 8

```
원문    가격은 12,500 원입니다
정규화  가격은 만이천오백원입니다
G2P      가겨근 마니처노배궈님니다
uroman  gagyeogeun manicheonobaegwonimnida

VITS → 파형 16 kHz → Whisper 받아쓰기

평균 CER   A 원문 ···  B G2P …  C 정규화 +G2P …
```

출력 모양 예시 · 숫자는 각자 실행 결과

0.0 · 오늘 답할 질문

글자는 어떻게 소리가 될까

1	TTS 는 어떤 단계로 글자를 소리로 바꾸나 ?	Part 1
2	"3 시 15 분 " 은 어떻게 읽게 하나 ?	Part 2
3	쓴 글자와 소리가 다른 한국어를 어떻게 다루나 ?	Part 3
4	기호 수십 개를 프레임 수백 개로 어떻게 늘이나 ?	Part 4
5	소리의 그림 (mel) 을 어떻게 진짜 소리로 바꾸나 ?	Part 5
6	End-to-end VITS 안에서는 무슨 일이 , 앞 처리는 얼마나 도움이 되나 ?	Part 6 ~ 7

▶ 애니메이션 D16-1 오늘의 흐름

부품 하나씩 → 마지막에 귀와 숫자로 확인

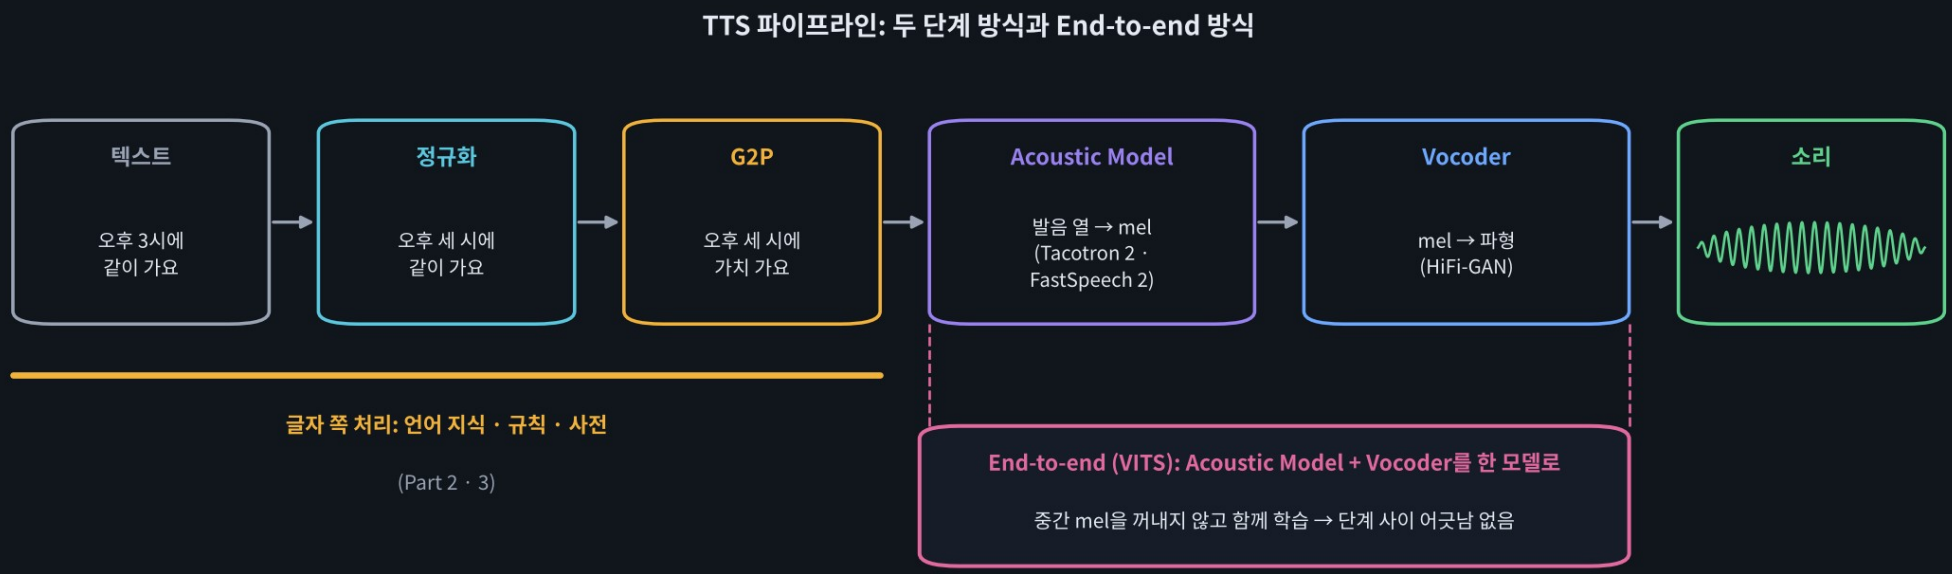
D16 · 글자가 소리가 되기까지 한 단계씩 만들고, 마지막에 귀와 숫자로 확인한다



3주차 ASR(소리 → 글자)의 반대 방향 · 오늘 쓰는 모델: g2pk2 · HiFi-GAN(SpeechT5) · VITS(MMS 한국어) · Whisper(역검증)

교시	내용	실습
1 교시	TTS 큰 그림 , 한국어 텍스트 정규화 (한자어 · 고유어 수)	Part 0 ~ 2 · 빈칸 1 · 2
2 교시	한글 자모 분해 , 연음 규칙 , g2pk2	Part 3 · 빈칸 3 · 4
3 교시	mel · duration (length regulator), Griffin-Lim vs HiFi-GAN	Part 4 ~ 5 · 빈칸 5 ~ 7
4 교시	VITS 해부 , ASR 역검증 (A · B · C), 정리	Part 6 ~ 8 · 빈칸 8 · 9 · 노션

정규화 → G2P → Acoustic Model → Vocoder

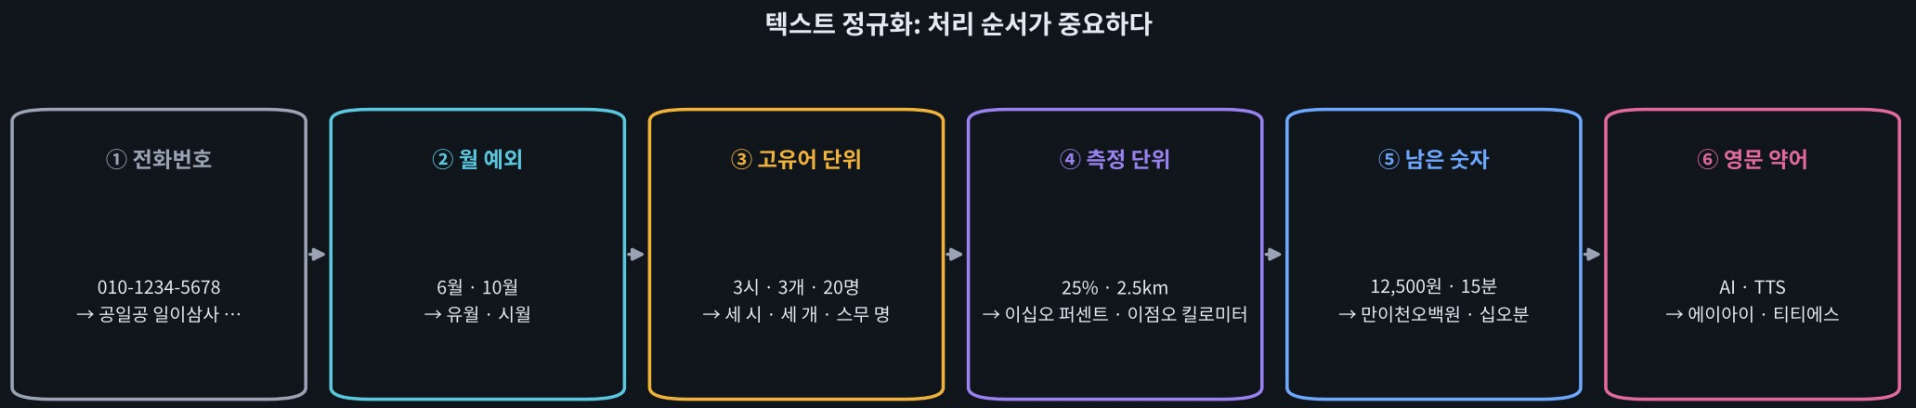


🍎 악보를 연주하기까지

가사 다듬기 (정규화) → 발음 표기 (G2P) → 작곡가가 악보 (mel) → 연주자가 연주 (Vocoder).
VITS 는 작곡가 겸 연주자 .

일대다 : 같은 문장 · 여러 정답 소리

모델은 숫자를 읽을 줄 모른다



순서를 바꾸면? ⑤를 먼저 하면 '3시'가 '삼 시'가 된다 · 규칙에 없는 표현(3~5개, 1/2, iPhone)은 사전 · LLM으로 보완

읽기	예	언제
한자어 수	2026 년 · 15 분 · 12,500 원 · 25%	날짜 · 분 · 돈 · 단위
고유어 수	3 시 · 3 개 · 20 명 (스무 명)	시 · 개수 단위
예외	유월 · 시월 · 공일공	사전

▶ 애니메이션 D16-2 정규화 실험실

네 자리씩 끊어 읽고 , 단위 앞 고유어는 모양이 바뀐다

```
def sino(n):   # 12500 → 만이천오백
    for big in ["", "만", "억", "조"]:
        ...
        s = ("" if d == 1 and i > 0 else ____[d]) + unit + s   # 빈칸 1

def read_count(n, unit):
    return (native(n) if unit in ____ else sino(n)) + " " + unit   # 빈칸 2
```

🧩 **빈칸 실습 1·2**

빈칸 1 → DIGITS

빈칸 2 → NATIVE_COUNTERS

입력	출력
sino(12500)	만이천오백
read_count(3, "시")	세 시
read_count(20, "명")	스무 명

음절 = 0xAC00 + (초성 × 21 + 중성) × 28 + 종성

한글 음절 = 0xAC00 + (초성 × 21 + 중성) × 28 + 종성



U+D55C

음절 번호	0xD55C − 0xAC00 = 10,588
초성	10,588 // 588 = 18 → ㅎ
중성	(10,588 % 588) // 28 = 0 → ㅏ
종성	10,588 % 28 = 4 → ㄴ



초성 하나 = 21 × 28 = 588칸
전체 19 × 21 × 28 = 11,172자

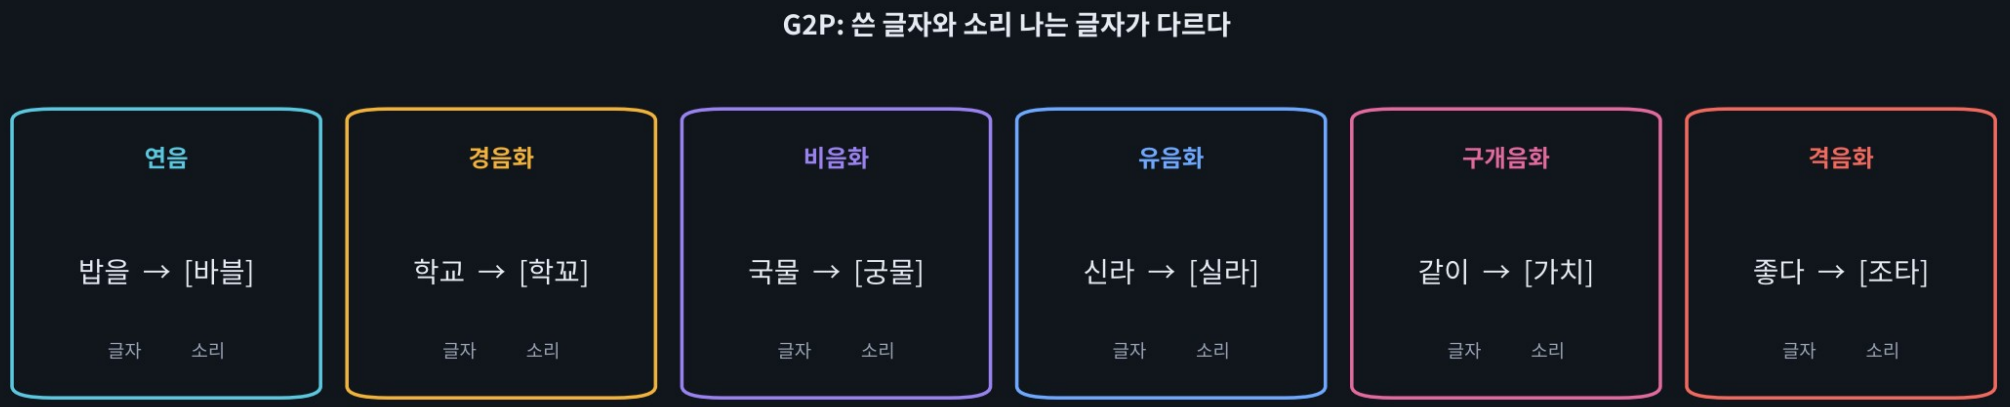
🧩 빈칸 실습 3 · 4

CHO[code // ___] → 588

연음 : b[0] == ___ → " ㅇ " (밥을 → 바블)

▶ 애니메이션 D16-3 한글 분해 계산기

쓴 글자와 소리가 다르다



g2pk2 = 형태소 분석(mecab)으로 단어 경계를 찾고 → 규칙 수십 개를 순서대로 적용 · descriptive=True면 실제 발음(의 → 에)

입력	직접 만든 연음	g2pk2
값이	갑시	갑씨
같이	가티 ✗	가치
국물	국물	궁물

▶ 애니메이션 D16-4 발음 규칙 탐색기

G2P 도 숫자를 일부 읽지만 , 틀리는 곳이 있다

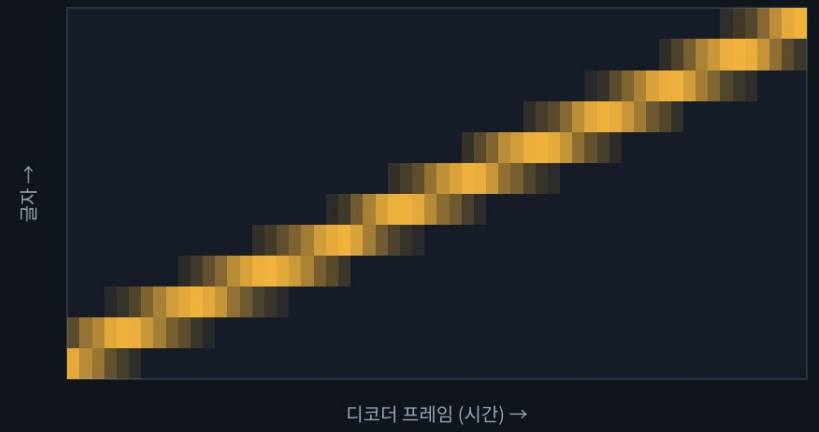
원문	g2p(원문)	g2p(정규화)
우유 2 병	우유 이병 ✗	우유 두 병
010-1234-5678	영이령 - 이리삼사 -… ×	공일공 이리삼사 …
2.5km	이 . 오 km ×	이점오 킬로미터
AI 음성	아이 음성 (영어 사전)	에이아이 음성
3 시 15 분	세시 시보분 ✓	세 시 시보분 ✓

정규화 (읽는 말로) → G2P(소리 나는 대로) 순서로 붙인다

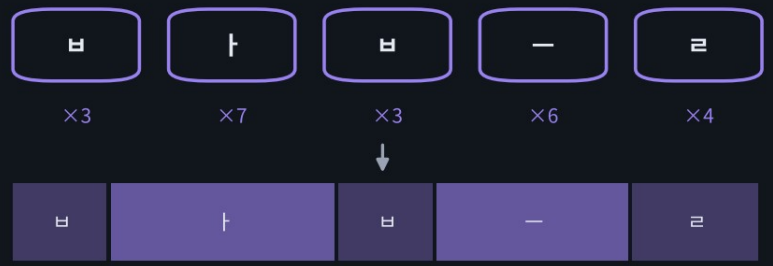
기호 수십 개 → 프레임 수백 개

Acoustic Model의 핵심 문제: 기호 수십 개 → 프레임 수백 개, 길이를 어떻게 맞추나

Tacotron 2: 어텐션 (프레임마다 어디를 읽나)



FastSpeech 2: duration 예측 → 복사해 늘이기



length regulator: np.repeat(enc, durations) · 말 빠르기 = duration ÷ rate

어텐션 실패(건너뛰기 · 반복)가 없고 병렬로 빠름

🧩 빈칸 실습 5

n_frames = 1 + len(y_real) // ____ → HOP (256)

▶ 애니메이션 D16-5 mel 만들기

기호마다 프레임 수만큼 복사



🧩 **빈칸 실습 6**

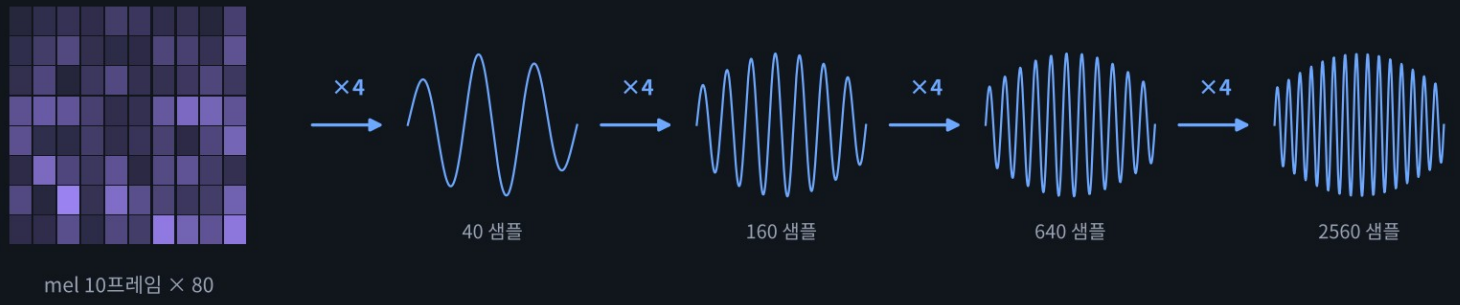
frames = np.repeat(enc, ____, axis=0) → durations

▶ 애니메이션 D16-6 길이 조절기

FastSpeech 2 는 pitch · energy 도 따로 예측 → 억양 · 강세 조절 (D18 감정 제어로 이어짐)

mel 에는 위상이 없다 → Vocoder 가 채운다

Vocoder: mel(위상 없음) → 파형 · HiFi-GAN은 4 × 4 × 4 × 4 = 256배 업샘플



Griffin-Lim
위상을 반복 추정
학습 X · 금속성 소리

HiFi-GAN
업샘플 합성곱 + GAN 판별기
깨끗 · 매우 빠름

프레임 10개 × hop 256 = 2,560 샘플 (0.16초) · Vocoder는 자기가 학습한 mel 설정만 제대로 읽는다

	Griffin-Lim	WaveNet	HiFi-GAN
방식	반복 위상 추정	자기회귀	업샘플 + GAN
품질	금속성	매우 좋음	매우 좋음
속도	보통	매우 느림	매우 빠름

▶ 애니메이션 D16-7 Vocoder 비교

진짜 녹음의 mel → HiFi-GAN → 소리

```
fe = SpeechT5FeatureExtractor.from_pretrained("microsoft/speecht5_tts")
vocoder = SpeechT5HifiGan.from_pretrained("microsoft/speecht5_hifigan")
mel_t5 = fe(audio_target=y_real, sampling_rate=SR, return_tensors="pt")
["input_values"][0]
hop_v = int(np.prod(vocoder.config.____))   # 빈칸 7
y_hifi = vocoder(mel_t5)   # 길이 = 프레임 × 256
```

🧩 **빈칸 실습 7**

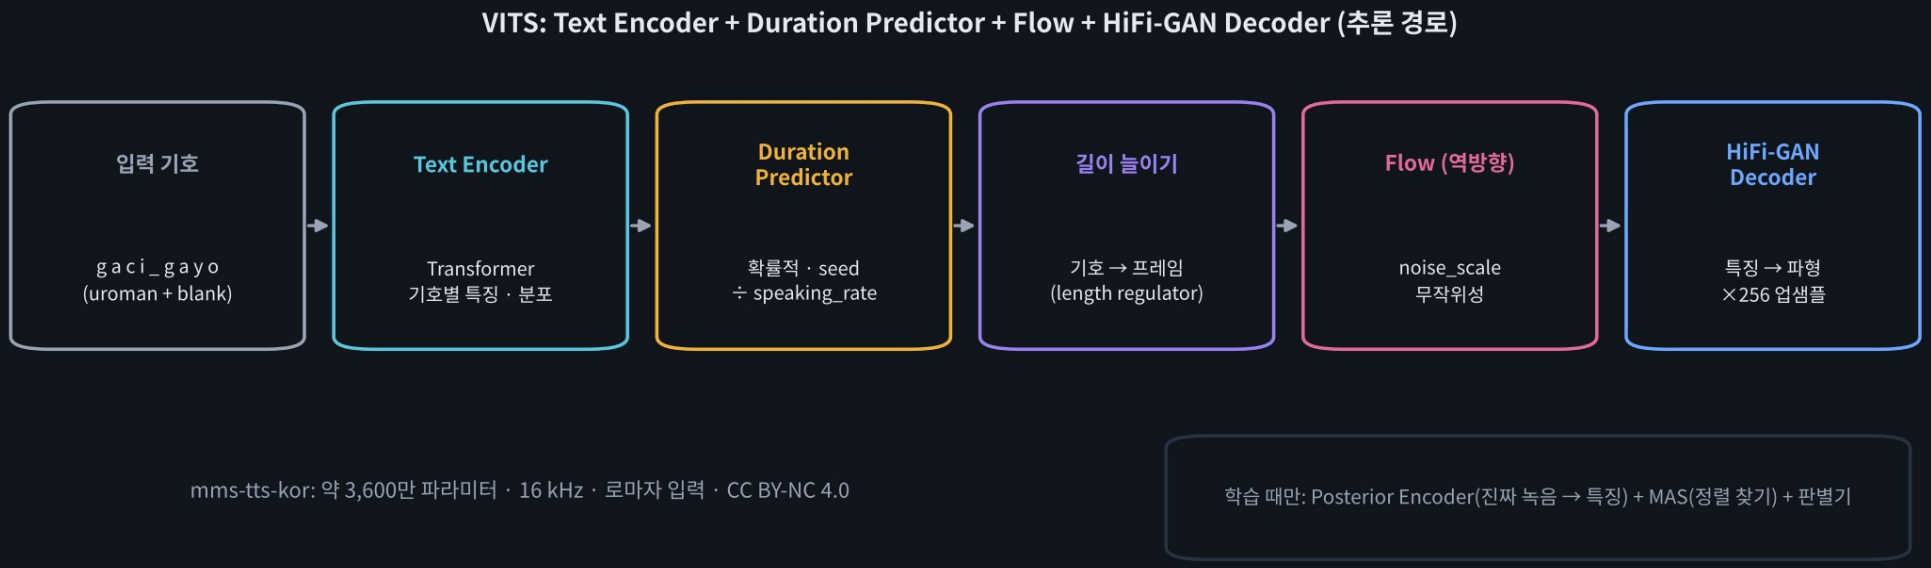
upsample_rates

(4, 4, 4, 4) → 곱 256 = hop

📐 **업샘플 배수의 곱 = hop · Vocoder 는 같은 mel 설정만 제대로 읽는다**

같은 Vocoder 로 비교해야 Acoustic Model 비교가 공정하다 (D14 같은 시험지)

Text Encoder + Duration + Flow + HiFi-GAN 한 몸



▶ 애니메이션 D16-8 VITS 해부

mms-tts-kor: 약 3,600 만 파라미터 · 16 kHz · 로마자 입력 · CC BY-NC 4.0

한글 → 로마자 , 그 전에 무엇을 하나

방식	처리	" 같이 "	" 오후 3 시 "
A 원문	uroman	gati	ohu 3si (숫자 남음 → 지워질 수 있음)
B G2P	g2pk2 → uroman	gaci	ohu sesi
C 정규화 + G2P	normalize_ko → g2pk2 → uroman	gaci	ohu se si

🧩 **빈칸 실습 8**

U.____(text) → romanize_string

토큰 사이사이 blank(0 번) → 입력 길이 약 2 배

frames = ceil(exp(log duration) ÷ speaking_rate)

```
hook = tts.duration_predictor.register_forward_hook(
    lambda mod, inp, out: CAP.__setitem__("log_dur", out))
dur = torch.ceil(torch.exp(____) / 1.0)[0, 0]   # 빈칸 9
int(dur.sum()) * HOP_V == len(wav)   # True
```

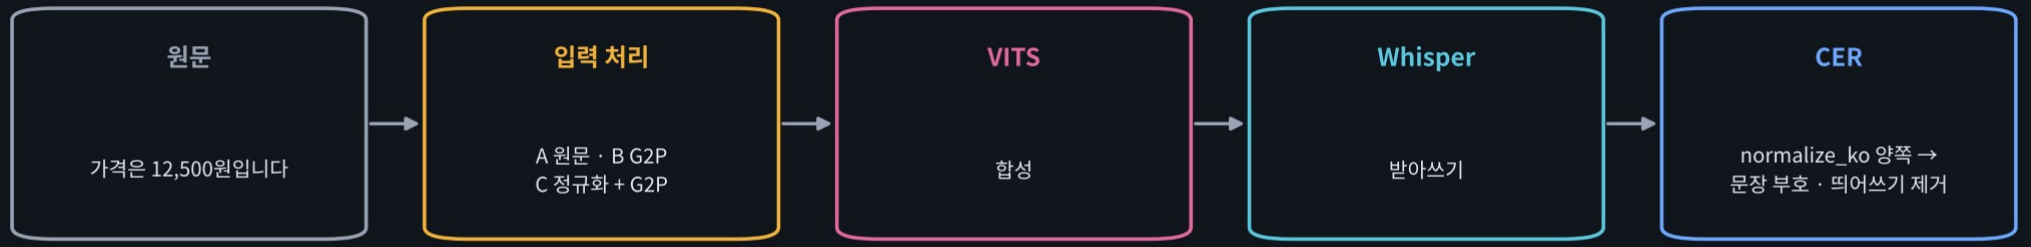
🧩 **빈칸 실습 9**

CAP["log_dur"]

손잡이	효과
speaking_rate ↑	빠르고 짧게
noise_scale = 0	단조롭고 평평
noise_scale ↑	변화 크고 불안정
set_seed	같은 결과 재현

TTS 가 말한 것을 Whisper 가 받아쓰게 한다

ASR 역검증: TTS가 말한 것을 Whisper가 받아쓰게 하고, 원문과 CER로 비교



정답(원문)과 받아쓴 결과에 같은 정규화 → CER이 낮을수록 또박또박 말한 것

잴 수 있는 것: 알아듣기 쉬운가 · 잴 수 없는 것: 자연스러운가(억양 · 감정) → D20 MOS · UTMOS와 함께

방식	예상 평균 CER	이유
A 원문	높음	숫자 · 기호 누락
B G2P	중간	발음 반영 · 숫자 일부
C 정규화 + G2P	가장 낮음	숫자 · 단위 · 약어까지

▶ 애니메이션 D16-9 ASR 역검증

알아듣기 쉬움 ≠ 자연스러움

잴 수 있는 것	잴 수 없는 것	보완
또박또박 말했나 (CER)	억양 · 감정 · 듣기 좋음	사람 평가 MOS · 자동 UTMOS (D20)
숫자 · 용어를 빠뜨렸나	ASR 자체 오류와 섞임	여러 ASR · 사람 확인
방식 간 차이	12 문장은 적음	부트스트랩 (D14) · 문장 늘리기

정리 · 오늘 배운 것

TTS 품질의 절반은 모델 앞에서 결정된다

개념	한 줄	코드
정규화	숫자 · 단위 · 약어를 읽는 말로	`normalize_ko()`
자모 · G2P	588 · 28 계산 , 연음 · 경음화 …	`decompose(), G2p()`
mel · duration	프레임 = 샘플 ÷ hop, 기호별 길이 복사	`np.repeat(enc, durations)`
Vocoder	위상 채우기 , 업샘플 곱 = hop	`SpeechT5HifiGan`
VITS	인코더 + duration + flow + HiFi-GAN	`VitsModel, speaking_rate`
역검증	받아써서 CER, 같은 정규화	`jiwer.cer(for_cer(...))`

D17 경량 TTS: Kokoro

- ☐ TTS 4 단계와 End-to-end 를 설명할 수 있다
- ☐ 숫자를 한자어 · 고유어로 읽는 정규화기를 만들었다
- ☐ 자모 분해와 연음을 구현하고 g2pk2 와 비교했다
- ☐ mel 프레임 · duration · length regulator 를 계산했다
- ☐ Griffin-Lim 과 HiFi-GAN 을 들어 비교했다
- ☐ VITS 로 합성하고 ASR 역검증으로 A · B · C 를 비교했다

다음 : D17 Kokoro

8,200 만 파라미터의 가벼운 TTS 로 CPU 에서도 실시간 합성 . 설치 · 추론 · 음성 스타일 선택 , 그리고 오늘 배운 음소 입력 · duration · Vocoder 가 Kokoro 안에서 어떻게 쓰이는지 찾아봅니다 .

worksheet.html	40 문항
개념 워크시트 · 노션 제출	
animation.html	9 개 탭
인터랙티브 애니메이션	
D16_TTS 원리 _ 실습 .ipynb	빈칸 9
실습 노트북 · T4	

온라인 자료 imguru-mooc.github.io/AI_Voice/day16