음성 AI 전문가 과정 · Day 18 / 40

# Day 18

## 표현형 TTS
## 같은 문장을 다른 말투로

운율 4 요소 · 제어 4 방식 → Chatterbox(exaggeration · CFG · 참고 음성 ) → F5-TTS(flow matching · 길이 식 ) → 같은 조건 비교 · 워터마크
4 주차 M4 · 4 시간 · T4 GPU 필수 · 실습 노트북 Part 0 ~ 7

```
text   드디어 합격했어요 !
model.generate(text, language_id="ko",
               exaggeration=0.25 → 1.0)

음높이 폭  … 반음  →  … 반음
음절 / 초  …       →  …

워터마크  Chatterbox 1.0 · F5-TTS 0.0
```

출력 모양 예시 · 숫자는 각자 실행 결과

0.0 · 오늘 답할 질문

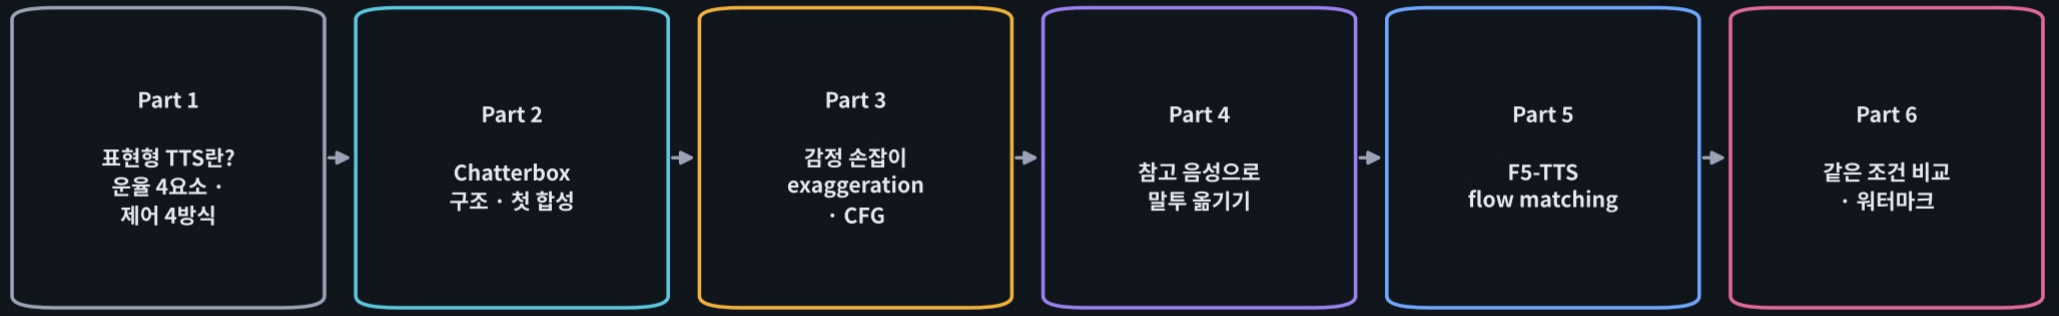
# 말투는 어떻게 조절하고 , 어떻게 재나

| | | |
|---|---|---|
| 1 | 운율은 무엇으로 이루어지고 , 말투를 조절하는 방법은 몇 가지인가 ? | Part 1 |
| 2 | Chatterbox 는 어떤 순서로 글자를 소리로 바꾸나 ? 한국어 숫자는 ? | Part 2 |
| 3 | exaggeration 과 cfg_weight 는 모델 안 어디에서 무엇을 하나 ? | Part 3 |
| 4 | 말투가 바뀐 것을 숫자 ( 반음 · 음절 / 초 ) 로 어떻게 재나 ? | Part 3 |
| 5 | 참고 음성은 무엇을 옮기고 , 무엇을 조심해야 하나 ? | Part 4 |
| 6 | F5-TTS 는 길이를 어떻게 정하고 , 두 모델은 어떻게 비교하나 ? | Part 5 ~ 6 |

▶ 애니메이션 D18-1 오늘의 흐름

# 조절하고 → 재고 → 비교한다

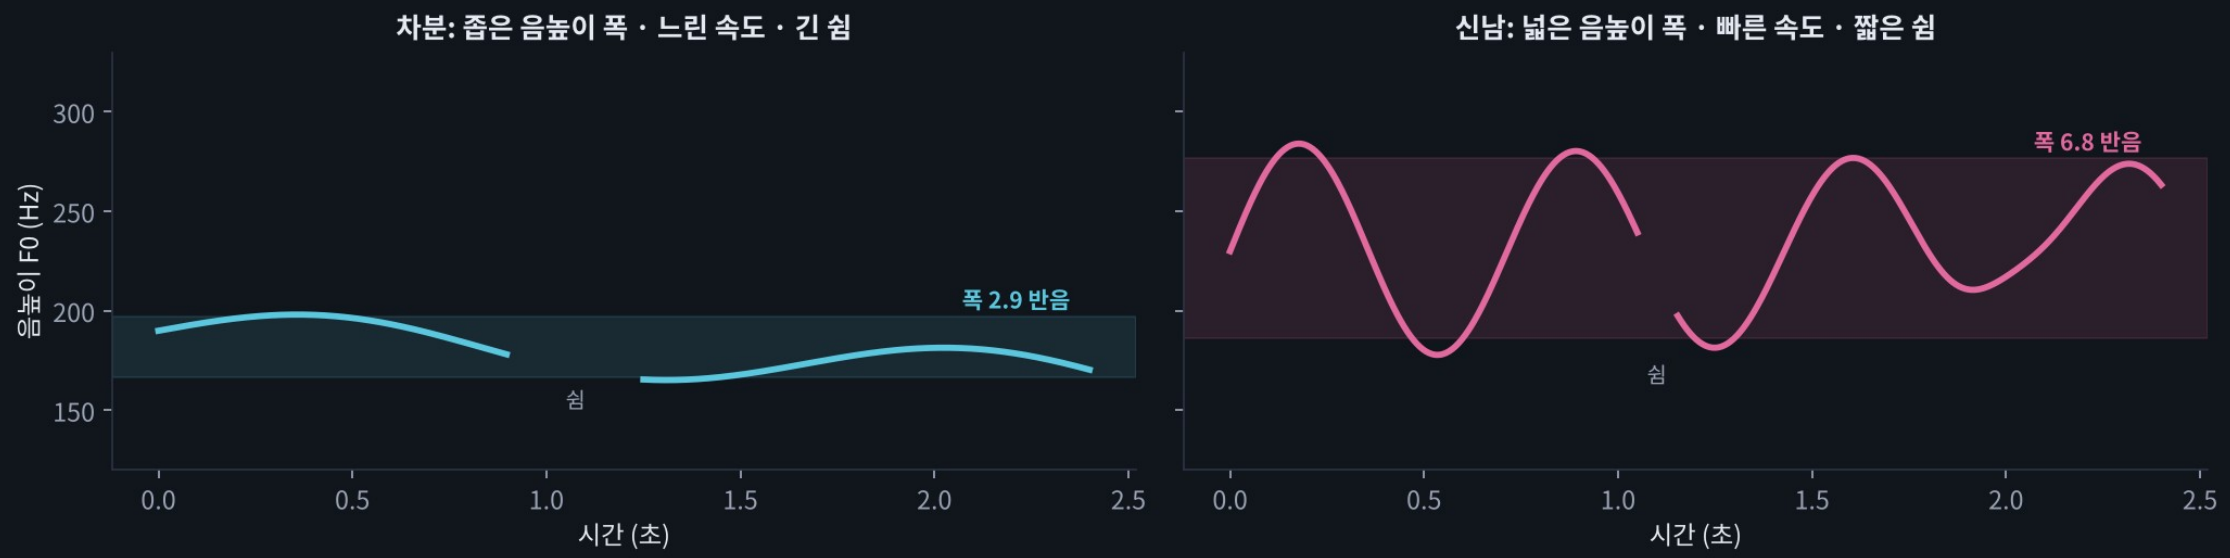
**D18 · 같은 문장을 다른 말투로: 감정 · 억양을 조절하는 TTS**




Chatterbox Multilingual V3 (MIT · 23개 언어 · 한국어 ✓) · F5-TTS v1 (가중치 CC BY-NC) · CosyVoice 3 (Apache 2.0) 비교 · T4 GPU 권장

| 교시 | 내용 | 실습 |
|---|---|---|
| 1 교시 | 운율 4 요소 · 제어 4 방식 , 설치 , Chatterbox 구조 · 첫 합성 , 숫자 정규화 | Part 0 ~ 2 · 빈칸 1 · 2 |
| 2 교시 | exaggeration · CFG, 운율 측정 ( 반음 · 음절 / 초 ), 프리셋 , 문장 부호 | Part 3 · 빈칸 3 · 4 · 5 |
| 3 교시 | 참고 음성으로 말투 옮기기 · 언어 섞임 , F5-TTS · 길이 식 · nfe_step | Part 4 ~ 5 · 빈칸 6 · 7 · 8 |
| 4 교시 | 같은 조건 비교 (RTF · WER · 화자 유사도 · 워터마크 ), 모델 선택 , 정리 | Part 6 ~ 7 · 빈칸 9 · 노션 |

# 높이 · 세기 · 빠르기 · 쉼



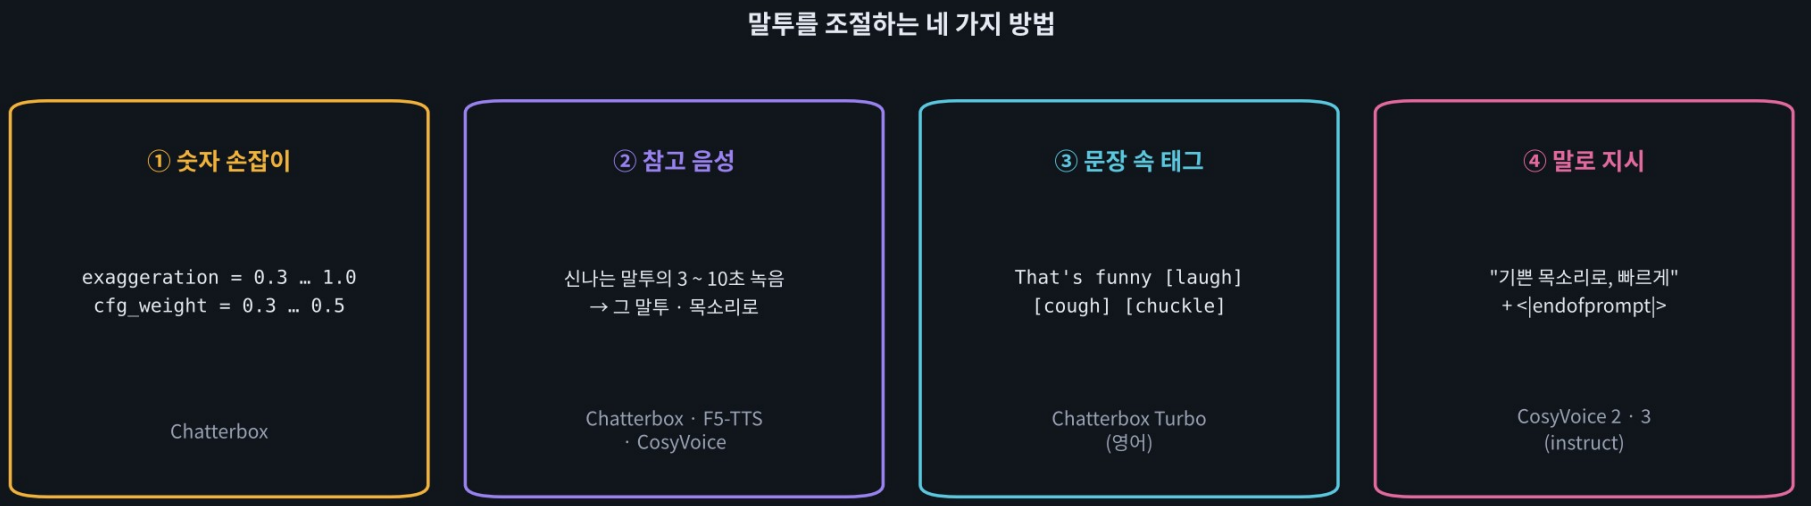

운율(prosody) 4요소: 높이(F0) · 세기(energy) · 빠르기(rate) · 쉼(pause) — 그림용 가상 곡선

| 요소 | 소리에서 | 오늘 재는 숫자 |
|---|---|---|
| 높이 | F0 (Hz) | 중앙값 · 음높이 폭 ( 반음 ) |
| 세기 | 소리 크기 | 세기 변화 (dB 표준편차 ) |
| 빠르기 | 초당 음절 | 음절 / 초 |
| 쉼 | 말 사이 침묵 | 무음 비율 |

**🍎 같은 대본 , 다른 배우**

대본 ( 글자 ) 은 같아도 연기 ( 운율 ) 에 따라 뜻이 달라진다 .

# 숫자 · 참고 음성 · 태그 · 말로 지시

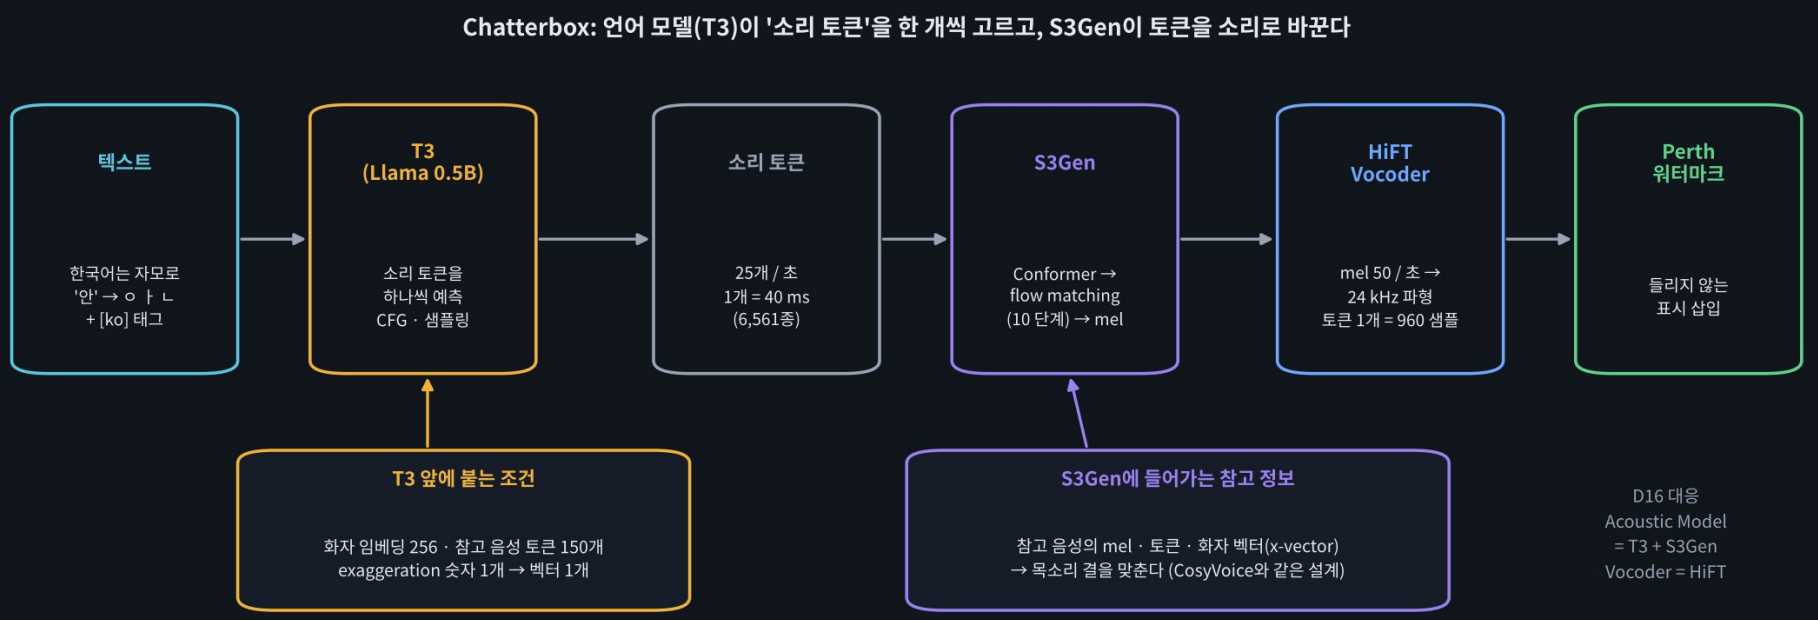



오늘 직접 해 보는 것: ① · ② (Chatterbox, F5-TTS) · ③ · ④는 표와 애니메이션으로 비교

| 용도 | 어울리는 조합 |
|---|---|
| 콜센터 안내 | ① 낮은 exaggeration 프리셋 + 결과 캐시 |
| 오디오북 | ② 장면별 참고 음성 + ① 미세 조정 |
| 게임 캐릭터 | ② 캐릭터 목소리 + ③ 태그 ( 웃음 · 한숨 ) |

▶ 애니메이션 D18-2 말투 조절 4방식

# 소리 길이 ( 샘플 ) ≈ 소리 토큰 수 × 960




| D16 단계 | Chatterbox | Kokoro (D17) |
|---|---|---|
| 정규화 + G2P | 부호 정리 + 자모 분해 ( 숫자 읽기 없음 ) | misaki |
| Acoustic Model | T3 ( 토큰 하나씩 ) + S3Gen | Predictor + Decoder |
| 길이 결정 | [STOP] ( 자기회귀 ) | pred_dur ( 한 번에 ) |

▶ 애니메이션 D18-3 Chatterbox 해부

# 큰 모델도 숫자 읽기는 앞 처리가 필요하다

```
model = ChatterboxMultilingualTTS.from_pretrained(
            device=DEVICE, t3_model="v3")
wav = model.generate(TEXT1, language_id=____)   # 빈칸 1
SAMPLES_PER_TOKEN = SR // ____                  # 빈칸 2
# len(wav) == (토큰 수 - 1) × 960
```

**🧩 빈칸 실습 1·2**

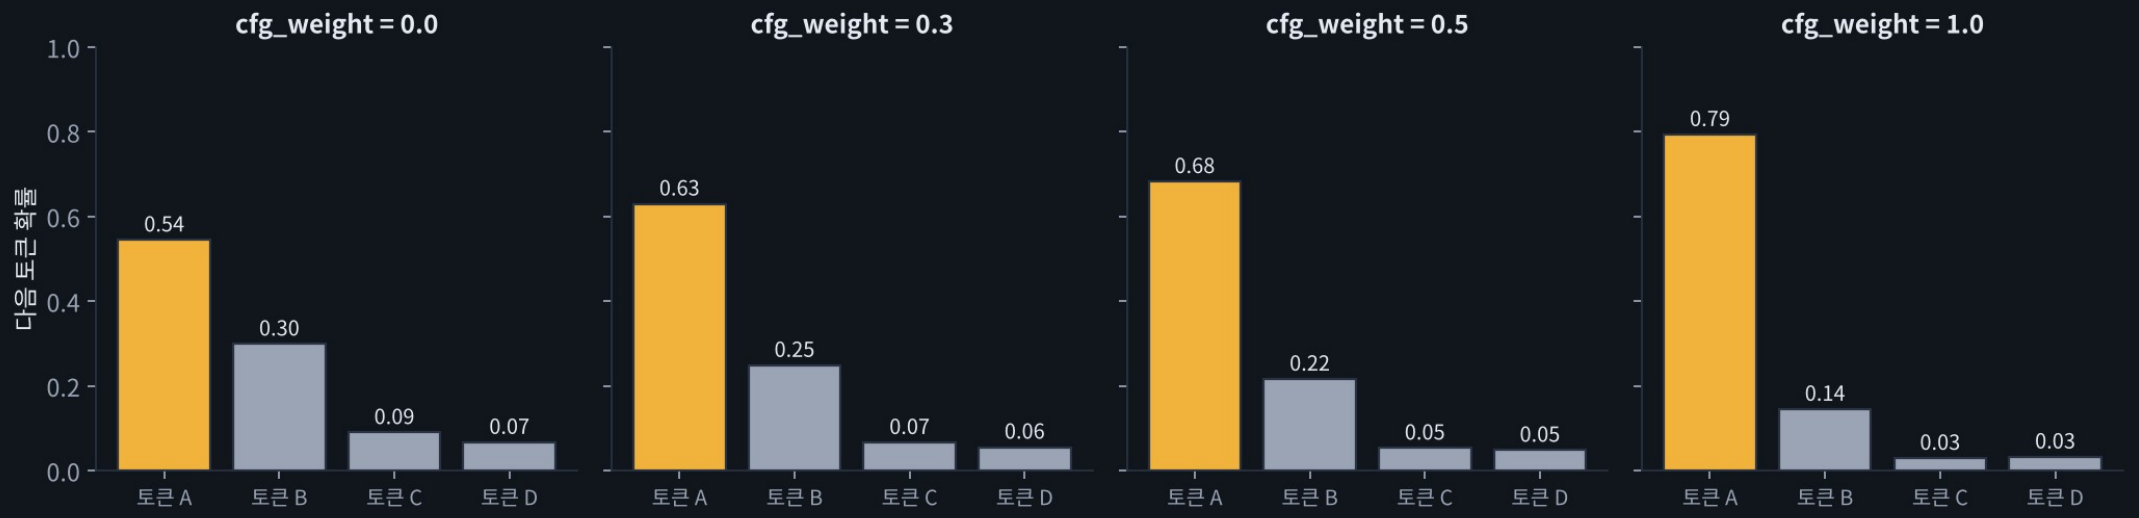
빈칸 1 → "ko"

빈칸 2 → S3_TOKEN_RATE (25)

| 입력 | 모델이 받는 것 | 결과 |
|---|---|---|
| 3 시에 만나요 | [ko] 3 ㅅ ㅣ ㅇ ㅔ … (숫자 그대로) | 삼 시 · 쓰리 시 · 건너뛰기 등 모델 추측 |
| 세 시에 만나요 (normalize_ko) | [ko] ㅅ ㅔ ㅅ ㅣ ㅇ ㅔ … | 대체로 바르게 읽음 → CER ↓ |

**이후 모든 한국어 실험은 normalize_ko 를 거친 문장을 쓴다**

# logits = cond + w · (cond – uncond)




logits = cond + w · (cond – uncond) · cond = 글자를 본 예측, uncond = 글자를 가린 예측 → w가 클수록 '글자를 따르는' 쪽이 더 강해짐

| 상황 (README 팁) | exaggeration | cfg_weight |
|---|---|---|
| 대부분의 문장 | 0.5 | 0.5 |
| 극적 · 표현력 | 0.7 이상 | 약 0.3 |
| 참고 화자가 말이 빠름 | — | 약 0.3 |
| 참고 음성 언어 ≠ 합성 언어 | — | 0 |

**🍎 가이드 멜로디 볼륨**

cfg_weight ↑ = 가이드 멜로디를 크게 .
정확하지만 개성 ↓

# 반음 = 12 · $\log_2$(f0 ÷ 중앙값)

```
def cfg_mix(cond, uncond, w):
    return cond + w * (____)            # 빈칸 3
```

```
f0, voiced, _ = librosa.pyin(y16, fmin=65, fmax=500, sr=16000, ...)
st = 12 * np.log2(f0v / np.median(____))   # 빈칸 4
음높이폭 = p90(st) − p10(st)
```

**🧩 빈칸 실습 3·4**

빈칸 3 → cond - uncond

빈칸 4 → f0v

| w | P(토큰 A) |
|---|---|
| 0.0 | 0.54 |
| 0.3 | 0.63 |
| 0.5 | 0.68 |
| 1.0 | 0.79 |

▶ 애니메이션 D18-8 운율 측정기

▶ 애니메이션 D18-4 CFG 계산기

# exaggeration 은 감정의 크기 , 종류가 아니다

| exaggeration | 음높이 폭 | 음절 / 초 | 세기 변화 |
|---|---|---|---|
| 0.25 | 작음 | 느림 | 작음 |
| 0.5 | ↑ | ↑ | ↑ |
| 0.75 | ↑ | ↑ | ↑ |
| 1.0 | 큼 | 빠름 | 큼 |

경향 ( 실제 숫자는 각자 실행 결과 )

**감정 종류는 문장 내용 · 참고 음성 · 지시로 정한다**

```
PRESETS = {
  "차분": dict(exaggeration=0.3, cfg_weight=0.5),
  "기본": dict(exaggeration=0.5, cfg_weight=0.5),
  "극적": dict(exaggeration=0.8, cfg_weight=____),
}
```

**🧩 빈칸 실습 5**

빈칸 5 → 0.3 (exaggeration ↑ 하면 말이 빨라짐 → cfg ↓)

# 마침표 · 물음표 · 느낌표가 억양을 바꾼다

| 문장 | 끝 0.6 초 ( 반음 ) | 들리는 느낌 |
|---|---|---|
| 내일 다시 오신다고요 . | 내려감 (−) | 확인 · 평서 |
| 내일 다시 오신다고요 ? | 올라감 (+) | 되묻기 · 의문 |
| 내일 다시 오신다고요 ! | 전체 높고 강함 | 놀람 · 강조 |

경향 ( 실행마다 다름 )

**TTS 앞 처리에서 문장 부호를 지우면 억양도 사라진다**

🍎 **대본의 지시**

문장 부호는 배우에게 주는 가장 작은 연기 지시 .
모델은 이것을 학습 데이터에서 배웠다 .

# 참고 음성은 목소리와 말투를 함께 옮긴다

```
BUILTIN = copy.deepcopy(model.conds)
def styled(text, ref_path=None, **kw):
    if ref_path is None:
        model.conds = copy.deepcopy(BUILTIN) ...
    return model.generate(text, language_id="ko",
        audio_prompt_path=____, **kw)      # 빈칸 6
```

**🧩 빈칸 실습 6**

빈칸 6 → ref_path

| 참고 음성에서 | 쓰이는 곳 |
|---|---|
| 앞 6 초 → 토큰 ⩽ 150 | T3 ( 말투 · 빠르기 ) |
| 앞 10 초 → mel · x-vector | S3Gen ( 목소리 결 ) |
| 전체 → 임베딩 256 | T3 ( 화자 ) |

| 조건 (exaggeration 0.5 동일 ) | 결과 경향 |
|---|---|
| 기본 목소리 | 기준 |
| 차분한 참고 음성 | 음높이 폭 ↓ · 느림 |
| 신나는 참고 음성 | 음높이 폭 ↑ · 빠름 |

▶ 애니메이션 D18-5 참고 음성 → 조건

# 억양 섞임 → cfg_weight = 0

| cfg_weight | 들리는 느낌 | 받아쓰기 |
|---|---|---|
| 0.5 ( 기본 ) | 영어식 리듬 · 억양이 묻어날 수 있음 | 평균 CER … |
| 0.0 | 한국어 억양이 더 자연스러운 경향 | 평균 CER … |

문장 2 개라 CER 차이는 작거나 반대로 나올 수 있음

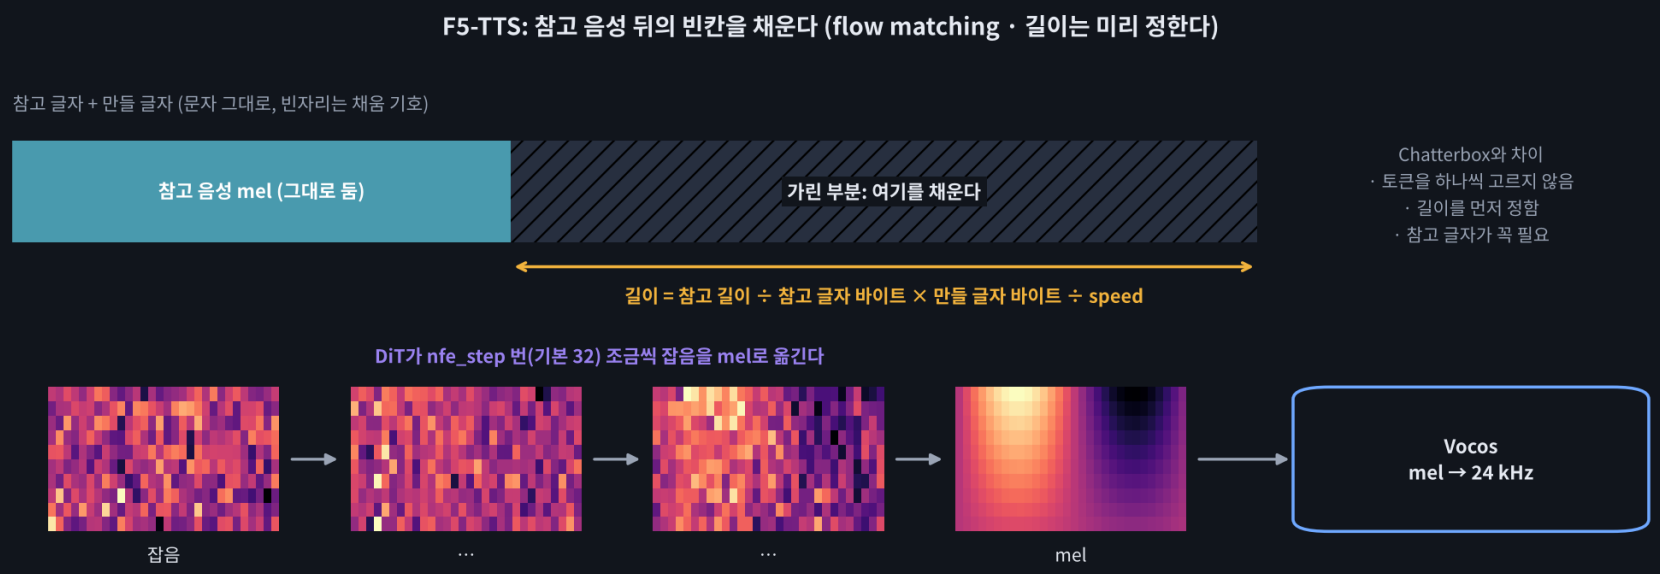
**cfg_weight 는 음색이 아니라 글자 따르기 · 말 빠르기에 작용**

**⚠ 오늘 참고 음성 규칙**

모델이 만든 소리 · 공개 예제 파일 · 본인 목소리만 .
다른 사람 목소리는 동의 없이는 금지 .

동의 절차와 탐지 기술은 D19.

# 참고 mel 뒤의 빈칸을 32 번 다듬어 채운다



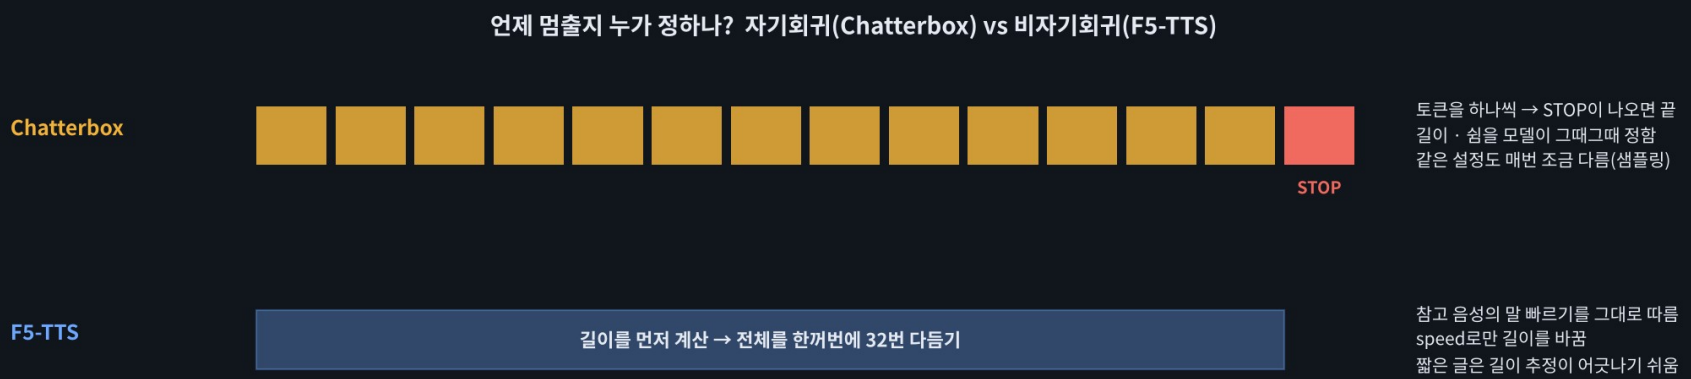

```
F5_REF_TEXT = ____                              # 빈칸 7
wav, sr, spec = f5.infer(ref_file=REF_EN, ref_text=F5_REF_TEXT,
                         gen_text=GEN_EN, nfe_step=32)
```

**🧩 빈칸 실습 7**

빈칸 7 → REF_EN_TEXT

"Some call me nature, others call me mother nature."

# 길이 = 참고 초 ÷ 참고 바이트 × 만들 바이트 ÷ speed




```
per_byte = REF_SEC / len(ref_text_proc.encode("utf-8"))
return per_byte * len(gen_text.encode("utf-8")) / ____   # 빈칸 8
```

**🧩 빈칸 실습 8**

빈칸 8 → speed

예 : 5 초 ÷ 50 × 100 ÷ 1 = 10 초

▶ 애니메이션 D18-6 F5 길이 · 다듬기

▶ 애니메이션 D18-9 AR vs NAR

# 같은 문장 · 같은 참고 음성 · 네 가지 지표

| 지표 | 계산 | 좋은 방향 |
|---|---|---|
| RTF | 생성 시간 ÷ 소리 길이 | 작을수록 |
| WER | Whisper 받아쓰기 vs 원문 | 작을수록 |
| 화자 유사도 | 화자 임베딩 코사인 | 1에 가까울수록 |
| 워터마크 | WM.get_watermark(y, sample_rate=sr) | 생성물이면 1 |

**문장 1개 · 씨앗 1개로는 순위를 확정할 수 없다 → 재는 틀을 만든 것**

```
WM = perth.PerthImplicitWatermarker()
float(WM.____(y, sample_rate=sr))
#             빈칸 9
```

🧩 **빈칸 실습 9**

빈칸 9 → get_watermark

▶ 애니메이션 D18-7 모델 비교판

# 들리지 않는 숨은 표시

| 소리 | 워터마크 점수 | 해석 |
|---|---|---|
| Chatterbox 결과 | ≈ 1.0 | Perth 표시 있음 |
| F5-TTS 결과 | ≈ 0.0 | 표시 없음 (AI 생성이지만) |
| 참고 음성 (사람) | ≈ 0.0 | 표시 없음 |

**워터마크는 AI 생성 확인 방법 중 하나일 뿐, 없다 ≠ 사람**

**🍎 지폐의 숨은 그림**

눈(귀)으로는 안 보이지만 검출기로 비추면 보인다.
없다고 위조가 아닌 것은 아니다.

# 라이선스 → 언어 → 제어 방식 → 지연 → 안전장치 → 역검증

| | Chatterbox ML V3 | Chatterbox Turbo | F5-TTS v1 | CosyVoice 3 | Kokoro |
|---|---|---|---|---|---|
| 한국어 | ✅ 23 개 언어 | ❌ 영어 | △ 영 · 중 위주 | ✅ 9 개 언어 | ❌ |
| 말투 조절 | exaggeration · cfg · 참고 | 태그 [laugh] 등 | 참고 · speed | 말로 지시 · 참고 | 섞기 · speed |
| 참고 대본 | 불필요 | 불필요 | 필요 | 필요 | — |
| 워터마크 | Perth | Perth | 없음 | 없음 | 없음 |
| 라이선스 | MIT | MIT | 가중치 CC BY-NC | Apache 2.0 | Apache 2.0 |
| 설치 | pip ( 오늘 ) | pip | pip | 전용 환경 | pip |

**한국어 상업 서비스 → F5 기본 가중치 · Turbo · Kokoro 제외 → 남는 후보를 내 문장으로 역검증**

# 말투는 조절하고 , 조절한 결과는 잰다

| 개념 | 한 줄 | 코드 |
|---|---|---|
| Chatterbox | T3 → 토큰 (25/ 초 ) → S3Gen → HiFT → 워터마크 | `generate(text, language_id="ko")` |
| 숫자 정규화 | 큰 모델도 숫자는 앞 처리 | `normalize_ko(s)` |
| exaggeration · CFG | 감정 크기 벡터 · 글자 방향 w 배 | `cond + w * (cond - uncond)` |
| 운율 측정 | 반음 폭 · 음절 / 초 | `12 * log2(f0v / median(f0v))` |
| 참고 음성 | 목소리 · 말투 옮김 , conds 되돌리기 | `audio_prompt_path=ref_path` |
| F5-TTS | 빈칸 채우기 , 길이는 계산 | `per_byte * bytes / speed` |
| 비교 · 워터마크 | RTF · WER · 유사도 · 워터마크 | `WM.get_watermark(y, sample_rate=sr)` |

# D19 Voice Cloning & AI 윤리

- ☐ 운율 4 요소와 말투 조절 4 방식을 구분할 수 있다
- ☐ Chatterbox 로 한국어를 합성하고 숫자를 정규화했다
- ☐ exaggeration · CFG 를 바꾸며 운율을 숫자로 쟀다
- ☐ 참고 음성으로 말투를 옮기고 조건을 되돌렸다
- ☐ F5-TTS 의 길이 식을 확인했다
- ☐ 같은 조건으로 비교하고 워터마크를 검출했다

**다음 : D19 Voice Cloning & 윤리**

몇 초의 녹음으로 목소리를 복제하는 zero-shot cloning 을 직접 해 보고, 딥페이크 · 보이스피싱 위험, 동의 절차 설계, 오늘 본 Perth 워터마크가 압축 · 잡음에 얼마나 버티는지 실험합니다.

| worksheet.html | 40 문항 |
| --- | --- |
| 개념 워크시트 · 노션 제출 | |

| animation.html | 9 개 탭 |
| --- | --- |
| 인터랙티브 애니메이션 | |

| D18_표현형 TTS_실습.ipynb | 빈칸 9 |
| --- | --- |
| 실습 노트북 · T4 | |

온라인 자료 imguru-mooc.github.io/AI_Voice/day18