음성 AI 전문가 과정 · Day 20 / 40

Day 20

TTS 평가 + 미니 프로젝트
재고 → 만들고 → 보여 준다

```
SUMMARY  ( 시스템별 평균 )
     MOS ± 반폭   UTMOS    CER   RTF
  A   4.0 ±0.4    x.xx   0.0x   0.x
  B   3.8 ±0.4    x.xx   0.0x   0.x
  C   3.0 ±0.4    x.xx   0.1x   0.0x

TTFA   통째로 8.x 초 → 문장마다 2.x 초
audiobook  -18.0 LUFS · 피크 -1.0 · 워터마크 1
```

출력 모양 예시 · 숫자는 각자 실행 결과

평가 지표 지도 → MOS 청취 평가 · 신뢰구간 → UTMOS · ASR 역검증 → Streaming TTFA → 오디오북 · 안내방송 생성기 → 리포트 · 3 분 발표
4 주차 M4 마무리 · 4 시간 · T4 GPU · 실습 노트북 Part 0 ~ 7

0.0 · 오늘 답할 질문

" 어느 TTS 가 더 좋아요 ?" 에 숫자로 답하기

1	TTS 품질은 무엇으로 재나 ? 하나의 숫자로 충분한가 ?	Part 1
2	사람 평가 (MOS) 는 어떻게 하고 , 차이가 " 확실한지 " 어떻게 아나 ?	Part 2
3	자동 지표 (UTMOS) 는 믿을 만한가 ? 원고대로 읽었는지는 ?	Part 3
4	사용자는 첫 소리를 얼마나 기다리나 ? 끊김은 언제 생기나 ?	Part 4
5	원고 한 장을 방송용 파일 · 자막으로 만들려면 무엇이 필요한가 ?	Part 5
6	결과를 어떻게 판정하고 3 분 안에 보여 줄까 ?	Part 6

재고 → 만들고 → 보여 준다

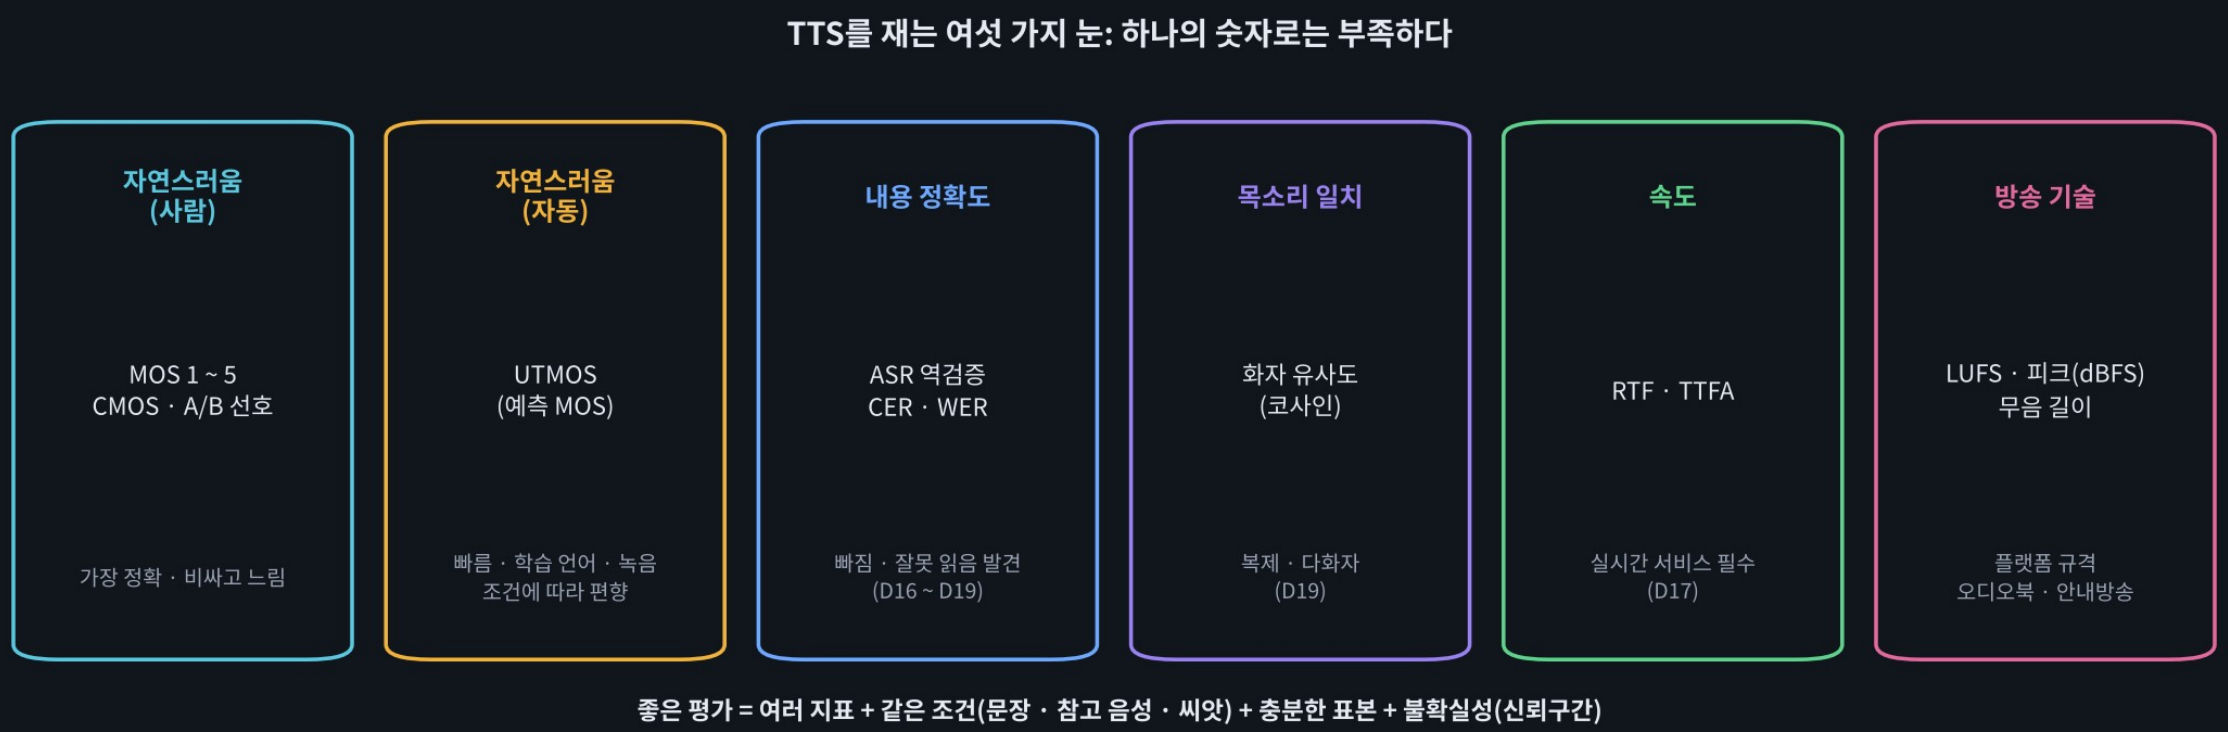
D20 · 4주차 마무리: 재고(평가) → 만들고(생성기) → 보여 준다(리포트 · 발표)



비교 대상: Chatterbox(기본 · 차분) · MMS-TTS 한국어 VITS(D16) · 오늘 만든 생성기는 D19의 고지 · 워터마크를 그대로 붙인다

교시	내용	빈칸	애니메이션
1 교시	Part 0 ~ 2 지표 지도 · MOS 청취 · 신뢰구간	1	D20-1 ~ 3
2 교시	Part 3 ~ 4 UTMOS · CER · Streaming TTFA	2 ~ 4	D20-4 ~ 5
3 교시	Part 5 생성기 (품질 게이트 · 마스터링 · MP3 · SRT)	5 ~ 9	D20-6 ~ 7
4 교시	Part 6 ~ 7 리포트 · 3 분 발표 · 동료 평가 · 회고	—	D20-8 ~ 9

TTS 를 재는 여섯 가지 눈



▶ 애니메이션 D20-2 지표 지도 · 함정 샘플

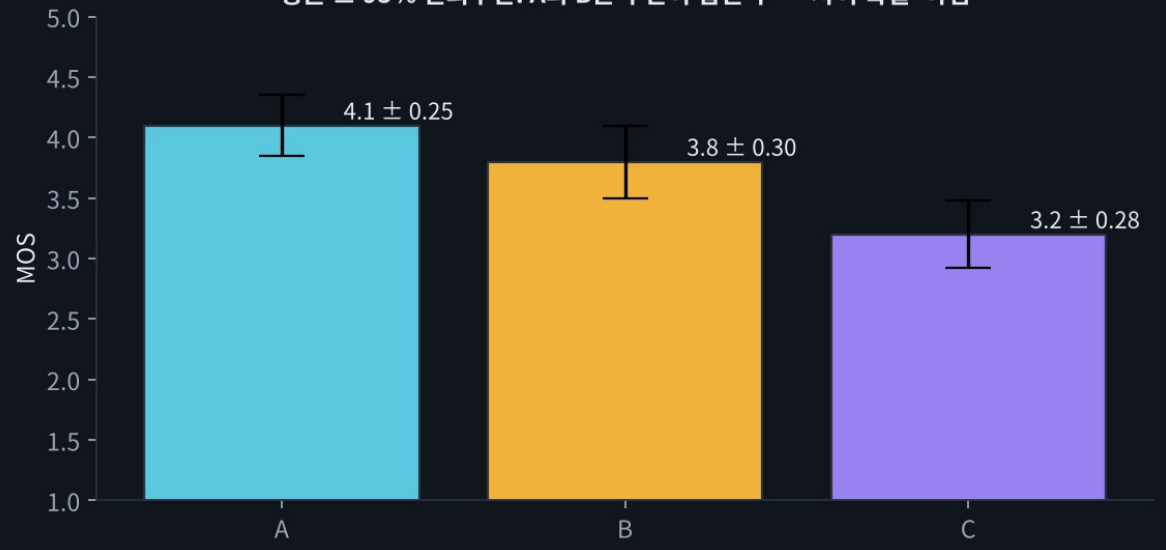
좋은 평가 = 여러 지표 + 같은 조건 + 충분한 표본 + 불확실성

사람 점수 1 ~ 5, 그리고 조건

ACR 5점 척도 (ITU-T P.800 방식)

5	**매우 좋음 (Excellent)**	자연스러운 사람 목소리
4	**좋음 (Good)**	약간 어색하지만 편안
3	**보통 (Fair)**	어색함이 분명, 이해는 됨
2	**나쁨 (Poor)**	듣기 불편
1	**매우 나쁨 (Bad)**	알아듣기 어려움

평균 ± 95% 신뢰구간: A와 B는 구간이 겹친다 → '차이 확실' 아님



그림용 가상 숫자 · 반 = 평가자 n명 · 구간 반폭 = t × 표준편차 ÷ √n

1. 블라인드 : 시스템 이름을 숨김
2. 무작위 순서 : 순서 효과를 고르게
3. 같은 문장 · 같은 이어폰 · 기준 안내

🍎 **블라인드 테스트**

상표를 가리면 순수하게 맛 (소리) 만 평가한다 .

반폭 = t × 표준편차 ÷ √n

```
def mos_ci(scores, conf=0.95):
    x = np.asarray(scores, float); n = len(x)
    m, sd = x.mean(), x.std(ddof=1)
    half = stats.t.ppf((1 + conf) / 2, n - 1) \
           * sd / np.sqrt(____)        # 빈칸 1
    return m, half, m - half, m + half
```

🧩 빈칸 실습 1

빈칸 1 → n (점수 개수)

표준오차 = sd ÷ √n

구간이 겹치면 ?

차이를 확신할 수 없음 → 평가자 늘리기 · 짝 비교 (CMOS · A/B) · 통계 검정

평가자 n	표준편차 0.8 일 때 반폭	해석
5	± 0.99	거의 아무 결론도 못 냄
15	± 0.44	0.2 점 차이는 불확실
60	± 0.21	0.5 점 차이면 분명

▶ 애니메이션 D20-3 MOS 신뢰구간 계산기

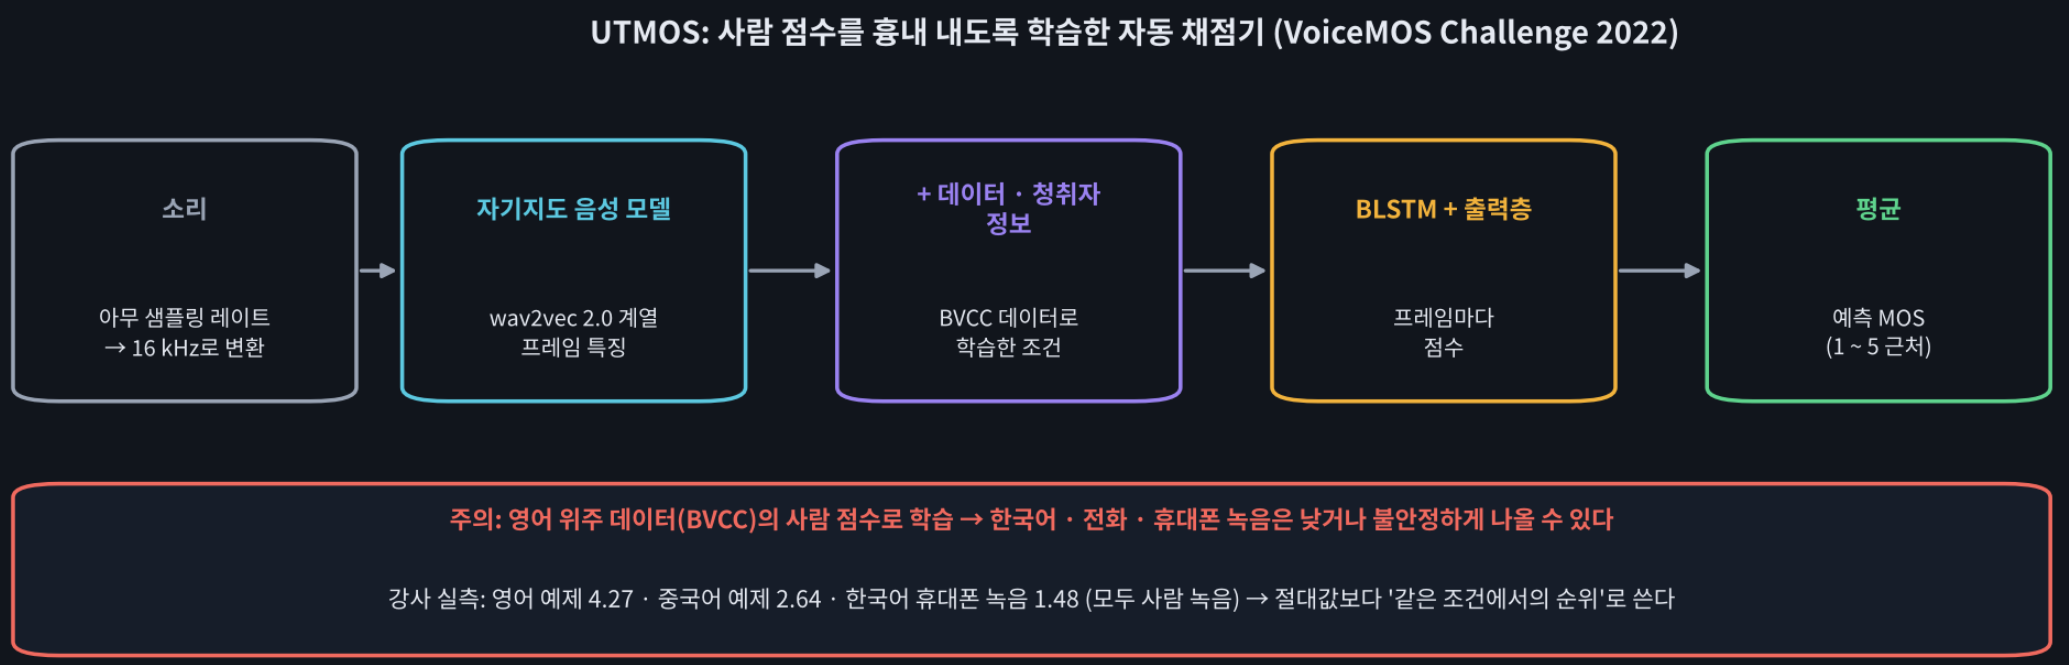
평균 하나가 아니라 " 평균 ± 구간 "

시스템	구성	MOS (예)
A	Chatterbox 기본 (ex 0.5)	4.0 ± 0.4
B	Chatterbox 차분 (ex 0.3)	3.8 ± 0.4
C	MMS-TTS 한국어 VITS (D16)	3.0 ± 0.4

읽는 법
· A vs B: 구간 겹침 → 차이 불확실
· A vs C: 안 겹침 → A 가 분명히 높음
· 내 점수와 반 평균이 다르면 ? 평가자 편차 → 그래서 여러 명

📝 **1 교시 워크시트 → worksheet.html 1 교시 탭 10 문항**

사람 점수를 흉내 낸 자동 채점기




```
utmos = torch.hub.load("tarepan/SpeechMOS:v1.2.0", "utmos22_strong", trust_repo=True)
score = utmos(wave[1, T], ____)      #  빈칸  2 = sr
```

▶ 애니메이션 D20-4 자동 지표 vs 사람

원고대로 읽었나 + 시스템별 평균

1. 합성한 소리를 Whisper 로 받아쓰기
2. 원문 · 받아쓰기 모두 정규화 (숫자 → 한글)
3. CER = 글자 편집 거리 ÷ 원문 글자 수
4. 시스템별 평균 : groupby("system").mean()

```
for s in SAMPLES:
    s["UTMOS"] = utmos_score(s["y"], s["sr"])
    s["CER"] = cer_ko(s["text"], transcribe(...))
SUMMARY = EVAL.groupby("system")[cols]
          .____().round(3)    # 빈칸 3
```

🍎 **대본 보며 받아쓰기 채점**

성우가 읽은 것을 받아 적어 대본과 비교 . 빠뜨린 단어 · 잘못 읽은 숫자가 드러난다 .

🧩 **빈칸 실습 2 · 3**

빈칸 2 → sr · 빈칸 3 → mean

자동 지표로 후보를 거르고 , 마지막은 사람 평가로 확정 → Part 5 품질 게이트

TTFA = ready[0]

```
ready = [첫 조각 준비, 둘째 조각 준비, ...]
TTFA  = ready[____]                # 빈칸 4 = 0
start = TTFA + [0, cumsum(lens[:-1])]
stall = ready > start              # 끊김
```

📐 조각 i 재생 시작
= TTFA + 앞 조각 길이의 합
그보다 늦게 준비되면 끊김

대책
첫 조각 짧게 · 버퍼 0.5 ~ 1초 · 빠른 모델 · GPU

방식	TTFA (T4 예)	사용자 체감
통째로	6 ~ 12 초	한참 침묵
문장마다	1.5 ~ 3 초	곧바로 시작
쉼표 단위 첫 조각	1초 안팎	가장 빠름

▶ 애니메이션 D20-5 스트리밍 타임라인

빠른 자동 지표 , 그리고 체감 속도

지표	잘 잡는 것	놓치는 것	오늘 쓰는 곳
UTMOS	어색함 · 잡음 · 순위	내용 오류 · 한국어 절대값	SUMMARY · 리포트
CER	빠짐 · 숫자 오류	억양 · 감정	품질 게이트
TTFA	체감 대기 시간	품질	D21 지연 예산
MOS	종합 자연스러움	(비쌈 · 느림)	최종 확정

📝 **2 교시 워크시트 → worksheet.html 2 교시 탭 10 문항**

원고 한 장 → 방송용 파일 + 자막 + 리포트

미니 프로젝트: 원고 한 장 → 방송용 소리 파일 + 자막 + 품질 리포트



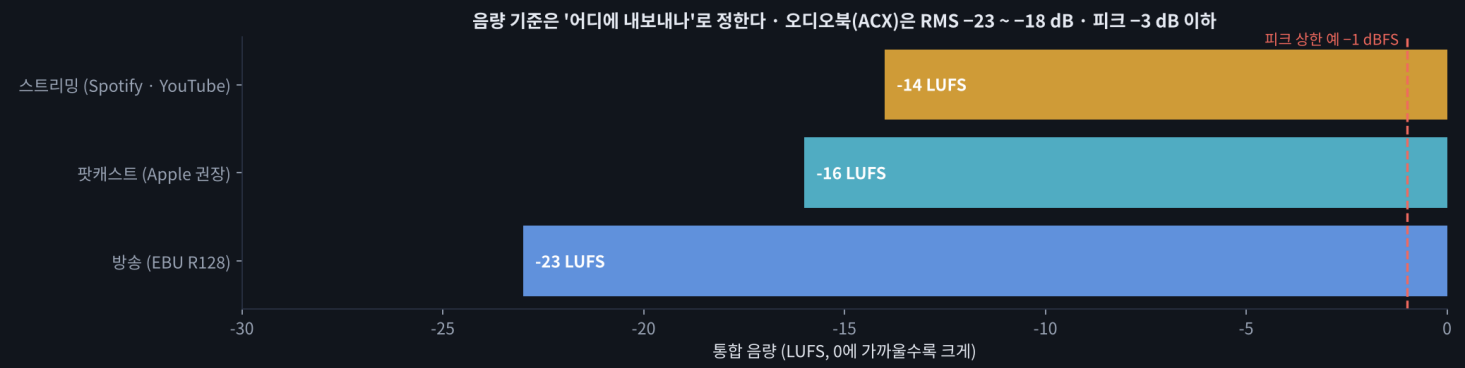
오디오북 모드: 차분 프리셋 · 문장 쉼 0.35초 · 문단 쉼 0.9초 | 안내방송 모드: 딩동댕 차임 → 안내 2번 반복 → 차임

리포트: 문장별 CER · 시도 횟수 · UTMOS · 전체 길이 · RTF · LUFS · 피크

모드	프리셋	쉼 (문장 · 문단)	차임 · 반복	음량
audiobook	ex 0.35	0.35 · 0.9 초	없음 · 1 번	−18 LUFS
announce	ex 0.5	0.5 · 0.8 초	딩동댕 · 2 번	−16 LUFS

▶ 애니메이션 D20-6 생성기 파이프라인

dBFS = 20 · $\log_{10}$(진폭)




```
np.zeros(int(sec * ____))                    # 5 SR
pyln.normalize.loudness(y, cur, ____)        # 6 target_lufs
peak_db = ____ * np.log10(max|y|)            # 7 20
if peak_db > -1: y *= 10 ** ((-1 - peak_db) / 20)
total_ms = int(round(sec * ____))            # 8 1000
→ "01:02:03,456"  (SRT 는 쉼표 )
```

🧩 빈칸 실습 5 ~ 8

5 → SR · 6 → target_lufs

7 → 20 · 8 → 1000

🍎 천장 높이

음량 (평균 키) 을 올려도 머리 (피크) 가 천장 (−1 dBFS) 에 닿으면 안 된다 .

▶ 애니메이션 D20-7 LUFS · 피크 계산기

best = min(cands, key=lambda c: c["cer"])

```
def synth_best(text, cfg, n_try=N_TRY):
    cands = []
    for k in range(n_try):
        y = model.generate(normalize_ko(text), ...)
        cands.append(dict(y=y, cer=cer_ko(text, transcribe(y))))
        if cands[-1]["cer"] <= CER_GATE: break
    best = min(cands, key=lambda c: c[____])  # 9
    return dict(best, tries=len(cands))
```

make_program() 순서

① AI 고지 문구 (D19)
② 차임 (안내방송)
③ 문장마다 synth_best · cache
④ 문장 쉼 · 문단 쉼
⑤ 워터마크 → 마스터링
⑥ 워터마크 확인
⑦ WAV · MP3 · SRT · 리포트

🎧 **오디오북 앞의 " 이 음성은 인공지능으로 만든 음성입니다 " 가 들리는지 확인**

안내방송 · 오디오북을 팀 원고로

결과 열	뜻	확인할 것
CER · 후보 _CER	선택된 후보 · 시도별 오류율	숫자 · 고유명사 문장이 높은지
시도 · 게이트	몇 번 만들었나 · 기준 통과	False 면 원고 나누기 · 숫자 풀어 쓰기
LUFS · 피크 _dBFS	최종 음량 · 최대 순간값	목표 ± 1 LU · ≤ −1 dBFS
워터마크	Perth 확인값	1 이어야 내보냄
자막	SRT 줄 수	고지 1 + 문장 수 (반복 포함)

❓ 10 시간 오디오북을 이 생성기로 만든다면 ?

시간 · 비용 (병렬) · 일관성 (참고 음성 · 씨앗 고정) · 검수 (사람 샘플링) · 권리 (원고 · 목소리 · 플랫폼 AI 낭독 정책)

📝 3 교시 워크시트 → worksheet.html 3 교시 탭 10 문항

목표를 정하고 , 측정으로 판정한다

목표	기준	오디오북	안내방송
게이트 통과율	≥ 0.8	✅	❌
음량	목표 ± 1 LU	✅	✅
피크	≤ −1 dBFS	✅	✅
워터마크	검출 1	✅	✅
평균 CER	≤ 0.10	✅	❌

판정 예시 · 실제 값은 팀마다 다름

▶ 애니메이션 D20-8 목표 판정판

report.md 목차

1. 시스템 비교 (MOS · UTMOS · CER · RTF)
2. 생성기 결과
3. 목표 판정
4. 문장별 품질
5. 한계와 다음 단계

무엇을 · 들려주고 · 근거로 · 다음은

시간	내용
0:00 – 0:30	무엇을 만들었나
0:30 – 1:30	🎧 결과물 15 초 + 자막
1:30 – 2:30	리포트 · 판정 · 실패 문장 원인
2:30 – 3:00	한계 · 다음 단계

평가 항목 (각 5 점)	5 점의 모습
결과물 품질	자연스럽고 원고대로
평가의 근거	여러 지표 + 한계까지
책임 있는 설계	고지 · 워터마크 · 권리
전달력	3 분 안에 핵심

▶ 애니메이션 D20-9 발표 평가표 계산기

D16 ~ D20: 원리 → 빠르게 → 감정 → 책임 → 평가

날	한 줄	오늘 생성기에서
D16 TTS 원리	정규화 · G2P · mel · Vocoder · VITS	normalize_ko · 시스템 C
D17 Kokoro	작은 모델 · CPU 실시간 · 스트리밍	Part 4 TTFA
D18 표현형 TTS	exaggeration · CFG · 참고 음성	모드별 프리셋
D19 복제 · 윤리	동의 · 고지 · 워터마크 · 철회	고지 문구 · 워터마크 확인
D20 평가 · 프로젝트	MOS · UTMOS · CER · LUFS	품질 게이트 · 리포트

여러 지표 · 같은 조건 · 불확실성 → 품질 게이트

개념	한 줄	코드
MOS 신뢰구간	반폭 = t × sd ÷ √n	`sd / np.sqrt(n)`
UTMOS	자동 MOS 예측 · 언어 편향	`utmos(wave, sr)`
비교표	시스템별 평균	`.groupby("system").mean()`
Streaming	TTFA = 첫 조각 준비 시각	`ready[0]`
품질 게이트	재시도 · CER 최소	`min(cands, key=lambda c: c["cer"])`
마스터링	LUFS 맞추기 · 피크 ≤ −1	`loudness(y, cur, target_lufs)`
내보내기	MP3 · SRT · 고지 · 워터마크	`srt_time(sec) · 20 · log10`

과제 · 다음 시간

5 주차 : 귀와 입 사이에 두뇌를

- ☐ TTS 지표 여섯 가지와 각각이 놓치는 것을 말할 수 있다
- ☐ MOS 신뢰구간을 계산하고 구간 겹침을 해석했다
- ☐ UTMOS · CER 로 시스템을 비교하고 한계를 말했다
- ☐ TTFA 와 끊김 조건을 측정했다
- ☐ 품질 게이트 · 마스터링 · 고지 · 워터마크를 갖춘 생성기를 만들었다
- ☐ 리포트로 3 분 발표 · 동료 평가를 했다

다음 : D21 Voice Agent 아키텍처

STT → LLM → TTS(Cascade) 음성 비서와 Speech-to-Speech 모델을 비교하고 , 오늘 잰 TTFA 를 출발점으로 지연 예산 (Latency Budget) 을 설계합니다 .

worksheet.html	40 문항
개념 워크시트 · 노션 제출	
animation.html	9 개 탭
인터랙티브 애니메이션	
D20_TTS 평가 _ 프로젝트 _ 실습 .ipynb	빈칸 9
실습 노트북 · T4	

온라인 자료 imguru-mooc.github.io/AI_Voice/day20