Day 22

LLM API 연동
Claude · OpenAI · Gemini · 음성 프롬프트 · 대화 이력

API 공통 구조 · 키 → 하나의 함수 ask() → TTFT · 비용 비교 → 음성용 프롬프트 자동 점검 → 대화 이력 (창 · 요약 · 끊김) → 음성 루프 3 턴
5 주차 M5 · 4 시간 · T4 GPU · API 키 선택 (없으면 로컬 Qwen3)

```
ask("claude", VOICE, msgs)
  ttft 0.3 s · 28 tok · $0.00002
ask("gemini", VOICE, msgs)
  ⚠ 옵션 거부 → 빼고 재시도

통과율 기본 0.0 → 음성 v2 1.0
턴 3: "회의는 내일 오후 3 시예요 ."
```

출력 모양 예시 · 숫자는 각자 실행 결과

0.0 · 오늘 답할 질문

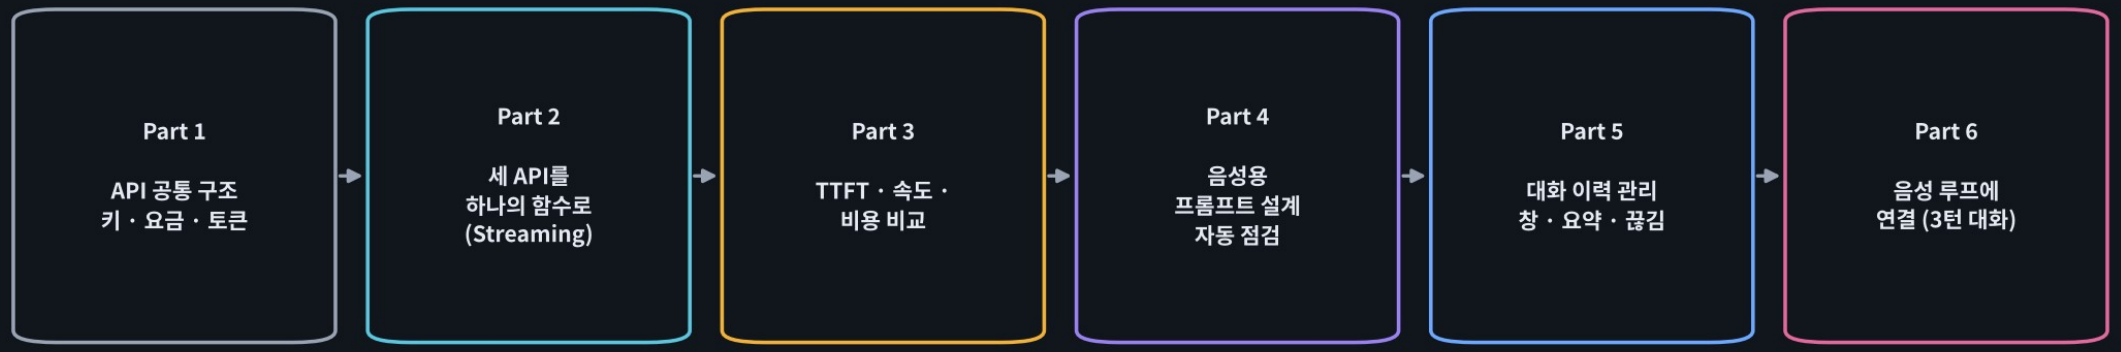
두뇌를 키우고 , 기억을 붙인다

1	세 회사의 LLM API 는 무엇이 같고 무엇이 다른가 ? 키는 어떻게 다루나 ?	Part 1
2	세 API 를 같은 코드로 부르려면 ?	Part 2
3	어느 API 가 빠르고 싼가 ? 어떻게 공정하게 재나 ?	Part 3
4	귀로 듣는 답은 어떻게 만들고 , 어떻게 점검하나 ?	Part 4
5	LLM 은 어떻게 앞 대화를 " 기억 " 하나 ? 길어지면 ?	Part 5
6	음성 루프에서 이어지는 대화를 하려면 ?	Part 6

0.0 · 오늘의 흐름

키가 없어도 모든 셀이 돈다

D22 · 두뇌를 키운다: 로컬 소형 LLM → 상용 LLM API (Claude · OpenAI · Gemini)



API 키가 하나도 없어도 로컬 Qwen3(D21)로 모든 셀이 돌아갑니다 · 키가 있는 API만 자동으로 비교에 들어갑니다

교시	내용	빈칸	애니메이션
1 교시	Part 0 ~ 2 API 구조 · 키 · ask()	1 ~ 3	D22-1 · 2 · 3
2 교시	Part 3 TTFT · 속도 · 비용 · 생각 모드	4 · 5	D22-4 · 8
3 교시	Part 4 ~ 5 음성 프롬프트 · 대화 이력	6 ~ 8	D22-5 · 6 · 7
4 교시	Part 6 ~ 7 음성 루프 3 턴 · 정리	9	D22-9

모델 · 시스템 지시 · 대화 목록 · 길이 상한 · Streaming

세 API의 요청은 거의 같다: 모델 · 시스템 지시 · 대화 목록 · 길이 상한 · Streaming

Claude (Anthropic)

```
client.messages.stream(
  model="claude-haiku-5-5",
  system=시스템 지시,
  messages=[user, assistant, …],
  max_tokens=300)
→ stream.text_stream
역할: user / assistant
```

OpenAI (Responses API)

```
client.responses.create(
  model="gpt-6-luna",
  instructions=시스템 지시,
  input=[user, assistant, …],
  max_output_tokens=300, stream=True)
→ response.output_text.delta
역할: user / assistant
```

Gemini (google-genai)

```
client.models.generate_content_stream(
  model="gemini-3.5-flash-lite",
  contents=[user, model, …],
  config=GenerateContentConfig(
    system_instruction=시스템 지시,
    max_output_tokens=300))
역할: user / model (주의)
```

모델 이름은 자주 바뀜(2026년 10월 기준 예) · 키는 Colab 보안 비밀(Secrets)에 · 요금 = 입력 토큰 × 입력 단가 + 출력 토큰 × 출력 단가

▶ 애니메이션 D22-2 세 API 요청 · 응답 비교

🍎 세 나라 택배 회사

송장 칸 이름만 다르다 → 송장 변환기 하나 (ask) 로 어디든 보낸다 .

키는 집 열쇠 · 요금은 글자 수 전보

하면 안 됨	이렇게
코드에 api_key="sk-..."	Colab 보안 비밀 · 환경 변수
print(키) · 캡처 제출	" 키 있음 / 없음 " 만 출력
깃허브 커밋	.env + .gitignore
브라우저 JS 에 키	서버가 대신 호출 (D31)
한도 없는 결제 키	프로젝트별 키 · 월 한도

📐 요금

(입력 토큰 × 입력 단가
+ 출력 토큰 × 출력 단가) ÷ 1,000,000

단가 = 100 만 토큰당 USD (예 : 0.10 / 0.50)

▶ 애니메이션 D22-9 API 키 안전 점검

이벤트를 글 조각 generator 로 맞춘다

API	글 조각	토큰 수
Claude	`stream.text_stream`	`get_final_message().usage`
OpenAI	`type == "response.output_text.delta" → .delta`	`response.completed → .response.usage`
Gemini	`chunk.text`	마지막 `chunk.usage_metadata`

1. 요청 전송 (stream)
2. 시작 이벤트
3. 글 조각 이벤트 여러 개 → 첫 글자 = TTFT
4. 끝 이벤트 (멈춘 이유 · 토큰 수)

▶ 애니메이션 D22-3 Streaming 이벤트 흐름

text_stream · delta · model

```
with client.messages.stream(model=..., system=sys,
        messages=msgs, max_tokens=n) as s:
    for text in s.____: yield text        # 1

for ev in client.responses.create(instructions=sys,
        input=msgs, stream=True, ...):
    if ev.type == "response.output_text.____":  # 2
        yield ev.delta

{"role": "____" if m["role"] == "assistant"  # 3
         else "user", "parts": [{"text": ...}]}
```

🧩 빈칸 실습 1 · 2 · 3

1 → text_stream

2 → delta · 3 → model

ask(provider, system, msgs)

→ text · ttft · total

→ in_tok · out_tok · cost

어떤 API 든 같은 결과 모양

→ 비교 · 교체 · D21 재사용

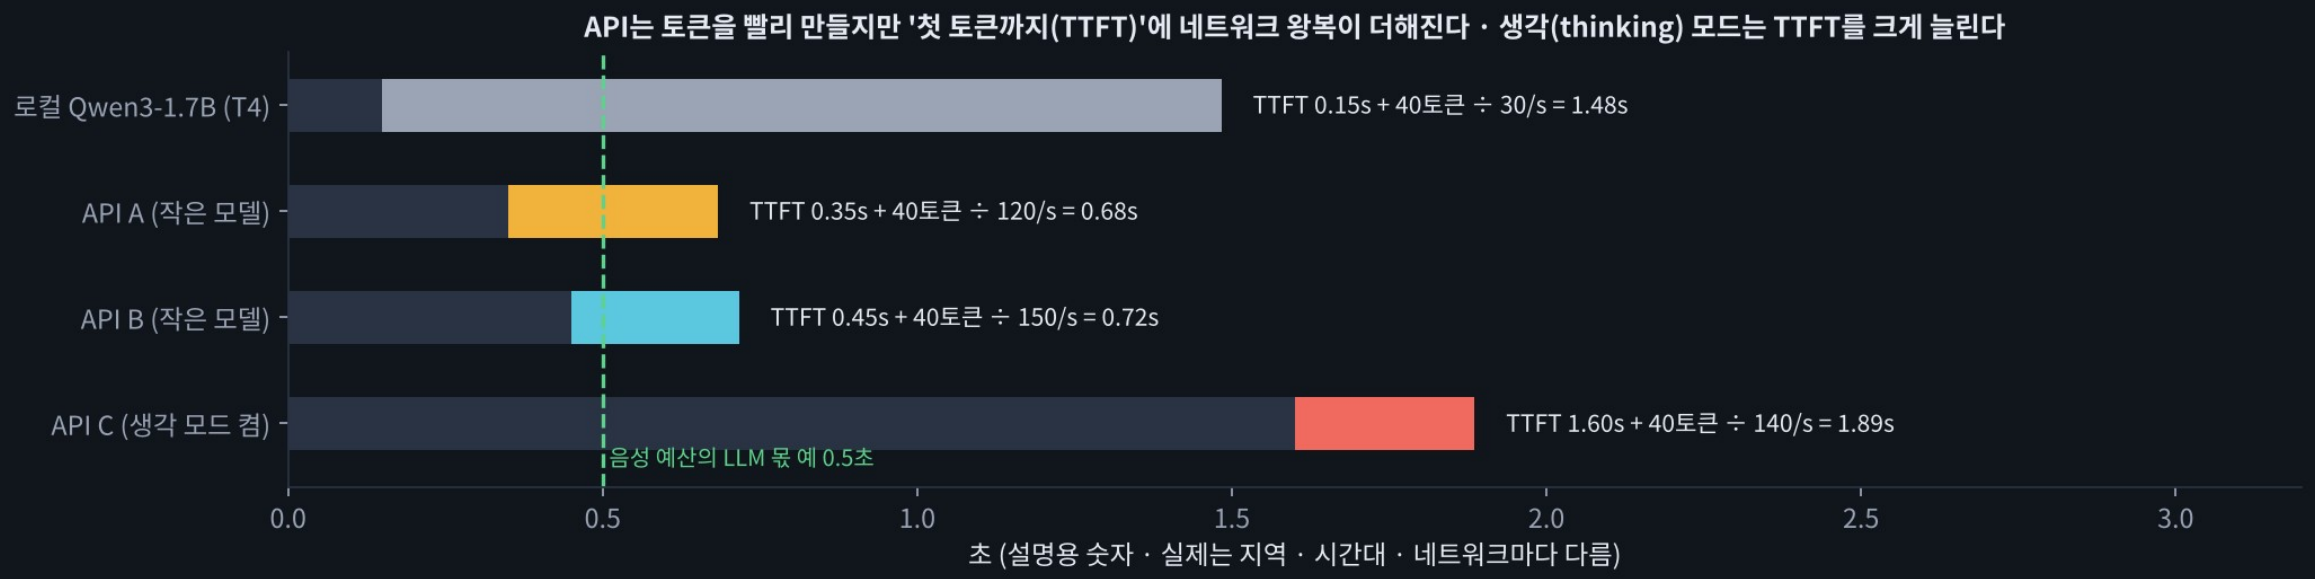
키 없는 API 는 건너뛰고 , local 은 항상

provider	ttft	total	out_tok	cost (USD)
claude	0.3 ~ 0.5	0.5 ~ 0.9	20 ~ 40	0.00002
openai	0.3 ~ 0.8	0.5 ~ 1.2	20 ~ 40	0.00002
gemini	0.3 ~ 0.7	0.4 ~ 1.0	20 ~ 40	0.0001
local (T4)	0.1 ~ 0.3	1 ~ 3	30 ~ 80	0

범위는 설명용 예 · 각자 실행 결과로

📝 1 교시 워크시트 → worksheet.html 1 교시 탭 10 문항

첫 토큰까지 = 네트워크 + 대기 + 입력 + 생각



▶ 애니메이션 D22-8 생각 모드와 TTFT

▶ 애니메이션 D22-4 음성 비서 비용 계산기

같은 조건 · 여러 번 · 중앙값 + 최댓값

```
def turn_cost(r, pr):
    return (r["in_tok"] * pr["inp"]
          + r["out_tok"] * pr["____"]) / 1e6     # 4
SUM = BENCH.groupby("provider")[cols].____()   # 5
```

🧩 **빈칸 실습 4 · 5**

4 → out · 5 → median

provider	ttft p50	ttft 최대	tok/s	1000 턴 USD
A	0.35	0.62	150	0.02
B	0.42	1.10	180	0.02
local	0.15	0.30	30	0

설명용 예시

음성 비서는 입력이 비용의 대부분

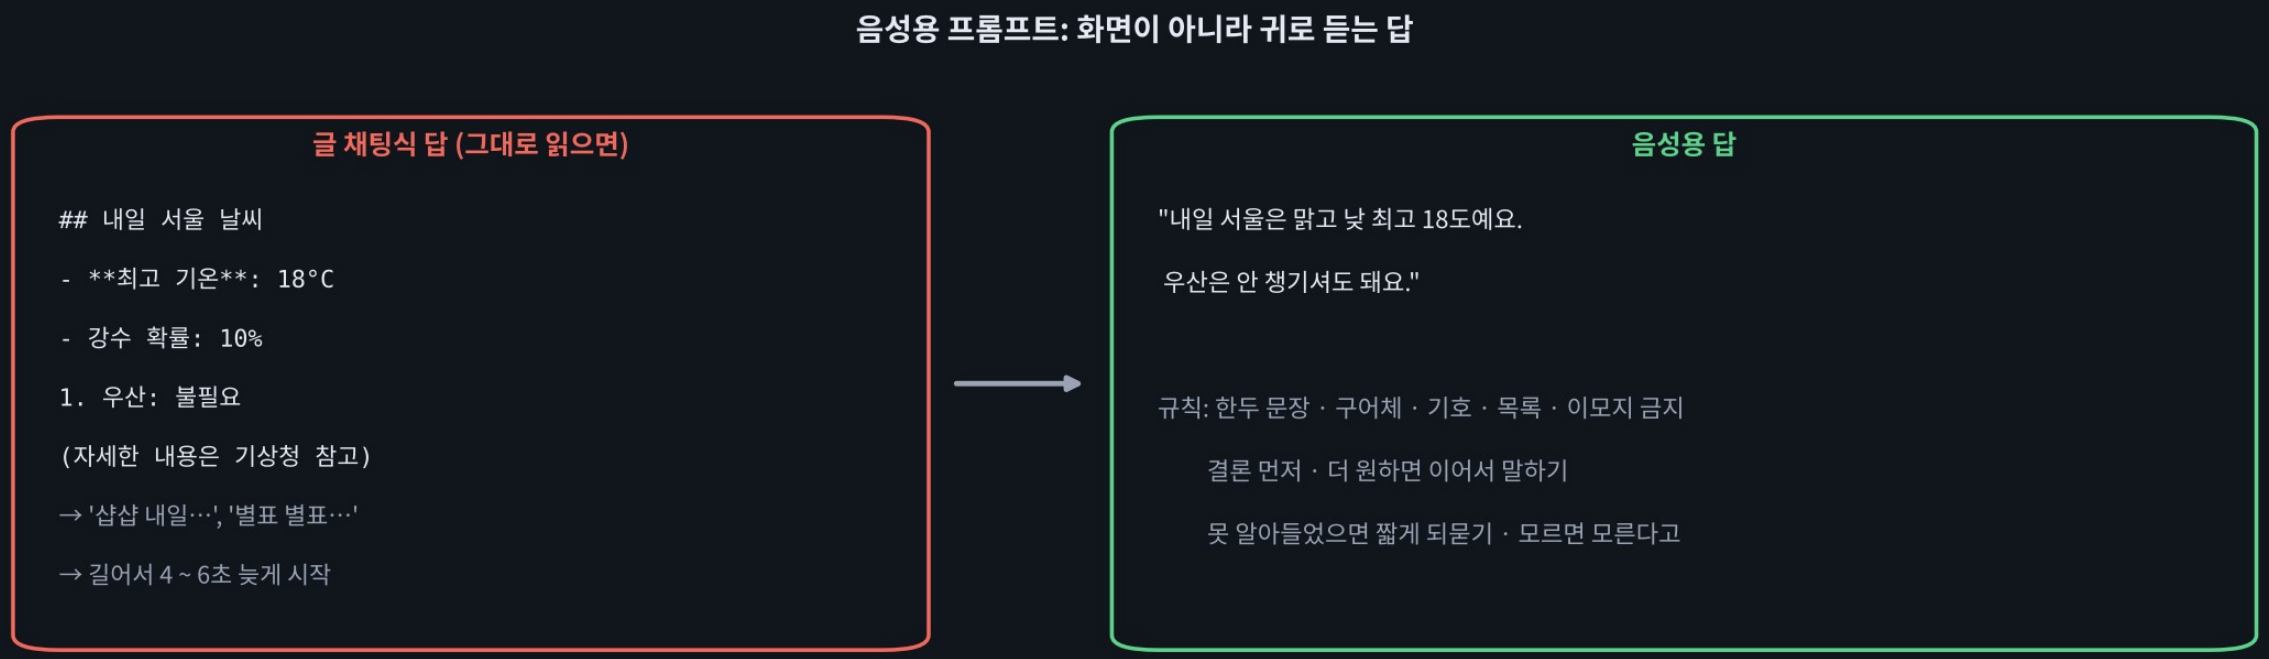
항목	토큰 (예)	단가 (예)	비용
시스템 지시	400	입력 0.10	0.00004
이력	1,500	입력 0.10	0.00015
답	60	출력 0.50	0.00003
한 턴			≈ 0.00022 USD
하루 1만 턴 × 30 일			≈ 66 USD

줄이는 방법

- 이력 창 + 요약 (Part 5)
- 프롬프트 캐싱
- 짧은 시스템 지시
- 작은 모델 + 필요할 때만 큰 모델

📝 **2 교시 워크시트 → worksheet.html 2 교시 탭 10 문항**

화면이 아니라 귀로 듣는 답



자동 점검(voice_lint): 글자 수 · 문장 수 · 마크다운 · 이모지 · 영어 단어 수 → 통과율로 프롬프트 비교

▶ 애니메이션 D22-5 음성용 답 점검기

voice_lint: 80 자 · 2 문장 · 기호 없음

규칙	프롬프트 문장 예
한두 문장 · 결론 먼저	" 가장 중요한 답을 첫 문장에 "
기호 · 목록 · 이모지 금지	" 마크다운 , 이모지를 쓰지 마 "
길면 이어서	" 더 자세히 알려 드릴까요 ?"
되묻기	" 질문이 이상하면 짧게 되물어 "
실시간 정보	" 확인할 수 없다고 말해 "
영어는 한글로	" 소리 나는 대로 써 "

```
r["ok"] = r[" 글자 "] <= max_chars
      and r[" 문장 "] <= ____     # 6
      and not r[" 마크다운 "]
      and not r[" 이모지 "]
```

🧩 빈칸 실습 6

6 → max_sent

감이 아니라 통과율로

프롬프트	API 통과율 (예)	local
기본	0.0 ~ 0.3	0.0
음성 v1 (D21)	0.5 ~ 0.8	0.0 ~ 0.3
음성 v2	0.7 ~ 1.0	0.0 ~ 0.5

까다로운 질문 6 개

- 파이썬 설치 방법 (목록 유혹)
- 내일 날씨 · 환율 (실시간)
- "내 일 서 울 날 씬" (STT 오류)
- 회의 3 시 30 분 (숫자)
- 요즘 우울해 (민감)

LLM 은 기억이 없다 → 매번 다시 보낸다



이력이 길수록 입력 토큰 ↑ → 요금 ↑ · TTFT ↑ · 그래서 창 + 요약 + 정확한 끊김 기록

▶ 애니메이션 D22-6 이력 창 · 요약

▶ 애니메이션 D22-7 끼어들기 저장

최근 N 턴 × 2 + 요약 + 말한 데까지만

```
recent = self.turns[-self.max_turns * ____:]   # 7
said = reply if spoken is None \
       else reply[:____] + " …( 끼어듦 )"          # 8
if len(self.turns) > N * 2: summary ← 가장 오래된 턴
```

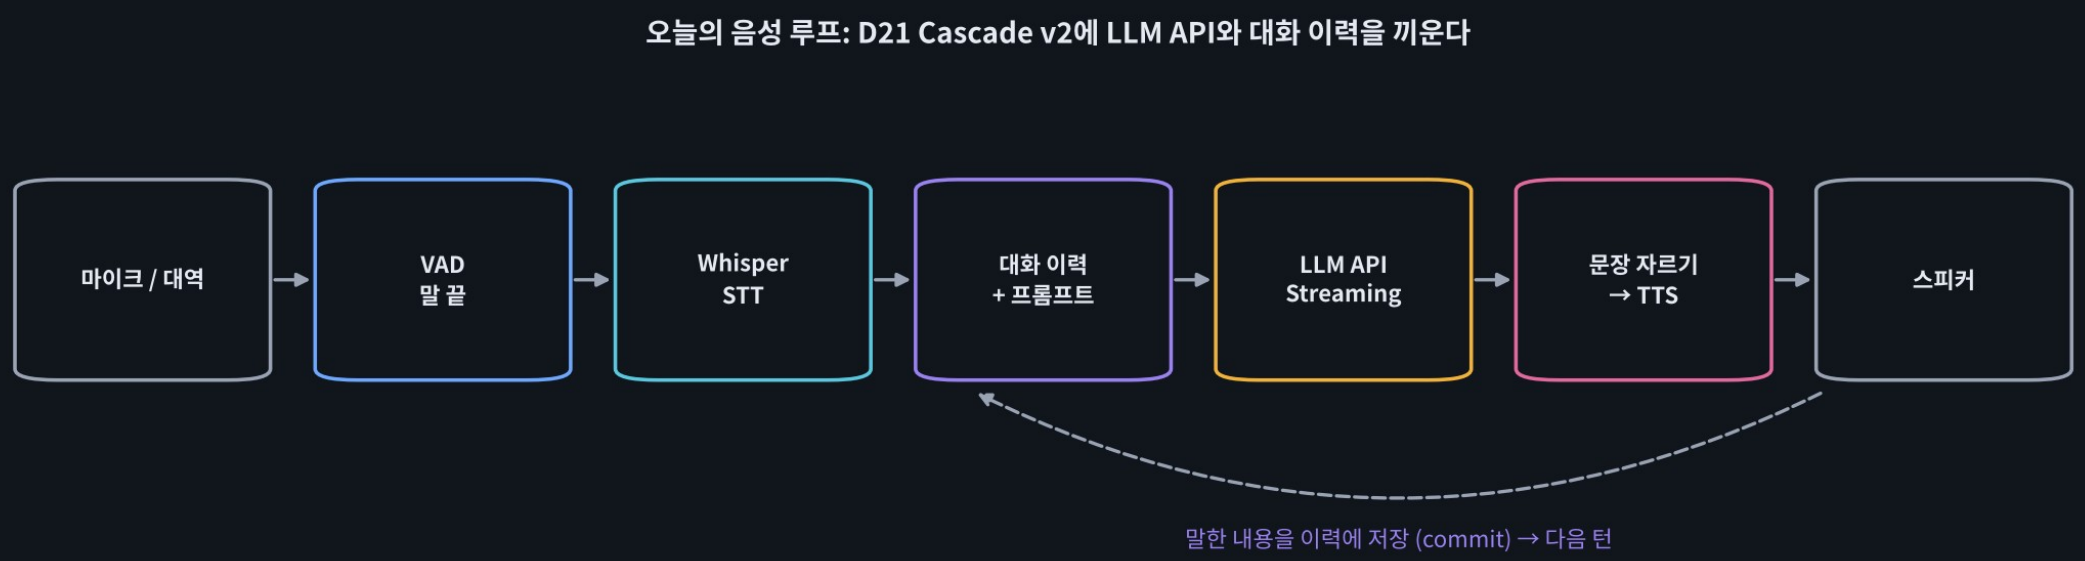
🧩 빈칸 실습 7 · 8

7 → 2 · 8 → spoken

전략	입력 토큰 (6 턴)	이름 · 약속 기억	비고
전체 이력	계속 증가	✅	길어지면 비용 · TTFT ↑
최근 2 턴	일정	❌	창 밖은 잊음
최근 2 턴 + 요약	거의 일정	✅	요약 호출 비용 · 요약 오류 위험

📝 3 교시 워크시트 → worksheet.html 3 교시 탭 10 문항

D21 v2 + ask() + Conversation




```
system, msgs = conv.messages(heard)
r = ask(P_VOICE, system, msgs, on_piece=...)
conv.____(heard, r["text"])                # 9
```

🧩 빈칸 실습 9

9 → commit

세 번째 턴에서 기억을 확인

턴	사용자	비서 (예)	입력 토큰	v2v_stream
1	안녕, 나는 지민이야.	안녕하세요, 지민 님!	≈ 600	≈ 1.3
2	내일 오후 3 시에 팀 회의가 있어.	네, 내일 오후 3 시 회의 기억할게요.	≈ 1,000	≈ 1.2
3	내 회의 몇 시라고 했지?	내일 오후 3 시예요.	≈ 1,500	≈ 1.1

❓ **이력 대신 "메모"에서 찾게 하려면? (D23 예고)**
save_note · get_note 같은 도구를 LLM 에 알려 주고, LLM 이 필요할 때 도구를 호출 → Tool Calling · 사내 문서 검색은 RAG

같은 함수 · 같은 조건 · 점검 · 이력 설계

개념	한 줄	코드
API 공통 구조	모델 · 시스템 · 대화 · 길이 · Streaming	`ask(provider, system, msgs)`
키 관리	보안 비밀 · 출력 금지 · 유출 시 폐기	`secret("…_API_KEY")`
Streaming	Claude · OpenAI · Gemini	`text_stream · .delta · role "model"`
비용 · 비교	입력 × 단가 + 출력 × 단가 · 중앙값	`pr["out"], .median()`
음성 프롬프트	짧게 · 결론 먼저 · 기호 금지 · 되묻기	`voice_lint(…, max_sent)`
대화 이력	최근 N 턴 쌍 · 요약 · 말한 데까지만	`turns[-N*2:], reply[:spoken]`
음성 루프	듣기 → 이력 → API → TTS → 저장	`conv.commit(heard, reply)`

과제 · 다음 시간

D23: 비서가 일을 한다

- ☐ 세 API 의 공통 구조와 차이를 설명할 수 있다
- ☐ 키를 안전하게 다룬다 (보안 비밀 · 유출 대응)
- ☐ 세 API 를 하나의 함수로 Streaming 호출했다
- ☐ TTFT · 비용을 같은 조건에서 비교했다
- ☐ 음성 프롬프트를 자동 점검으로 비교했다
- ☐ 이력 (창 · 요약 · 끊김) 을 관리하는 3 턴 음성 대화를 만들었다

다음 : D23 Tool Calling & RAG

Function Calling 으로 예약 · 조회 함수를 LLM 이 직접 부르게 하고 , 사내 문서를 검색해 근거를 들어 답하는 RAG 를 음성 비서에 붙입니다 .

worksheet.html	40 문항
개념 워크시트 · 노션 제출	
animation.html	9 개 탭
인터랙티브 애니메이션	
D22_LLM_API 연동 _ 실습 .ipynb	빈칸 9
실습 노트북 · T4	

온라인 자료 imguru-mooc.github.io/AI_Voice/day22