음성 AI 전문가 과정 · Day 31 / 40

Day 31

FastAPI 음성 API 서버
REST · 업로드 · 비동기 · WebSocket

```python
app = FastAPI(title="한빛치과 음성 API")

@app.post("/stt")
async def stt_endpoint(file: UploadFile = File(...)):
    y = decode_audio(await file.read())
    text = await asyncio.to_thread(stt, y)
    return {"text": text}

@app.websocket("/ws/voice")   # 실시간
```

/health · /tts → /stt 업로드와 상태 코드 → 이벤트 루프와 to_thread → /ws/stt · /ws/voice

7 주차 M7 첫날 · 4 시간 · 키 필요 없음

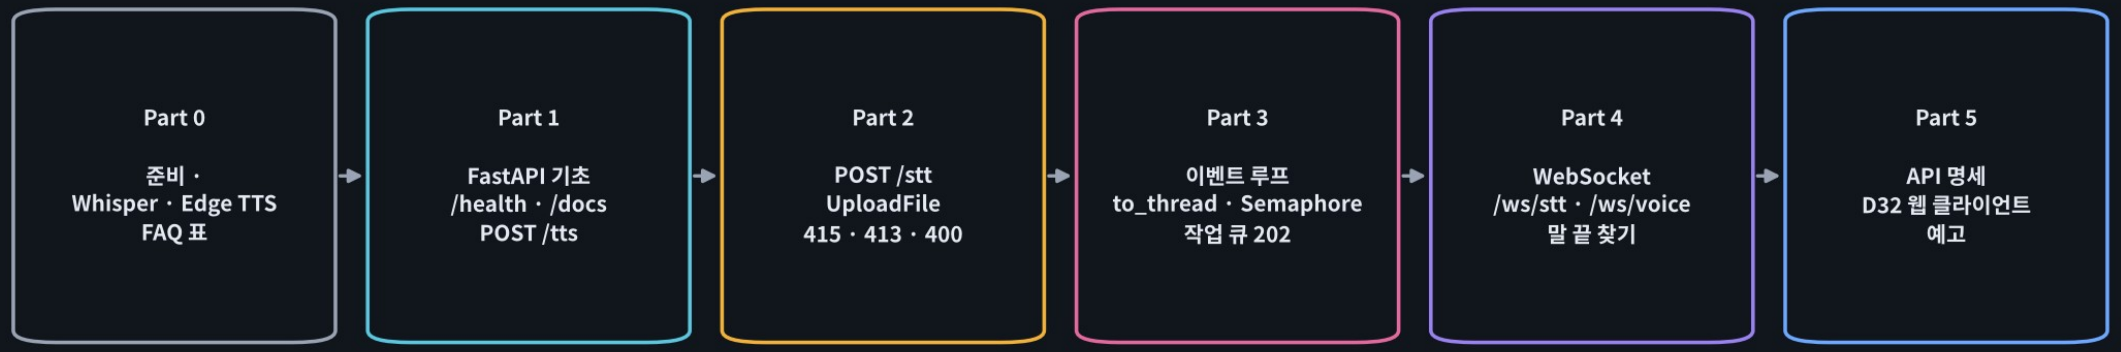
0.0 · 오늘 답할 질문

노트북 함수를 다른 프로그램이 부르게 하려면

1	요청과 응답은 무엇으로 이루어지나 ?	Part 1
2	글자를 보내 소리를 받으려면 ? (POST /tts)	Part 1
3	음성 파일을 올려 받아쓰려면 ? (POST /stt)	Part 2
4	잘못된 요청은 어떻게 거절하나 ?	Part 2
5	받아쓰는 동안 서버가 멈추지 않게 하려면 ?	Part 3
6	말하는 동안 바로 받아쓰려면 ?	Part 4

REST → 업로드 → 비동기 → WebSocket

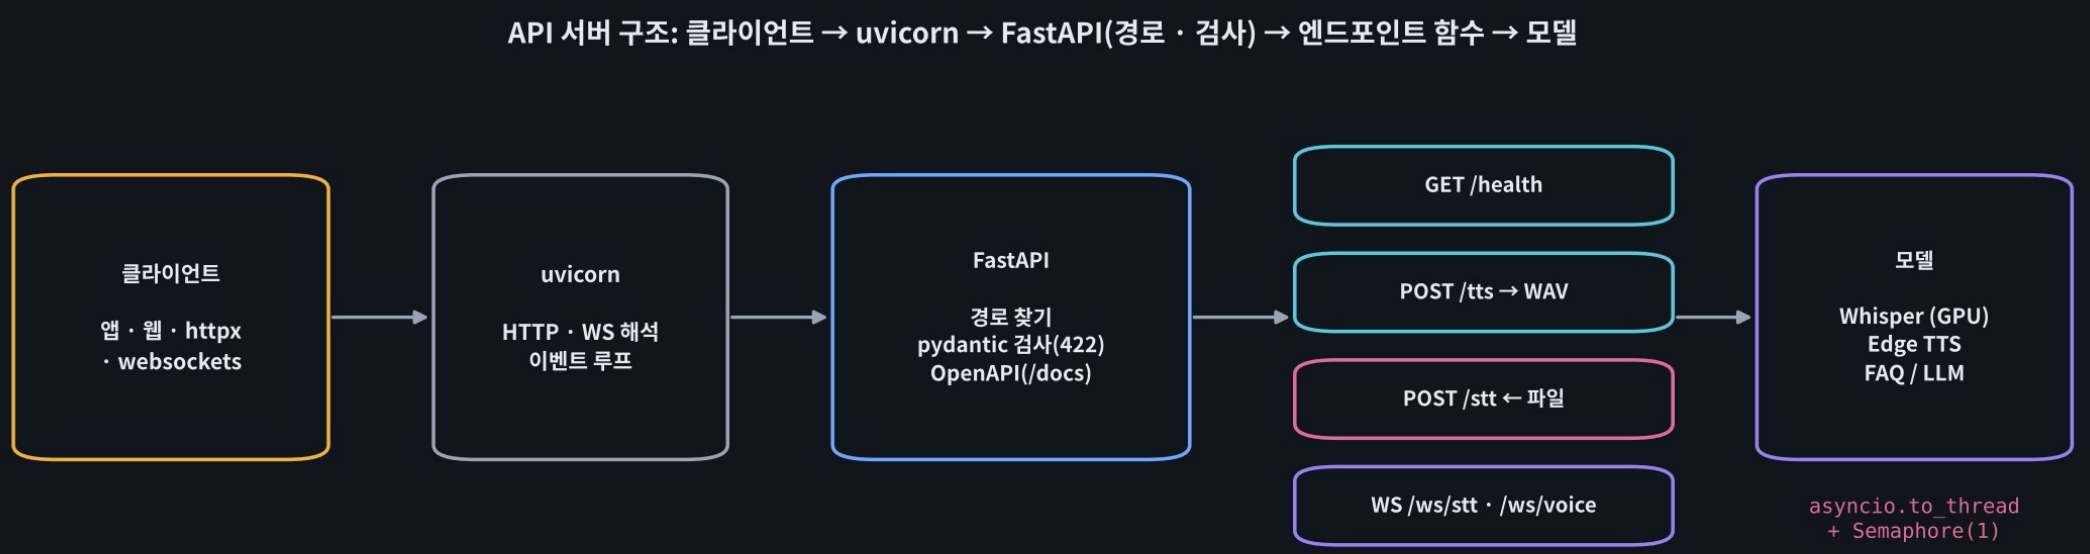
D31 · 노트북 함수를 API 서버로: REST(TTS · STT) → 비동기 처리 → WebSocket(실시간)



서버는 Colab 안 127.0.0.1:8031 (uvicorn 스레드) · 클라이언트는 같은 노트북의 httpx · websockets

교시	내용	빈칸	애니메이션
1 교시	Part 0 ~ 1 HTTP · FastAPI · /health · /docs · /tts	1 · 2 · 3	D31-1 · 2
2 교시	Part 2 /stt 업로드 · 상태 코드	4 · 5	D31-3 · 4
3 교시	Part 3 이벤트 루프 · to_thread · Semaphore · 작업 큐	6 · 7	D31-5 · 6
4 교시	Part 4 ~ 5 /ws/stt · /ws/voice · API 명세	8 · 9	D31-7 · 8 · 9

클라이언트 → uvicorn → FastAPI → 엔드포인트 → 모델



요청 = 메서드 + 경로 + 머리글 + 본문 · 응답 = 상태 코드 + 머리글(content-type) + 본문

🍎 민원 창구 vs 전화 상담

REST 는 서류 한 장 내고 결과 받기 , WebSocket 은 전화를 걸어 두고 계속 주고받기 .

▶ 애니메이션 D31-2 요청과 응답의 일생

요청 = 메서드 + 경로 + 머리글 + 본문

```
POST /tts HTTP/1.1
content-type: application/json

{"text": "평일은 오전 9시 반부터 …"}
```

```
HTTP/1.1 200 OK
content-type: audio/wav
x-synth-seconds: 0.312

RIFF....WAVEfmt … (42 KB)
```

메서드	뜻	오늘
GET	읽기	/health · /jobs/{id}
POST	만들기 · 처리	/tts · /stt · /jobs/stt
WS	연결 유지 · 양방향	/ws/stt · /ws/voice

@app.get("/health") + uvicorn 스레드

```
app = FastAPI(title="한빛치과 음성 API")

@app.get("/health", summary="서버 상태")
async def health():
    return {"ok": True, "gpu": GPU}

server = uvicorn.Server(uvicorn.Config(app, port=8031))
threading.Thread(target=server.run, daemon=True).start()

client = httpx.AsyncClient(base_url=BASE)
await client.get("/health")   # → 200
```

🧩 빈칸 1

get (읽기 요청 장식자)

1. Colab 프록시로 /docs 열기
2. Try it out → Execute
3. 실서비스 : uvicorn main:app

BaseModel 로 검사 → WAV 바이트로 응답

```python
class TTSRequest(BaseModel):
    text: str = Field(..., min_length=1, max_length=300)
    voice: str = Field(VOICE_BOT)

@app.post("/tts")
async def tts_endpoint(req: TTSRequest):
    y = await asyncio.to_thread(tts, normalize_ko(req.text), 0, req.voice)
    return Response(content=wav_bytes(y), media_type="audio/wav")
```

🧩 **빈칸 2 · 3**

BaseModel · "audio/wav"

❓ **base64 JSON? → 33% 커짐 , 대신 정보를 함께 담기 편함**

multipart/form-data → UploadFile

```python
@app.post("/stt")
async def stt_endpoint(file: UploadFile = File(...)):
    if file.content_type not in ALLOWED:
        raise HTTPException(status_code=415, detail="지원하지 않는 형식")
    data = await file.read()
    if len(data) > MAX_BYTES: raise HTTPException(413, ...)
    try: y = decode_audio(data)          # 16 kHz 모노
    except ValueError as e: raise HTTPException(400, str(e))
    text, waited, worked = await transcribe(y)
    return {"text": text, "rtf": worked / (len(y) / SR)}
```

🧩 **빈칸 4 · 5**

UploadFile · HTTPException

▶ 애니메이션 D31-3 업로드 해부

soundfile → 안 되면 ffmpeg

파일	크기	푸는 방법
16 kHz 모노 WAV	88 KB	soundfile
48 kHz 스테레오 WAV	529 KB	soundfile → 평균 → 리샘플
FLAC	14 KB	soundfile
MP3 64 kbps	19 KB	ffmpeg
WebM Opus	9 KB	ffmpeg

📐 핵심 식 하나

RTF = 처리 시간 ÷ 소리 길이 (< 1)

크기는 예시 (테스트 실행 기준)

4xx = 보낸 쪽 잘못 , 5xx = 서버 잘못

코드	뜻	오늘 언제
200	OK	성공
202	Accepted	작업 접수
400	Bad Request	깨진 소리
404	Not Found	없는 작업
413	Content Too Large	10 MB 초과
415	Unsupported Media Type	이미지 · 텍스트
422	Unprocessable Content	빈 글자 · 칸 이름
429	Too Many Requests	(D33 · D34)
500	Internal Server Error	처리 못 한 예외

▶ 애니메이션 D31-4 상태 코드 고르기

❓ 1 GB 업로드 공격 → 프록시 크기 제한 · Content-Length · 인증 · 429

통과한 것만 Whisper 로

요청	상태 코드	응답
정상 WAV	200	{"text": "..."}
이미지 파일	415	지원하지 않는 형식 : image/png
11 MB WAV	413	파일이 너무 큼 : 11,534,336 바이트 > 10,485,760
깨진 WAV	400	소리로 풀 수 없는 파일
파일 칸 이름이 틀림	422	[{"type": "missing", "loc": ["body", "file"]}]

async = 기다리는 동안 딴 일 (동시 계산이 아님)



🍎 홀 직원 한 명

직원이 주방에서 직접 요리하면 주문도 계산도 멈춘다 . 요리는 주방 (스레드) 에 , 화구가 하나면 주문표를 줄 세운다 (Semaphore).

▶ 애니메이션 D31-5 이벤트 루프 한 명

def 는 스레드 풀 , async def 는 to_thread

엔드포인트 모양	무거운 호출	결과
`async def + stt(y)`	루프 안에서	🚫 서버 전체 멈춤 (/health 1 초 이상)
`def`	자동 스레드 풀	✅ 멈추지 않음 (스레드 약 40 개)
`async def + await asyncio.to_thread(stt, y)`	별도 스레드	✅ 멈추지 않음 · await 와 섞기 쉬움
`+ asyncio.Semaphore(1)`	GPU 한 번에 하나	✅ 메모리 · 경쟁 방지 , 줄 선 시간 보임

테스트 실행 예 : /health 최대 응답 1,398 ms → 고친 뒤 4 ms (대역 모델 · CPU 기준)

엔드포인트는 그대로 , transcribe 만 교체

```
GPU_LOCK = asyncio.Semaphore(1)

async def transcribe(y):
    t_q = time.perf_counter()
    async with GPU_LOCK:                # 차례 기다림 (await)
        t0 = time.perf_counter()
        text = await asyncio.to_thread(stt, y)
    return text, t0 - t_q, time.perf_counter() - t0
```

🧩 **빈칸 6·7**

to_thread · Semaphore

▶ 애니메이션 D31-6 번호표 줄 세우기

오래 걸리는 일은 접수증 (202) 부터

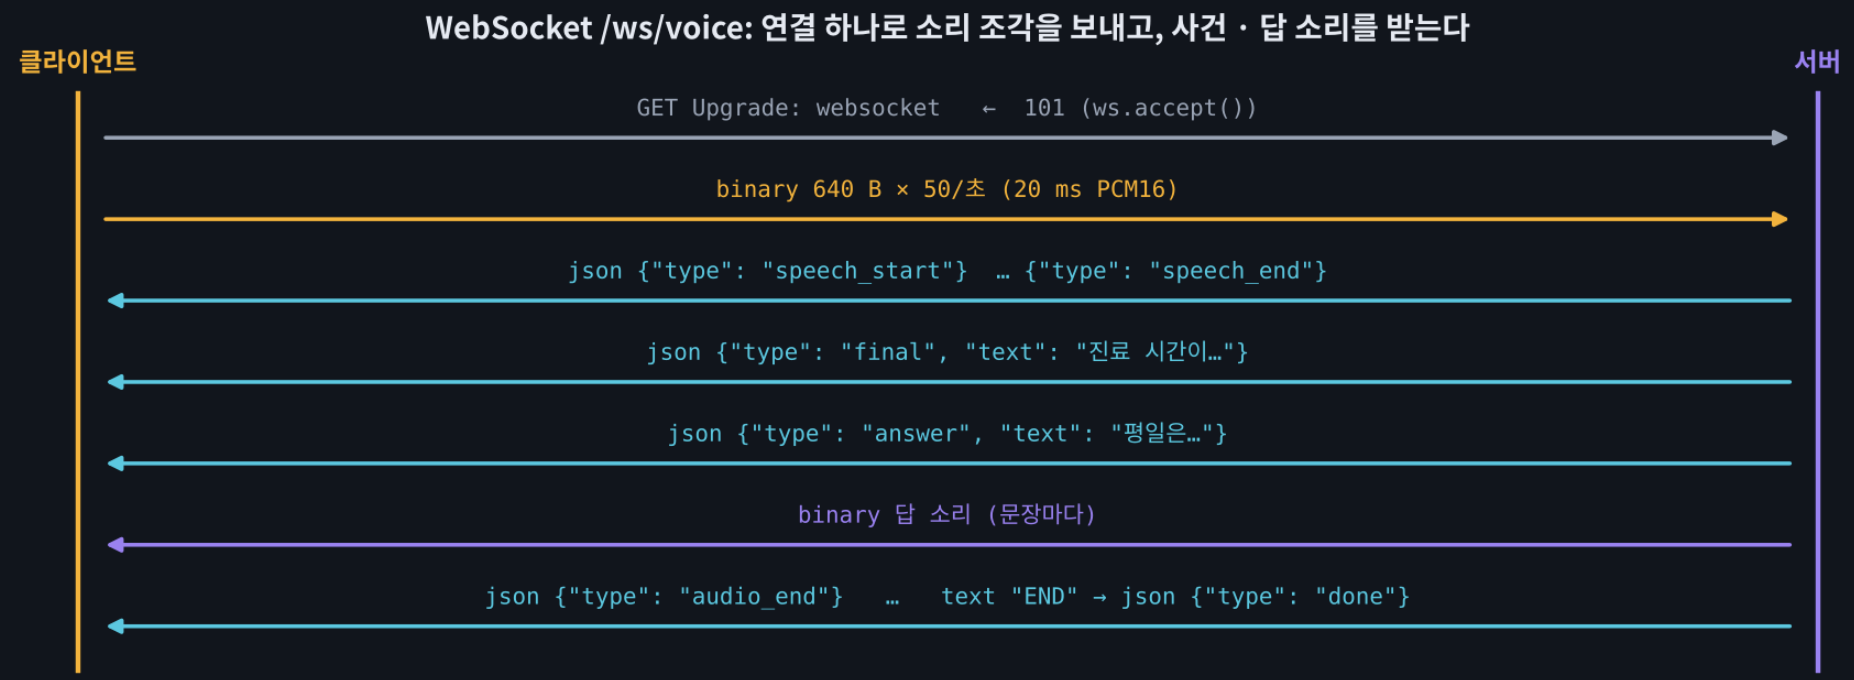
1. POST /jobs/stt → 202 + job_id
2. BackgroundTasks: 응답 보낸 뒤 받아쓰기
3. GET /jobs/{id} → queued · running · done
4. 없는 번호 → 404

```
@app.post("/jobs/stt", status_code=202)
async def submit_job(background: BackgroundTasks,
                     file: UploadFile = File(...)):
    background.add_task(run_job, job_id, y)
    return {"job_id": job_id, "status": "queued"}
```

🍎 **세탁소**

옷을 맡기면 번호표를 받고 , 나중에 번호로 찾으러 간다 .

연결 하나로 소리 조각과 사건 · 답 소리를 주고받기



▶ 애니메이션 D31-7 WebSocket 메시지 흐름

accept → receive → 말 끝 → send_json(final)

```python
@app.websocket("/ws/stt")
async def ws_stt(ws: WebSocket):
    await ws.accept()
    ep = Endpointer()
    while True:
        msg = await ws.receive()
        if msg.get("bytes"):
            for kind, t, seg in ep.feed(msg["bytes"]):
                await ws.send_json({"type": kind, "t": t})
                if kind == "speech_end": … send_json({"type": "final", …})
        elif msg.get("text") == "END": break
```

🧩 **빈칸 8 · 9**

accept · send_json

말 끝 → 글자 ≈ HANG_SEC 0.6 초 + STT + 전송

소리 → 받아쓰기 → FAQ 답 → 문장마다 소리

1. 말 끝 → transcribe → json final
2. answer(text) → json answer (✏️ LLM 자리)
3. 문장마다 TTS → send_bytes
4. json audio_end

▶ 애니메이션 D31-8 말 끝 찾기 손잡이

❓ 지연 줄이기 : HANG_SEC · Silero/Smart Turn · 첫 문장 짧게 · TTS 캐시 · 스트리밍 STT

OpenAPI 에서 자동으로 뽑은 명세표



FastAPI	한 줄 요약
@app.get · post · websocket	주소 + 함수
BaseModel · UploadFile · HTTPException	검사 · 업로드 · 오류
to_thread · Semaphore · BackgroundTasks	막히지 않게 · 줄 세우기 · 나중에

주소 + 함수 , 상태 코드 , 스레드 , WebSocket

빈칸	정답
1	get
2 · 3	BaseModel · "audio/wav"
4 · 5	UploadFile · HTTPException
6 · 7	to_thread · Semaphore
8 · 9	accept · send_json

다음 : D32 웹 클라이언트

브라우저 마이크 (Web Audio · MediaRecorder) 로 녹음해 오늘의 /stt · /ws/stt 로 보내고 , 답 소리를 재생하는 간단한 UI 를 만듭니다 . WebRTC 연결과도 비교합니다 .

worksheet.html — 40 문항
개념 워크시트 · 노션 제출

animation.html — 9 개 탭
인터랙티브 애니메이션

D31_FastAPI 음성 API_ 실습 .ipynb — 빈칸 9
실습 노트북 · 키 필요 없음

온라인 자료 imguru-mooc.github.io/AI_Voice/day31