음성 AI 전문가 과정 · Day 35 / 51

Day 35

화자 임베딩
화자 검증 · 화자 식별 · 위조 음성 탐지

ECAPA · WavLM 임베딩 → 코사인 → FAR · FRR · EER → 운영 문턱
검증 1:1 · 식별 1:N · 동의 · 암호화 · 삭제
TTS · 재생 · 복제 (kNN-VC) 공격 → LFCC 탐지기 · 다층 방어

```
e = ecapa.encode_batch(x).squeeze()
E = E / np.linalg.norm(E, axis=1, keepdims=True)

far = np.mean(non >= th); frr = np.mean(tgt < th)
i = np.argmin(np.abs(far - frr))        # EER
th = np.quantile(non, 1 - 0.01)         # FAR 1%

best = max(scores, key=scores.get)      # 1:N
blob = vault.encrypt(emb.tobytes())     #  보관
C = scipy.fft.dct(np.log(S), axis=0)    # LFCC
```

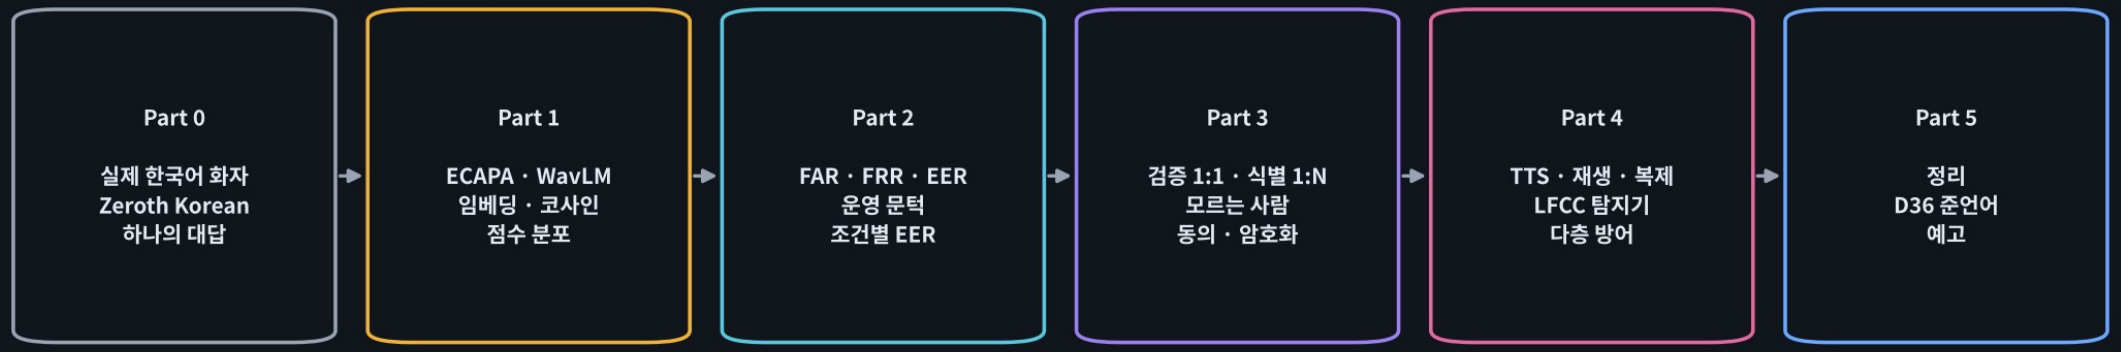
0.0 · 오늘 답할 질문

목소리로 " 그 사람이 맞나요 ?" 에 답할 수 있을까

1	목소리를 어떻게 숫자로 바꾸고 , 같은 사람인지 어떻게 재나 ?	Part 1
2	어디에 선을 그어야 하나 ? 두 실수 (FAR · FRR) 는 ?	Part 2
3	말 길이 · 등록 수 · 전화 음질은 얼마나 영향을 주나 ?	Part 2
4	" 김하늘 님 맞나요 ?" 와 " 가족 중 누구죠 ?" 는 무엇이 다른가 ?	Part 3
5	목소리 템플릿은 어떻게 보관해야 하나 ?	Part 3
6	녹음 재생 · 목소리 복제로 뚫리면 어떻게 막나 ?	Part 4

임베딩 → 문턱 → 검증 · 식별 → 위조 공격과 방어

D35 · 목소리로 '누구인지' 확인하기: 임베딩 → 문턱 → 검증 · 식별 → 위조 공격과 방어



실제 사람 목소리(CC BY 4.0)로 재고, 우리 검증기를 우리가 직접 공격해 본다 · 이름은 모두 가상

교시	내용	✍ 직접 작성	애니메이션
1 교시	Part 0 ~ 1 실제 화자 데이터 · 임베딩 · 코사인 · 점수 분포	1 코사인 함수	D35-1 · 2 · 3
2 교시	Part 2 FAR · FRR · EER · 운영 문턱 · 조건별 EER	2 FRR 목표 문턱	D35-4 · 5 · 6
3 교시	Part 3 검증 · 식별 · 1:N · 본인 확인 · 생체 정보 보관	3 1:N 오수락 확률	D35-7
4 교시	Part 4 ~ 5 TTS · 재생 · 복제 공격 · LFCC 탐지기 · 다층 방어	4 관문 판정	D35-8 · 9

Zeroth Korean 시험 세트 : 실제 한국어 화자의 낭독

항목	값
출처	Hugging Face kresnik/zeroth_korean · 시험 세트
규모	457 문장 · 화자 10 명 안팎 · 약 60 MB
내려받기	data/test-*.parquet 만 (학습용 2.8 GB 는 받지 않음)
소리	parquet 안의 파일 바이트 → sf.read(io.BytesIO(...))
나누기	화자마다 앞 5 문장 = 등록 · 나머지 = 시험
예비	내려받기 실패 → Edge TTS 목소리 10 개 (EER 이 비현실적으로 낮음)

🍎 **왜 실제 사람 목소리 ?**

TTS 목소리는 매번 똑같이 말해서 너무 쉽습니다 . 사람은 문장마다 높낮이 · 빠르기 · 컨디션이 달라 같은 사람의 점수도 흔들립니다 . 그 흔들림이 오늘 오류의 정체입니다 .

윤리 : 공개 데이터 · 가상 이름 · 결과물은 수업 밖으로 내보내지 않음 (D19).

▶ 애니메이션 D35-2 임베딩 공간

소리 한 마디 → 숫자 192 개 → 길이 1 → 내적 = 코사인

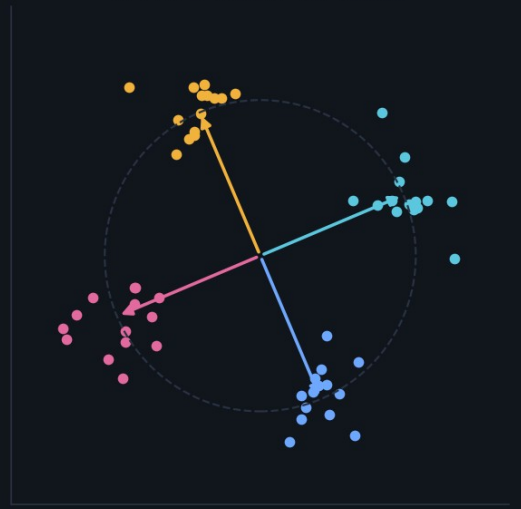
소리 한 마디 → 숫자 192개 → 길이 1로 → 내적 = 코사인 유사도



$$\cos(a, b) = a \cdot b \,/\, (\|a\| \, \|b\|)$$

같은 사람 → 같은 방향(점수 높음) · 다른 사람 → 다른 방향 · 목소리 크기는 길이만 바꿈

화자 4명의 문장들 (그림은 설명용)



모델	차원	특징
ECAPA-TDNN (speechbrain/spkrec-ecapa-voxceleb)	192	화자 인식 전용 , 주의 집중 통계 풀링 , D9 에서 씀
WavLM-SV (microsoft/wavlm-base-plus-sv)	512	큰 자기지도 모델 + x-vector 머리 , D19 에서 씀

encode_batch 로 묶음 → 임베딩 , norm 으로 길이 1

```
def embed_ecapa(y):
    x = torch.tensor(to_np(y))[None].to(DEVICE)   # (1, 샘플 수)
    with torch.no_grad():
        e = ecapa.encode_batch(x)                 # (1, 1, 192)
    return e.squeeze().cpu().numpy()

def l2n(E):
    return E / np.linalg.norm(E, axis=1, keepdims=True)
```

▶ 애니메이션 D35-3 코사인 유사도

⭐ **핵심 줄**
encode_batch

⭐ **핵심 줄**
norm (벡터의 길이)

길이 1 이면 수천 쌍의 코사인을 행렬 곱 한 번 (E @ T.T) 으로 .

등록 템플릿과 시험 문장을 비교한 점수 두 묶음

1. 화자마다 앞 n 문장 임베딩을 평균 → 길이 1 = 등록 템플릿
2. 시험 문장 하나를 모든 화자의 템플릿과 비교
3. 같은 사람 템플릿과의 점수 = 본인 시도 (target)
4. 다른 사람 템플릿과의 점수 = 타인 시도 (non-target)

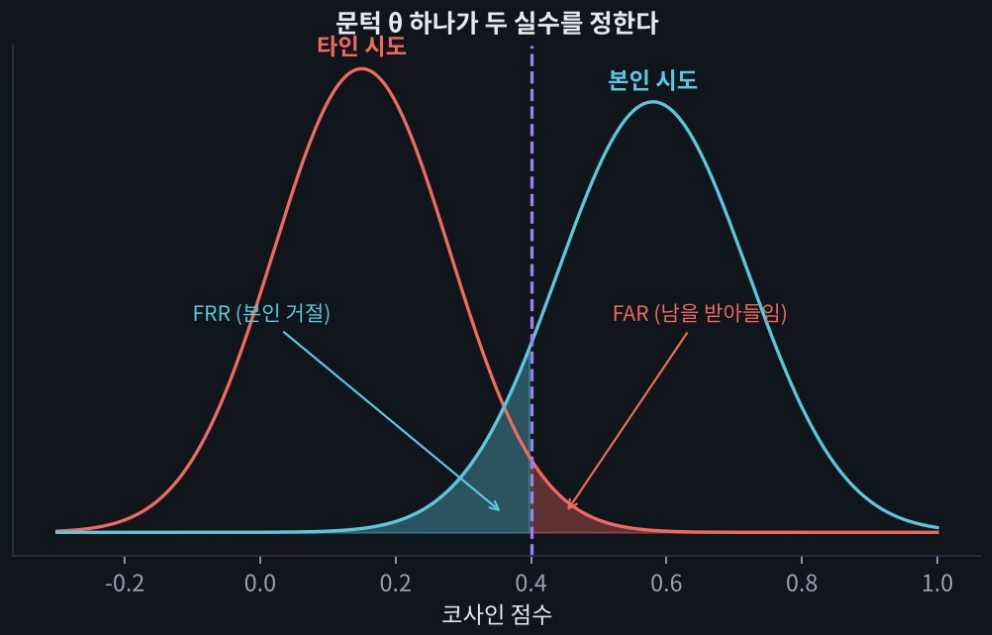
```
T = {s: l2n(E[IDX[s][:3]].mean(0))[0]}
for i in TEST_IDX[s]:
    for c, t in T.items():
        (tgt if c == s else non).append(E[i] @ t)
```

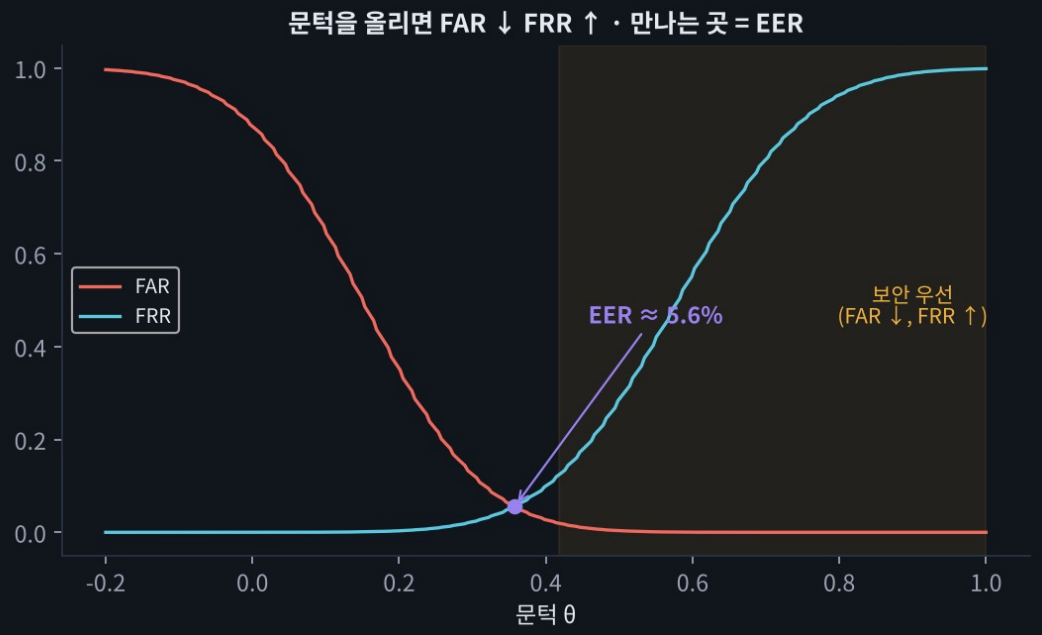
🍎 **사칭이란 ?**

다른 사람이 " 김하늘입니다 " 라고 말하는 것 . 타인 시도 점수가 높으면 사칭이 통과합니다 .

▶ 애니메이션 D35-4 FAR · FRR · EER

문턱 하나가 두 실수를 맞바꾼다





실수	뜻	문턱을 올리면	서비스에서
FAR (오수락률)	타인 시도 중 받아들인 비율	줄어듦	남이 예약 · 진료 기록을 봄
FRR (오거절률)	본인 시도 중 거절한 비율	늘어남	본인이 다른 방법으로 확인

FAR 은 타인 점수에서 , EER 은 차이가 가장 작은 곳

```
def far_frr(tgt, non, th):
    far = np.mean(non >= th)      # 남을 받아들인 비율
    frr = np.mean(tgt < th)       # 본인을 거절한 비율

def eer(tgt, non):
    ths = np.sort(np.concatenate([tgt, non]))
    far, frr = np.array([far_frr(tgt, non, t) for t in ths]).T
    i = np.argmin(np.abs(far - frr))
    return (far[i] + frr[i]) / 2, ths[i]
```

⭐ **핵심 줄**

non (타인 시도 점수)

⭐ **핵심 줄**

argmin (D33 argmax 의 반대)

tgt 를 쓰면 1 – FRR 이 되어 검산이 틀림 .

목표 FAR 에서 거꾸로 : 타인 점수의 (1 − 목표) 분위수

```
TH_SEC = float(np.quantile(NON, 1 - 0.01))   # FAR 1%
```

⭐ **핵심 줄**

quantile (percentile 이면 0 ~ 100 단위)

운영 목표	문턱	FAR	FRR	쓰임
편의 우선	낮음	5%	작음	가벼운 개인화 (이름 불러 주기)
EER 지점	중간	= FRR	= FAR	모델 비교용
보안 (오늘 TH_SEC)	높음	1%	커짐	예약 변경 · 개인정보 안내
은행급	아주 높음	0.1%	많이 커짐	결제 · 다른 인증과 함께

▶ 애니메이션 D35-5 문턱 고르기

말 길이 · 등록 수 · 채널 · 잡음 · 모델

조건	예상 경향
등록 1 · 3 · 5 문장	많을수록 템플릿 안정 → EER ↓
시험 1 · 2 · 3 초	짧을수록 크게 나빠짐 (" 네 " 한마디는 어려움)
시험만 전화 음질	채널 불일치 → 크게 나빠짐
등록 · 시험 모두 전화	채널이 맞아 다시 좋아짐
시험에 잡음 SNR 10 dB	나빠짐 (D33 전처리가 도움)
ECAPA vs WavLM-SV	데이터에 따라 순위가 바뀜

🍎 채널 불일치

임베딩은 목소리뿐 아니라 마이크 · 코덱의 흔적도 담습니다 . 앱으로 등록하고 전화로 확인하면 같은 사람도 점수가 떨어집니다 → 등록도 전화로 , 채널별 문턱 .

▶ 애니메이션 D35-6 등록과 길이

1:1 " 김하늘 님 맞나요 ?" vs 1:N " 가족 중 누구죠 ?"

	검증 (1:1)	식별 (1:N)
비교	주장한 사람 하나	등록된 모두
거절	점수 < 문턱	최고 점수 < 문턱 → 모르는 사람
한빛치과	전화 예약 변경 본인 확인	가족 계정에서 누구 예약인지

max(scores) 만 쓰면 이름의 가나다순 최댓값이 나온다 .

```
scores = {n: e @ t for n, t in db.items()}
best = max(scores, key=scores.get)
if scores[best] < th:
    best = " 모르는 사람 "
```

⭐ **핵심 줄**

get (값이 가장 큰 키)

등록 인원이 늘면 모르는 사람도 누군가가 된다

등록 인원 N	모르는 사람 오수락 (1:1 FAR 1%)
1 명	1.0%
5 명	4.9%
10 명	9.6%
100 명	63.4%
1,000 명	100.0%
10,000 명	100.0%

🍎 졸업 사진 비유

사진 속 300 명 중 나와 닮은 사람 한 명은 꼭 있습니다 . 비교 대상이 많을수록 우연히 닮은 사람을 고를 확률이 커집니다 .

▶ 애니메이션 D35-7 1:N 식별

별도 동의 · 원본 최소화 · 암호화 · 가명 · 삭제

원칙	오늘 코드
별도 동의 · 목적 한정	CONSENT 기록 · 동의 번호를 템플릿에
원본 최소화	템플릿 생성 뒤 등록 녹음 삭제
암호화	Fernet · 키는 KMS (출력 금지)
가명	이름 대신 해시값
삭제 (철회)	forget() → 이후 검증 실패

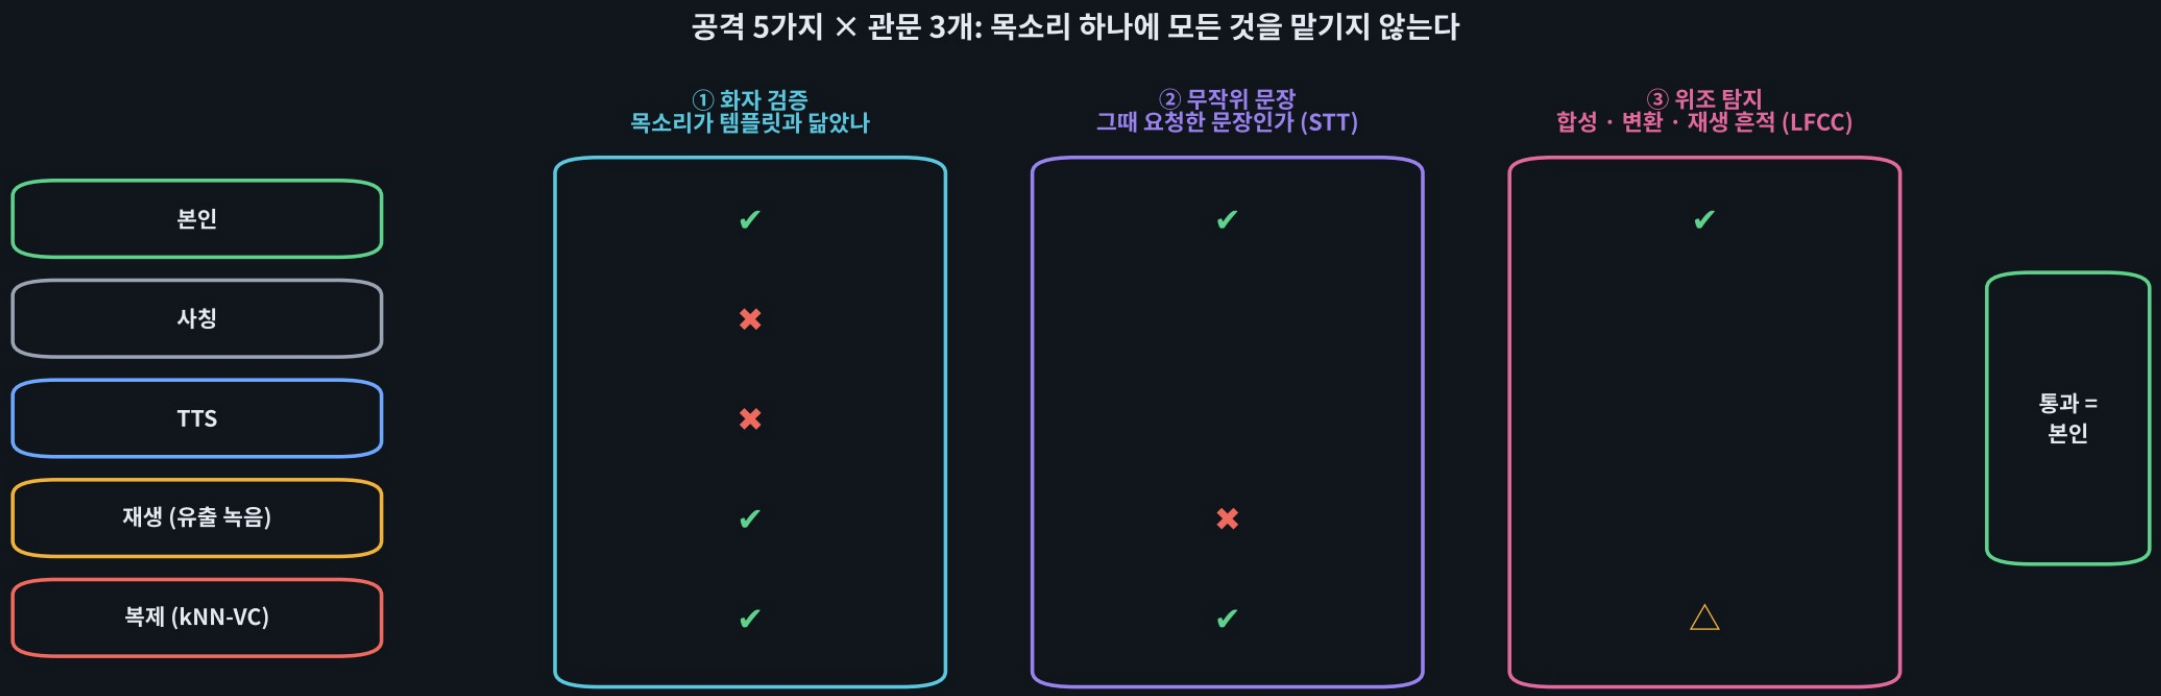
```
vault = Fernet(VAULT_KEY)   # 출력 금지
blob = vault.encrypt(emb.tobytes())
emb = np.frombuffer(vault.decrypt(blob))
```

⭐ **핵심 줄**

encrypt

비밀번호는 바꿀 수 있지만 목소리는 못 바꾼다 .

공격 다섯 가지 × 관문 세 개



(표시는 전형적인 결과, 실제 숫자는 노트북 4-2) △ = 본 적 있는 복제는 잘 잡고 처음 보는 복제에는 약함 → 중요한 행동은 문자 인증 등 다른 요소와 함께

▶ 애니메이션 D35-8 공격과 방어

공격자 말소리를 대상 목소리 조각으로 갈아 끼운다

1. 공격자 말소리 → WavLM 특징 (프레임마다)
2. 유출된 대상 녹음 → WavLM 특징 묶음 (matching set)
3. 프레임마다 대상 묶음에서 가장 닮은 4 개 평균으로 교체
4. 보코더 (HiFi-GAN) 로 소리 만들기 → 대상 목소리

```
knn_vc = torch.hub.load("bshall/knn-vc", "knn_vc",
    prematched=True, trust_repo=True, pretrained=True)
ms = knn_vc.get_matching_set(leaked_paths)
out = knn_vc.match(knn_vc.get_features(src), ms, topk=4)
```

공격	화자 검증만 (예상)
사칭 · TTS	거의 막힘
재생 (유출 녹음)	상당수 통과
복제 (kNN-VC)	상당수 통과할 수 있음

LFCC + 로지스틱 회귀

```
def lfcc(y, n=20):
    S = np.abs(librosa.stft(y, n_fft=512, hop_length=160)) ** 2
    C = scipy.fft.dct(np.log(S + 1e-10), type=2, axis=0,
                      norm="ortho")[:n]
    return np.r_[C.mean(1), C.std(1), np.diff(C, axis=1).std(1)]

DET = make_pipeline(StandardScaler(), LogisticRegression())
p_fake = DET.predict_proba(lfcc(y)[None])[0, 1]
```

⭐ **핵심 줄**

dct (MFCC 와 같은 변환)

⭐ **핵심 줄**

predict_proba ([:, 1] = 위조)

학습 : 진짜 = 등록 문장 , 위조 = TTS 만 . 재생 · 복제는 처음 보는 공격 .

본 적 있는 공격은 잘 잡고, 처음 보는 공격에는 약하다

탐지기	TTS	재생	복제
TTS 만 배움 (예상)	잘 잡음	잘 못 잡음	잘 못 잡음
복제도 배움 (예상)	잘 잡음	잘 못 잡음	크게 좋아짐

복제를 학습에 넣을 때는 공격 문장 · 공격자 목소리와 다른 소리로 (평가 누출 방지).

🍎 지름길 학습 주의

오늘 진짜는 FLAC 낭독, 위조는 MP3 로 받은 TTS 입니다. 탐지기가 "AI 목소리" 가 아니라 "MP3 흔적" 을 배웠을 수도 있습니다. 진짜 목소리를 MP3 로 바꿔 넣어 확인해 보세요.

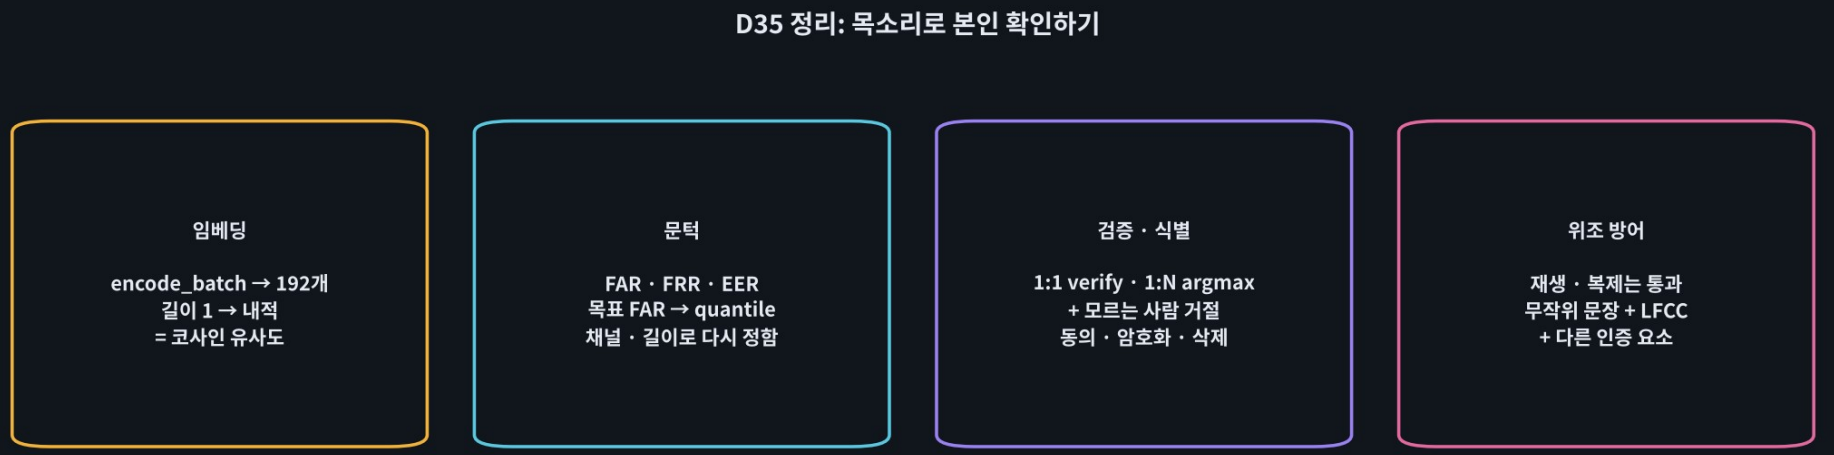
화자 검증 + 무작위 문장 + 위조 탐지 (+ 다른 인증)

관문을 더하면 (예상)	막히는 공격
① 화자 검증	사칭 · TTS
② + 무작위 문장 (STT)	재생 (유출 녹음은 요청 문장이 아님)
③ + 위조 탐지	배운 적 있는 복제 · TTS
④ + 문자 인증	목소리만으로 하는 모든 공격

한빛치과 행동	관문
진료 시간 문의	없음
예약 확인	① + ②
예약 변경 · 기록	① + ② + ③ + ④

어느 관문에서 떨어져도 끊지 않고 대체 수단으로. 떨어진 이유는 로그로 남겨 문턱 · 탐지기를 다시 맞춘다 (D43).

목소리로 본인 확인하기



다음 시간(D36): 목소리에서 '누구'가 아니라 '어떤 상태'를 — 감정 · 말속도 · 소리 이벤트

`animation.html` D35-1 ~ 9

임베딩 · 코사인 · EER · 문턱 · 등록 · 1:N · 공격

`worksheet.html` 하루 25 문항

9 가지 형식 · 오답 정리 → 노션

`D35_화자임베딩_실습.ipynb` ✍️ 직접 작성 4

힌트 · 정답 보기 · T4

온라인 자료 imguru-mooc.github.io/AI_Voice/day35